cdTaller AWS

Presentado por: Johan Daniel Duque Hernández

Repositorio git: https://github.com/Dduquejh/TallerAWS-DE-2026

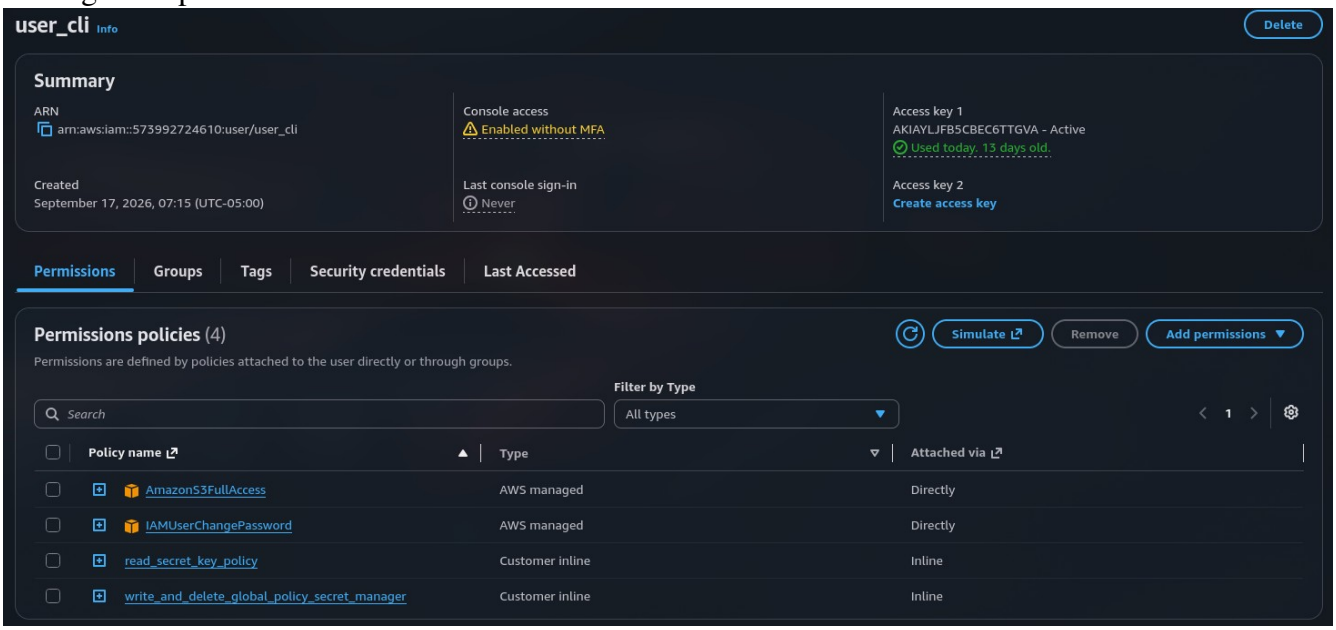
1. AWS Secrets Manager

Servicio que permite administrar, recuperar y rotar las credenciales de acceso de las bases de datos, las credenciales de las aplicaciones, tokens Oauth, claves de API y otros secretos. Se suben en texto plano o en JSON. Mejora la seguridad ya que no necesita credenciales directamente en el código fuente de la aplicación. Se controla quién lo lee con políticas IAM sobre que usuario o rol puede hacer sobre qué secreto. El precio de AWS Secrets Manager es de 0.40 USD/mes por cada secreto. En caso de que no se cumpla el mes se hace el cobro según la cantidad de horas, además, se tiene un cobro por las llamadas al API que es de 0.05 USD por 10.000 llamadas.

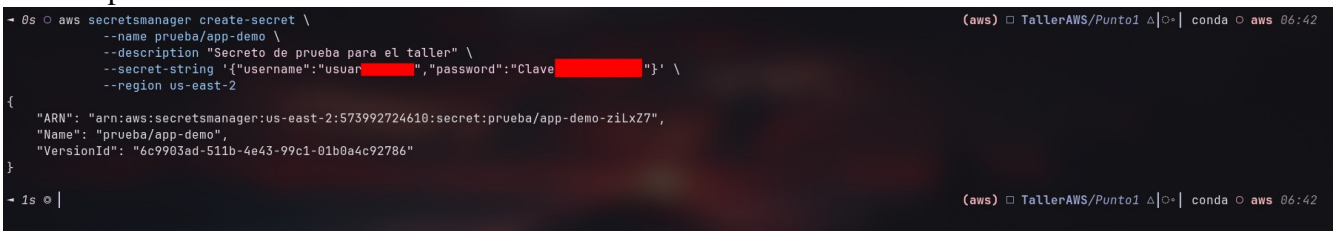
- CreateSecret: Guarda el secreto por primera vez
- GetSecretValue: Obtiene el valor mientras la aplicación se ejecuta
- RotateSecret: Cambiar el valor de forma periódica

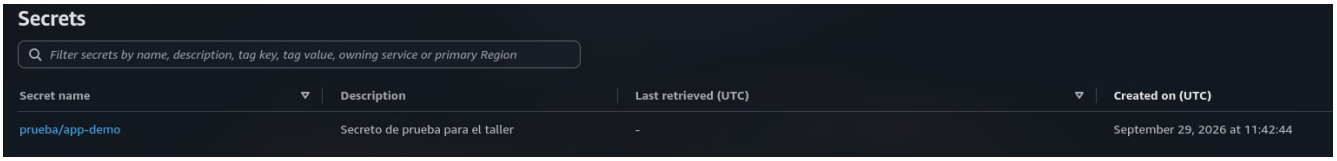
Despliegue

Se cargan las políticas de acceso directamente en la consola de AWS



Con las políticas se crea un secreto usando AWS CLI





Obtener secreto usando el código de python

```
◄ 0s ◎ python punto1.py (aws) □ TallerAWS/Punto1 △|○◦| py ]l 3.12.13 conda ○ aws 06:53
Username: usuar[redacted], Password: Clave[redacted]

◄ 0s ◎ |                (aws) □ TallerAWS/Punto1 △|○◦| py ]l 3.12.13 conda ○ aws 06:53
```

Cambio de secreto

```
◄ 1s ○ aws secretsmanager put-secret-value \
            --secret-id prueba/app-demo \
            --secret-string '{"username":"usuar[redacted]","password":"Camb[redacted]"}'
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:prueba/app-demo-ziLxZ
7",
    "Name": "prueba/app-demo",
    "VersionId": "330811db-ef80-4093-a7f9-2af8ff04dfdd",
    "VersionStages": [
        "AWSCURRENT"
    ]
}
```

Volver a ejecutar el código para obtener el nuevo secreto

```
◄ 1s ◎ python punto1.py (aws) □ TallerAWS/Punto1 △|○◦| py ]l 3.12.13 conda ○ aws 06:57
Username: usua[redacted], Password: Camb[redacted]

◄ 0s ◎ |                (aws) □ TallerAWS/Punto1 △|○◦| py ]l 3.12.13 conda ○ aws 06:57
```

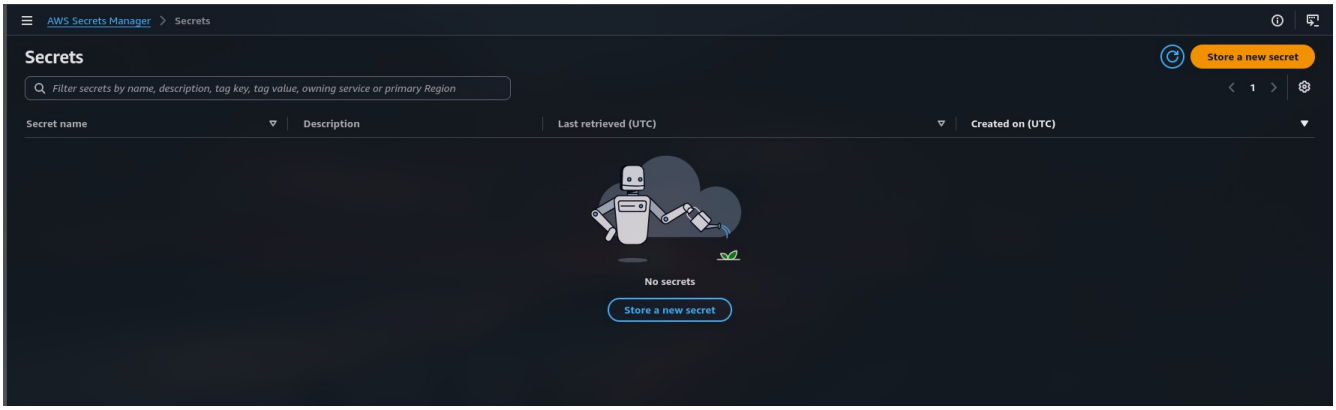
Eliminación

Eliminar el secreto

```
◄ 0s ◎ aws secretsmanager delete-secret \
            --secret-id prueba/app-demo \
            --force-delete-without-recovery

      aws secretsmanager describe-secret --secret-id prueba/app-demo
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:prueba/app-demo-ziLxZ
7",
    "Name": "prueba/app-demo",
    "DeletionDate": "2026-09-29T06:58:39.854000-05:00"
}
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:prueba/app-demo-ziLxZ
7",
    "Name": "prueba/app-demo",
    "Description": "Secreto de prueba para el taller",
    "LastChangedDate": "2026-09-29T06:58:39.868000-05:00",
    "LastAccessedDate": "2026-09-28T19:00:00-05:00",
    "DeletedDate": "2026-09-29T06:58:39.862000-05:00",
    "VersionIdsToStages": {
        "330811db-ef80-4093-a7f9-2af8ff04dfdd": [
            "AWSCURRENT"
        ],
        "8d878a6a-053f-4342-8087-6b61f0e9f7af": [
            "AWSPREVIOUS"
        ]
    },
    "CreatedDate": "2026-09-29T06:42:44.045000-05:00"
}

◄ 2s ◎ |              (aws) □ TallerAWS/Punto1 △|○◦| py ]l 3.12.13 conda ○ aws 06:58
```



2. Despliegue con Terraform, SDK y AWS CLI

Terraform es una herramienta de Infraestructura como Código (IaC) que permite definir, crear y administrar recursos tecnológicos mediante archivo de texto legibles.

- **Definir:** Se escribe la infraestructura ideal necesitada. Se hace en un archivo .tf usando lenguaje HCL. En el documento se define el proveedor de nube y los recursos que se necesitan.

```
# 1. Definir el proveedor (en este caso, AWS)
provider "aws" {
  region = "us-east-2"
}

# 2. Definir el recurso (un servidor virtual simple)
resource "aws_instance" "mi_servidor" {
  ami           = "ami-0c55b159cbfafe1f0" # ID de la imagen del sistema operativo
  instance_type = "t2.micro"              # Tamaño del servidor

  tags = {
    Name = "ServidorDePrueba"
  }
}
```

- **Planificar:** Terraform permite previsualizar que va a pasar antes de realizar cualquier modificación en la nube. Se hace ejecutando terraform plan. Esto lee el código, revisa el estado actual del proveedor de nube y genera un reporte detallando recursos nuevos, recursos existentes que se van a modificar y recursos que se van a eliminar.
- **Crear:** Se despliega la infraestructura una vez se aprueba el plan. Se hace usando terraform apply. Con este comando, terraform hace las llamadas a las APIs del proveedor para levantar la infraestructura definida. Genera un archivo .tfstate donde almacena que ha creado.
- **Eliminar:** Se hace con el comando terraform destroy. Esto lee el archivo .tfstate, detecta los recursos creados y los elimina en el orden inverso de como fueron creados. Se hace cuando la infraestructura ya no es necesaria.

  El usuario IAM `user_cli` autentica AWS CLI, Boto3 y Terraform mediante sus credenciales de acceso de AWS. Estas credenciales están configuradas en el entorno de AWS y las tres herramientas las utilizan para firmar y autenticar las solicitudes ante AWS. Los permisos que puede ejecutar cada herramienta están determinados por las políticas IAM asociadas a `user_cli`.
  Las credenciales de `user_cli` son independientes de las contraseñas de las bases de datos y no deben almacenarse en AWS Secrets Manager como si fueran una contraseña de RDS.

Aunque no se tenga tráfico se siguen generando cargos en el almacenamiento EDS de EC2 y de RDS. Por otro lado, con solo tener encendido el EC2 y el RDS se genera cargo.

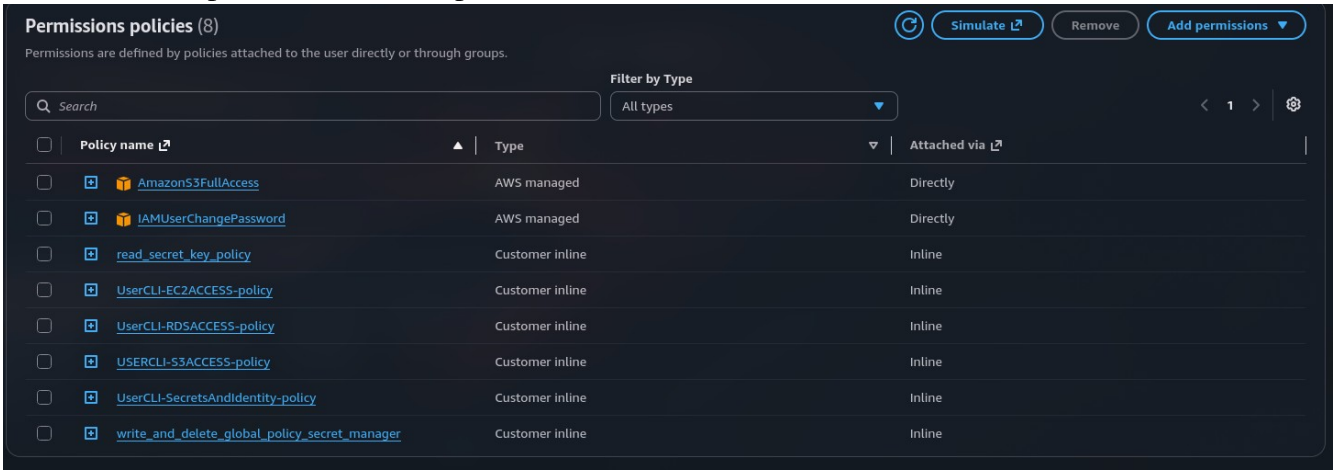
Costos Recursos AWS

Recurso	Tarifa aprox	1 Hora	1 Semana
EC2 (t3.micro)	$0.0104 USD/h	$0.0104 USD	$1.7472 USD
RDS (PostgSQL, t3.micro)	$0.018 USD/h	$0.018 USD	$3.024 USD
S3 (Standar primeros 50TB)	$0.023 USD/GB - mes	$0.00003194 USD/GB	$0.00537 USD/GB
Storage RDS (gp2)	$0.115 USD/GB - mes	$0.0001597 USD/GB	$0.02683 USD/GB
Secrets Manager	$0.40 USD secreto/mes $0.05 USD por cada 10.000 llamadas al API	$0.000556 USD	$0.0933 USD

Terraform

Despliegue

Creación de las políticas de acceso para el usuario user_cli



Validación de usuario en terminal

```
◄ 1s ◎ aws sts get-caller-identity  (aws) □ TallerAWS/Punto2 △|●◦◌◦| conda ○ aws 07:26
{
    "UserId": "AIDAYLJFB5CBB5GMLFRAL",
    "Account": "573992724610",
    "Arn": "arn:aws:iam::573992724610:user/user_cli"
}
```

Configuración de main.tf (configuración de VPC, subnet y security group) y terraform init

```
# Configuración de terraform
terraform {
  required_providers {
    aws = {
      source  = "hashicorp/aws"
    }
  }
}

# Configuración de proveedor y región
provider "aws" {
  region = "us-east-2"
}

# Configuración de componentes de red
locals {
  vpc_id             = "vpc-0f97d7e96864377f2"
  subnet_id          = "subnet-096a4967a3ea16daa"
  security_group_id  = "sg-01cd7b4a43ef5a50c"
  db_subnet_group    = "default-vpc-0f97d7e96864377f2"
  ami_id             = "ami-0ca656964bac97e7f"
```

```
◄ 21s ⋈─◎ terraform init
Initializing the backend...

Initializing provider plugins...
- Finding latest version of hashicorp/aws...
- Installing hashicorp/aws v6.67.0...
- Installed hashicorp/aws v6.67.0 (signed by HashiCorp)

Terraform has created a lock file .terraform.lock.hcl to record the provider
selections it made above. Include this file in your version control repository
so that Terraform can guarantee to make the same selections by default when
you run "terraform init" in the future.

Terraform has been successfully initialized!

You may now begin working with Terraform. Try running "terraform plan" to see
any changes that are required for your infrastructure. All Terraform commands
should now work.

If you ever set or change modules or backend configuration for Terraform,
rerun this command to reinitialize your working directory. If you forget, other
commands will detect it and remind you to do so if necessary.

◄ 9s ⋈─◎ □            (aws) □ Punto2/terraform|●◦○◦|via ▯  default  conda ○ aws 20:48
```

terraform validate

```
◄ 9s ⋈─◎ terraform validate
Success! The configuration is valid.


◄ 2s ⋈─◎ □            (aws) □ Punto2/terraform|●◦○◦|via ▯  default  conda ○ aws 20:50
```

Agregar S3 al main.tf

```
# Obtener ID de la cuenta
data "aws_caller_identity" "current" {}

# Creación del bucket de S3
resource "aws_s3_bucket" "taller" {
  bucket = "talleraws-de-2026-${data.aws_caller_identity.current.account_id}"
}}
```

Agregar EC2 al main.tf

```
# Creación de EC2
resource "aws_instance" "taller" {
  ami           = local.ami_id
  instance_type = "t3.micro"

  subnet_id                   = local.subnet_id
  vpc_security_group_ids      = [local.security_group_id]
  associate_public_ip_address = true

  tags = {
    Name = "TallerAWS-Terraform-EC2"
  }
}
```

Agregar RDS al main.tf

```
# Creación de RDS
resource "aws_db_instance" "taller" {
  identifier = "talleraws-terraform-rds"

  engine         = "postgres"
  instance_class = "db.t3.micro"

  allocated_storage = 20
  storage_type      = "gp2"

  db_name  = "talleraws"
  username = "admin"

  manage_master_user_password = true

  db_subnet_group_name   = local.db_subnet_group
  vpc_security_group_ids = [local.security_group_id]

  publicly_accessible = false

  skip_final_snapshot = true

  tags = {
    Name = "TallerAWS-Terraform-RDS"
  }
}
~
```

```
◄ 0s ◎ terraform fmt   (aws) □ Punto2/terraform|●◦○◦|via ▯  default  conda ○ aws 21:02
main.tf

◄ 0s ◎ terraform validate
Success! The configuration is valid.


◄ 2s ◎ |              (aws) □ Punto2/terraform|●◦○◦|via ▯  default  conda ○ aws 21:03
```

Terraform plan

```
◄ 3s ○ terraform plan  (aws) □ Punto2/terraform|●◦○◦|via ⍁  default  conda ○ aws 21:04
data.aws_caller_identity.current: Reading...
data.aws_caller_identity.current: Read complete after 0s [id=573992724610]

Terraform used the selected providers to generate the following execution plan.
Resource actions are indicated with the following symbols:
  + create

Terraform will perform the following actions:

  # aws_db_instance.taller will be created
  + resource "aws_db_instance" "taller" {
      + address                               = (known after apply)
      + allocated_storage                     = 20
      + apply_immediately                     = false
      + arn                                   = (known after apply)
      + auto_minor_version_upgrade            = true
      + availability_zone                     = (known after apply)
      + backup_retention_period               = (known after apply)
      + backup_target                         = (known after apply)
      + backup_window                         = (known after apply)
      + ca_cert_identifier                    = (known after apply)
      + character_set_name                    = (known after apply)
      + copy_tags_to_snapshot                 = false
      + database_insights_mode                = (known after apply)
      + db_name                               = "talleraws"
      + db_subnet_group_name                  = "default-vpc-0f97d7e96864377f2"
      + dedicated_log_volume                  = false
      + delete_automated_backups              = true
      + domain_fqdn                           = (known after apply)
      + endpoint                              = (known after apply)
      + engine                                = "postgres"
      + engine_lifecycle_support              = (known after apply)
      + engine_version                        = (known after apply)
      + engine_version_actual                 = (known after apply)
      + hosted_zone_id                        = (known after apply)
      + id                                    = (known after apply)
      + identifier                            = "talleraws-terraform-rds"
      + identifier_prefix                     = (known after apply)
      + instance_class                        = "db.t3.micro"
      + iops                                  = (known after apply)
      + kms_key_id                            = (known after apply)
      + latest_restorable_time                = (known after apply)
      + license_model                         = (known after apply)
      + listener_endpoint                     = (known after apply)
```

```
    + kms_key_id                            = (known after apply)
    + latest_restorable_time                = (known after apply)
    + license_model                         = (known after apply)
    + listener_endpoint                     = (known after apply)
    + maintenance_window                    = (known after apply)
    + manage_master_user_password           = true
    + master_user_secret                    = (known after apply)
    + master_user_secret_kms_key_id         = (known after apply)
    + monitoring_interval                   = 0
    + monitoring_role_arn                   = (known after apply)
    + multi_az                              = (known after apply)
    + nchar_character_set_name              = (known after apply)
    + network_type                          = (known after apply)
    + option_group_name                     = (known after apply)
    + parameter_group_name                  = (known after apply)
    + password_wo                           = (write-only attribute)
    + performance_insights_enabled          = false
    + performance_insights_kms_key_id       = (known after apply)
    + performance_insights_retention_period = (known after apply)
    + port                                  = (known after apply)
    + publicly_accessible                   = false
    + region                                = "us-east-2"
    + replica_mode                          = (known after apply)
    + replicas                              = (known after apply)
    + resource_id                           = (known after apply)
    + skip_final_snapshot                   = true
    + snapshot_identifier                   = (known after apply)
    + status                                = (known after apply)
    + storage_throughput                    = (known after apply)
    + storage_type                          = "gp2"
    + tags                                  = {
        + "Name" = "TallerAWS-Terraform-RDS"
      }
    + tags_all                              = {
        + "Name" = "TallerAWS-Terraform-RDS"
      }
    + timezone                              = (known after apply)
    + upgrade_rollout_order                 = (known after apply)
    + username                              = "admin"
    + vpc_security_group_ids                = [
        + "sg-01cd7b4a43ef5a50c",
      ]
  }

# aws_instance.taller will be created
```

```
# aws_instance.taller will be created
+ resource "aws_instance" "taller" {
    + ami                                  = "ami-0ca656964bac97e7f"
    + arn                                  = (known after apply)
    + associate_public_ip_address          = true
    + availability_zone                    = (known after apply)
    + disable_api_stop                     = (known after apply)
    + disable_api_termination              = (known after apply)
    + ebs_optimized                        = (known after apply)
    + enable_primary_ipv6                  = (known after apply)
    + force_destroy                        = false
    + get_password_data                    = false
    + host_id                              = (known after apply)
    + host_resource_group_arn              = (known after apply)
    + iam_instance_profile                 = (known after apply)
    + id                                   = (known after apply)
    + instance_initiated_shutdown_behavior = (known after apply)
    + instance_lifecycle                   = (known after apply)
    + instance_state                       = (known after apply)
    + instance_type                        = "t3.micro"
    + ipv6_address_count                   = (known after apply)
    + ipv6_addresses                       = (known after apply)
    + key_name                             = (known after apply)
    + monitoring                           = (known after apply)
    + outpost_arn                          = (known after apply)
    + password_data                        = (known after apply)
    + placement_group                      = (known after apply)
    + placement_group_id                   = (known after apply)
    + placement_partition_number           = (known after apply)
    + primary_network_interface_id         = (known after apply)
    + private_dns                          = (known after apply)
    + private_ip                           = (known after apply)
    + public_dns                           = (known after apply)
    + public_ip                            = (known after apply)
    + region                               = "us-east-2"
    + secondary_private_ips                = (known after apply)
    + security_groups                      = (known after apply)
    + source_dest_check                    = true
    + spot_instance_request_id             = (known after apply)
    + subnet_id                            = "subnet-096a4967a3ea16daa"
    + tags                                 = {
        + "Name" = "TallerAWS-Terraform-EC2"
      }
    + tags_all                             = {
```

```
      + "Name" = "TallerAWS-Terraform-EC2"
    }
  + tags_all                              = {
      + "Name" = "TallerAWS-Terraform-EC2"
    }
  + tenancy                               = (known after apply)
  + user_data_base64                      = (known after apply)
  + user_data_replace_on_change           = false
  + vpc_security_group_ids                = [
      + "sg-01cd7b4a43ef5a50c",
    ]

  + capacity_reservation_specification (known after apply)

  + cpu_options (known after apply)

  + ebs_block_device (known after apply)

  + enclave_options (known after apply)

  + ephemeral_block_device (known after apply)

  + instance_market_options (known after apply)

  + maintenance_options (known after apply)

  + metadata_options (known after apply)

  + network_interface (known after apply)

  + primary_network_interface (known after apply)

  + private_dns_name_options (known after apply)

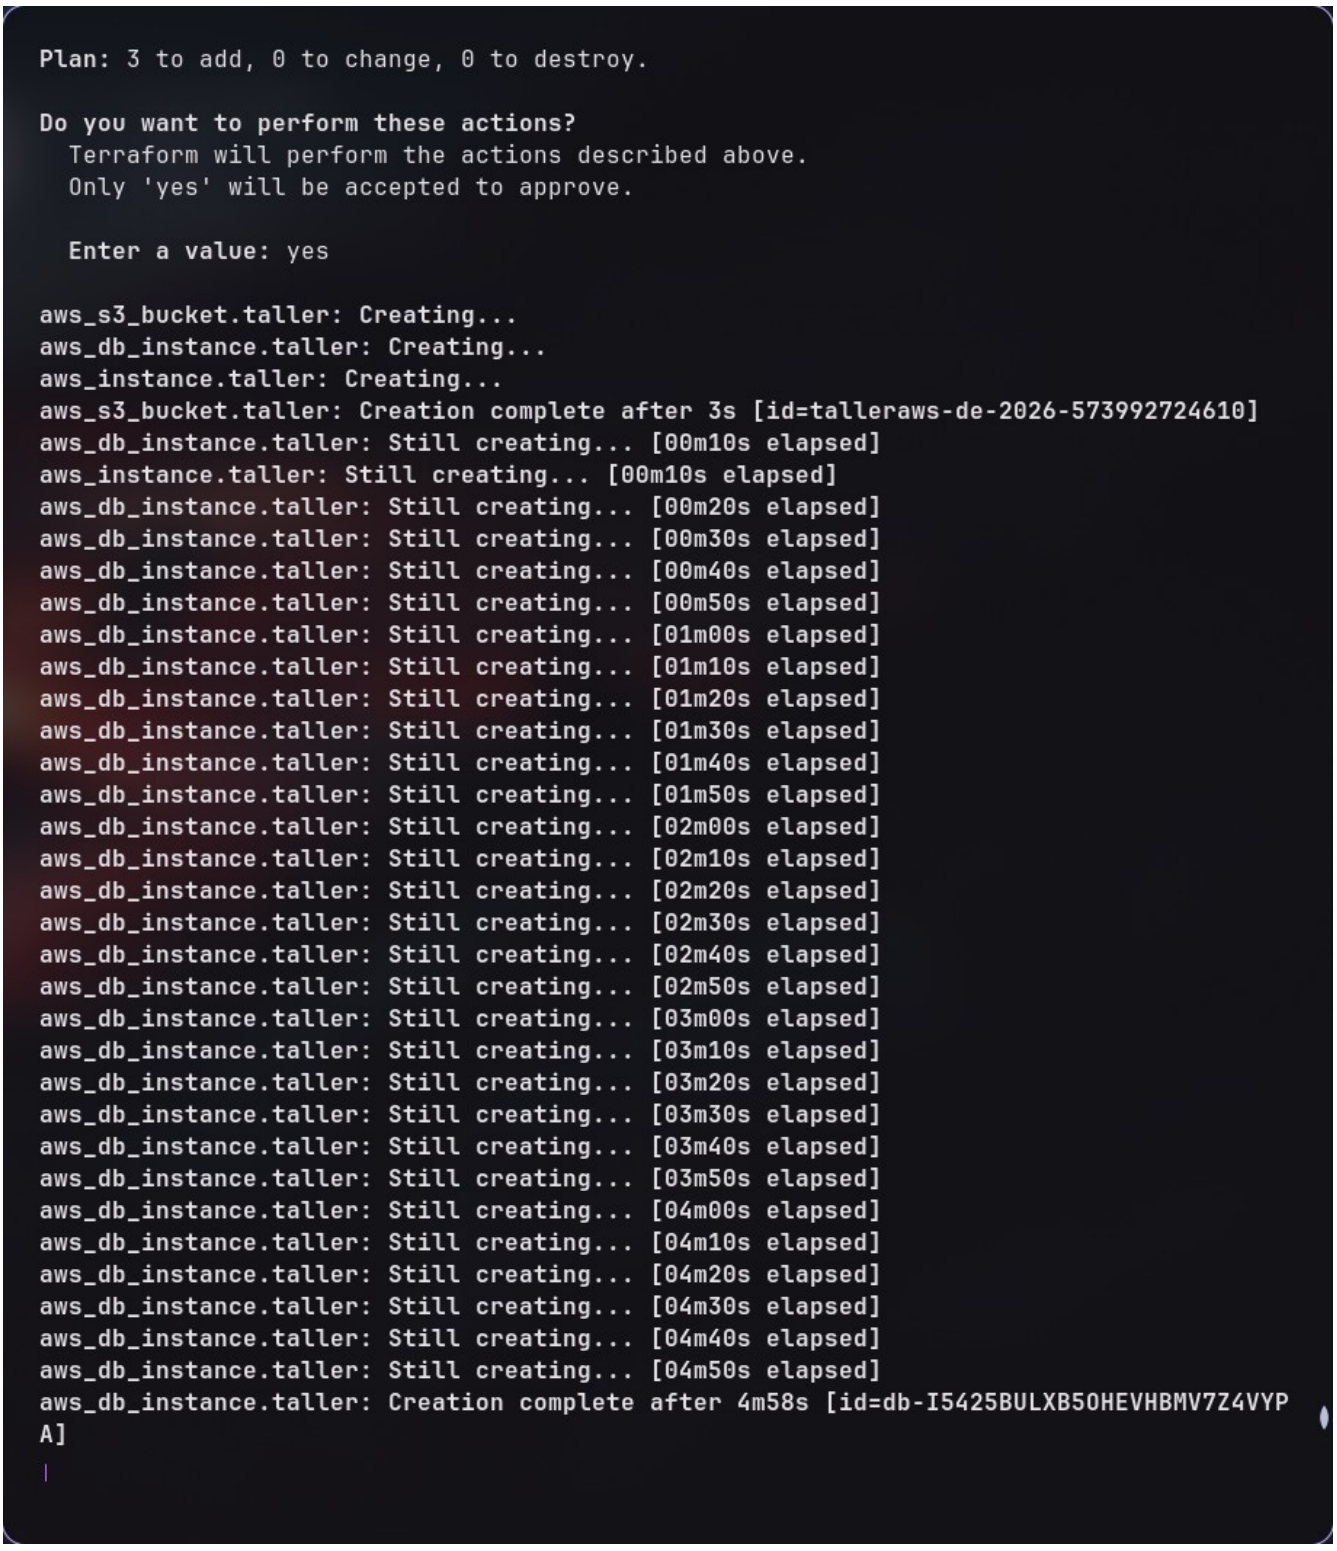
  + root_block_device (known after apply)

  + secondary_network_interface (known after apply)
}

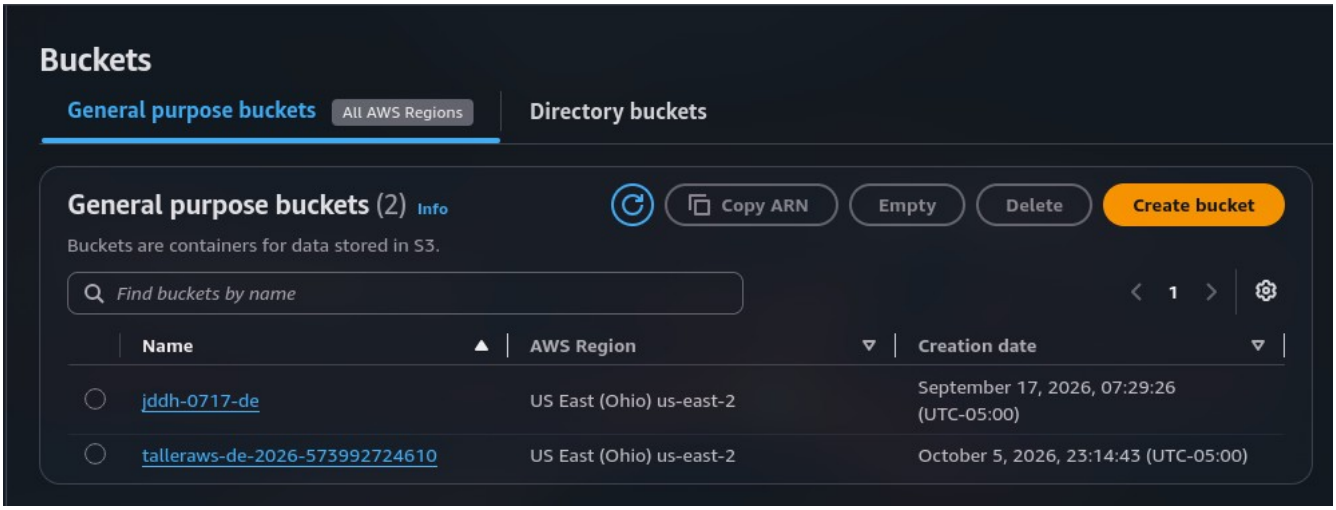
# aws_s3_bucket.taller will be created
+ resource "aws_s3_bucket" "taller" {
  + acceleration_status         = (known after apply)
  + acl                         = (known after apply)
  + arn                         = (known after apply)
  + bucket                      = "talleraws-de-2026-573992724610"
```



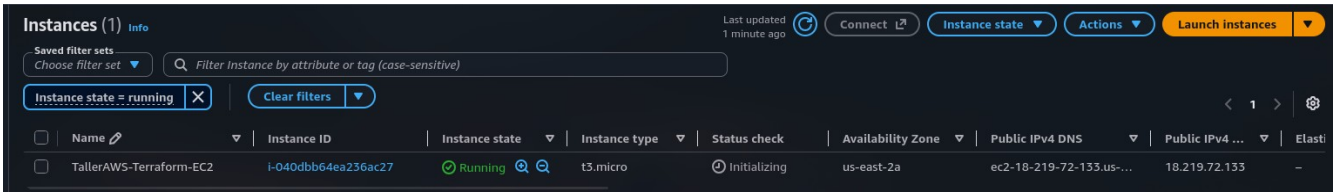
terraform apply



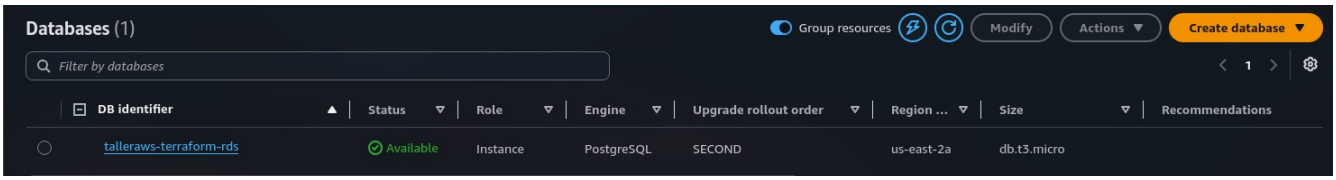
Bucket S3 Terraform



EC2 Terraform



RDS Terraform



Eliminación

terraform destroy

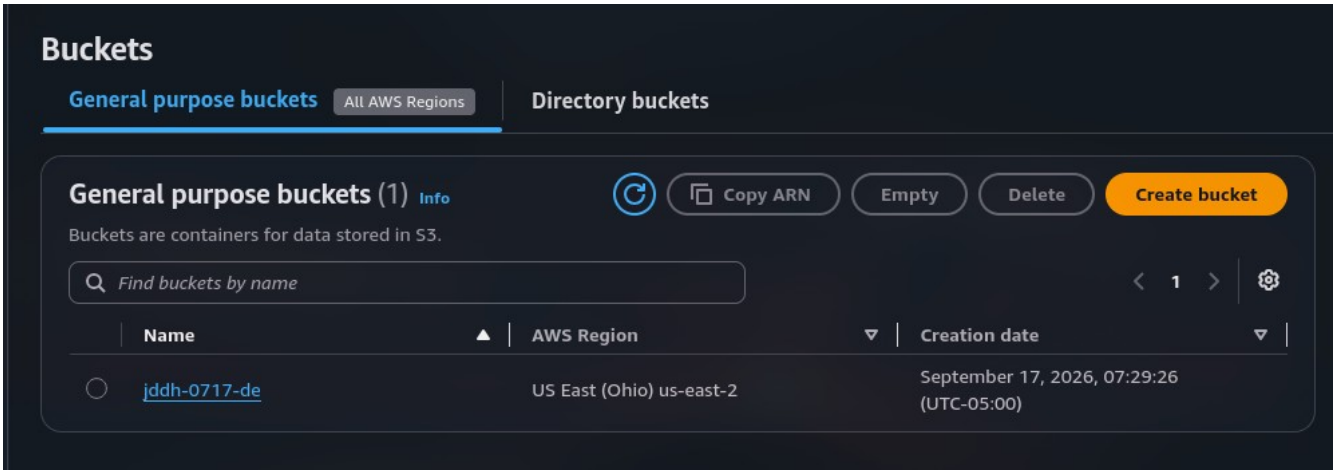
```
→ 0s ◎ terraform destroy
data.aws_caller_identity.current: Reading...
aws_instance.taller: Refreshing state... [id=i-040dbb64ea236ac27]
aws_db_instance.taller: Refreshing state... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA]
data.aws_caller_identity.current: Read complete after 0s [id=573992724610]
aws_s3_bucket.taller: Refreshing state... [id=talleraws-de-2026-573992724610]

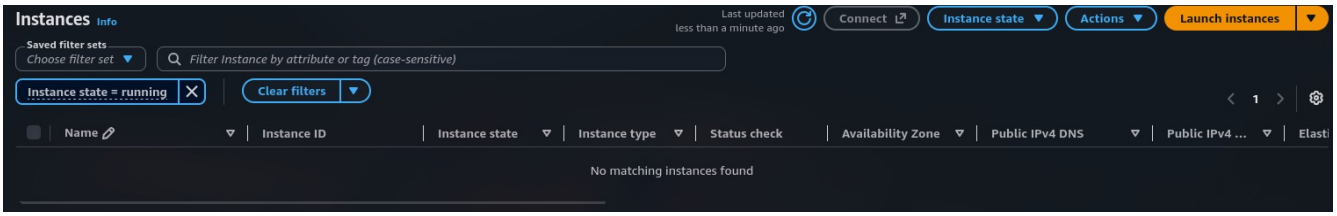
Terraform used the selected providers to generate the following execution plan.
Resource actions are indicated with the following symbols:
  - destroy
```

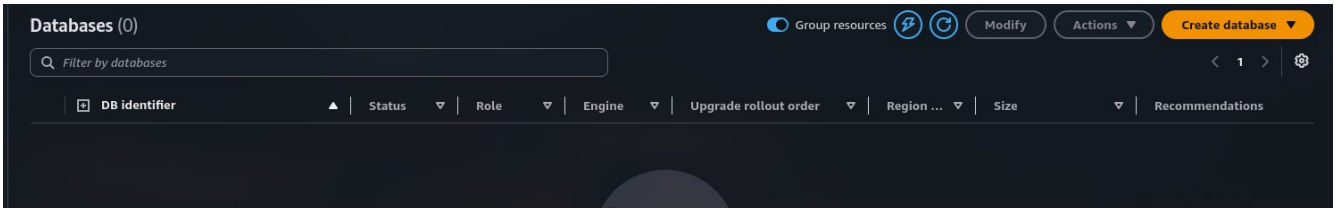
```
^[[Caws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 00m
40s elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 00m50s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m00s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m10s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m20s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m30s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m40s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 01m50s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m00s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m10s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m20s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m30s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m40s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 02m50s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m00s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m10s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m20s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m30s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m40s
elapsed]
aws_db_instance.taller: Still destroying... [id=db-I5425BULXB5OHEVHBMV7Z4VYPA, 03m50s
elapsed]
aws_db_instance.taller: Destruction complete after 3m54s

Destroy complete! Resources: 3 destroyed.

◄ 4m10s ◎ [redacted]          (aws) □ Punto2/terraform|●◦○◦|via ⍁  default  conda ○ aws 23:36
```







Python (boto3)

Despliegue

Ejecución de los scripts de Python (boto3)

```
◄ 2s ◎ python boto3_create.py
                                (aws) □ Punto2/boto3|●◦○◦| py 𝄀 3.12.13 conda ○ aws
23:48
=== Creando S3 ===
S3 creado: talleraws-de-2026-573992724610

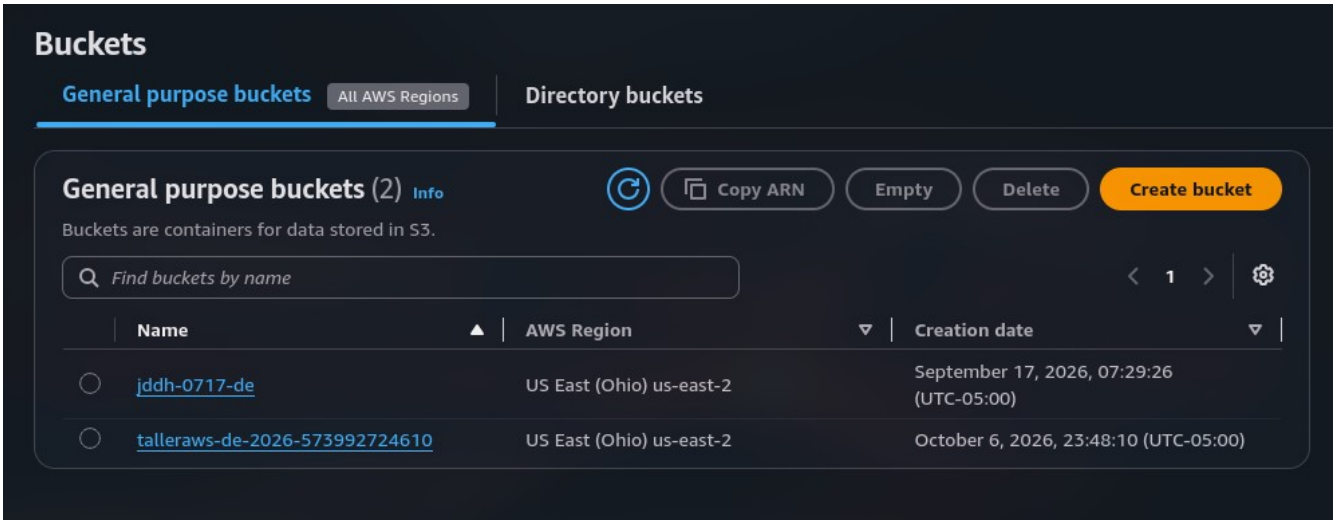
=== Creando EC2 ===
EC2 creada: i-04b258c22149bf622
Esperando a que EC2 esté disponible...
EC2 está en estado running.

=== Creando RDS ===
RDS creado: talleraws-boto3-rds
Esperando a que RDS esté disponible...
RDS está disponible.

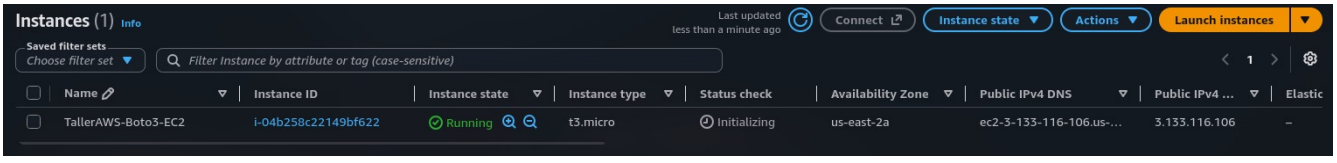
=== DESPLIEGUE COMPLETADO ===
S3 : talleraws-de-2026-573992724610
EC2: i-04b258c22149bf622
RDS: talleraws-boto3-rds


◄ 4m51s ◎ |                     (aws) □ Punto2/boto3|●◦○◦| py 𝄀 3.12.13 conda ○ aws 23:53
```

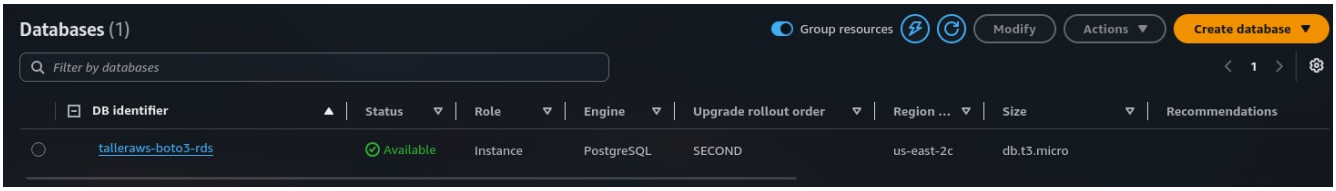
s3



EC2



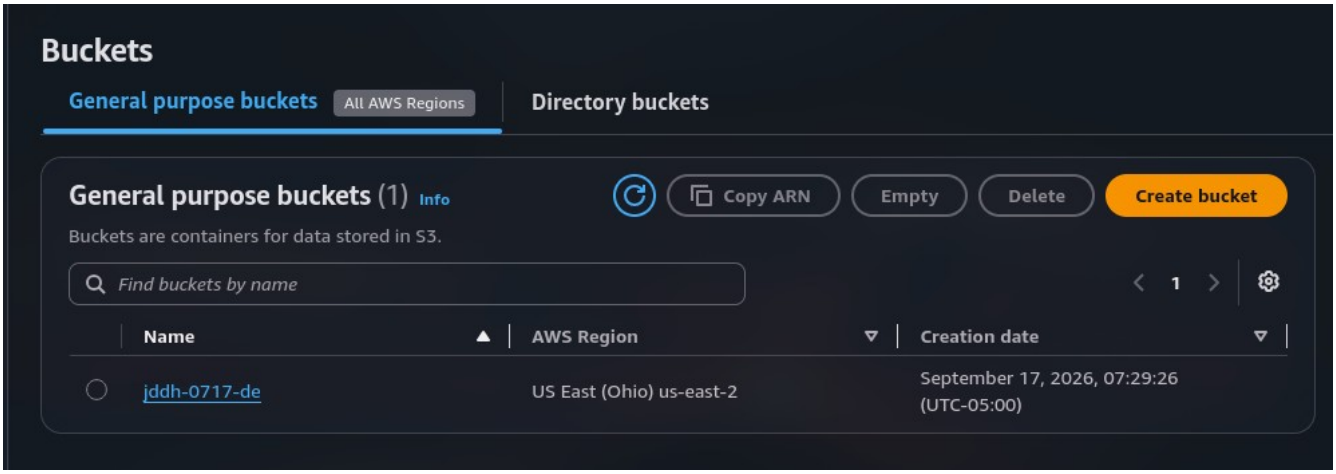
RDS



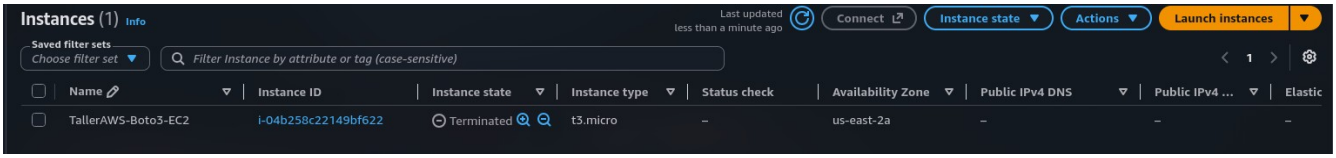
Eliminación



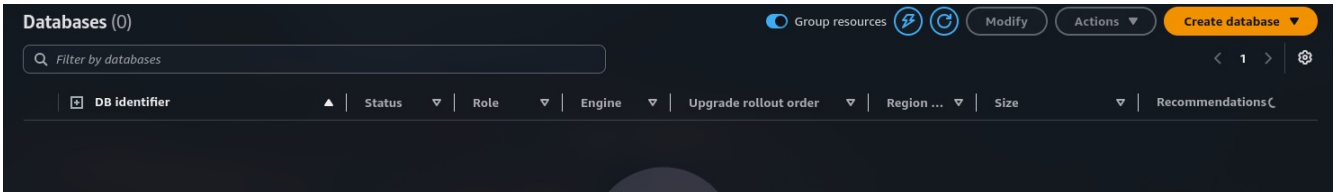
S3



EC2



RDS



AWS CLI

Despliegue

Creación de servicios con aws cli usando script de bash

```
◄ 0s ◎ bash cli_create.sh                    (aws) □ Punto2/aws_cli|●◦◌◦| conda ○ aws 00:00
=== Creando S3 ===
{
    "Location": "http://talleraws-de-2026-573992724610-cli.s3.amazonaws.com/",
    "BucketArn": "arn:aws:s3:::talleraws-de-2026-573992724610-cli"
}
S3 creado: talleraws-de-2026-573992724610-cli

=== Creando EC2 ===
EC2 creado: i-089de46f4f7da3120
Esperando a que EC2 esté en estado running...
EC2 listo.
IP pública: 13.58.189.235

=== Creando RDS ===
{
    "DBInstance": {
        "DBInstanceIdentifier": "talleraws-cli-rds",
        "DBInstanceClass": "db.t3.micro",
        "Engine": "postgres",
        "DBInstanceStatus": "creating",
```

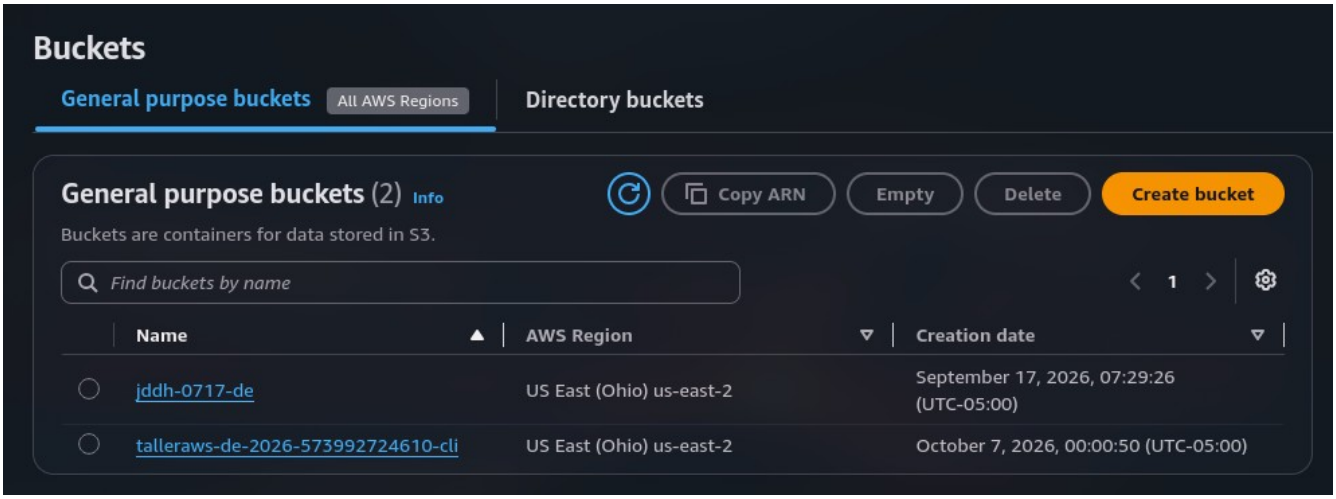
```
RDS solicitado: talleraws-cli-rds
Esperando a que RDS esté disponible...
RDS listo.

=====================================
      RECURSOS CREADOS CORRECTAMENTE
=====================================
S3:  talleraws-de-2026-573992724610-cli
EC2: i-089de46f4f7da3120
RDS: talleraws-cli-rds
EC2 IP pública: 13.58.189.235

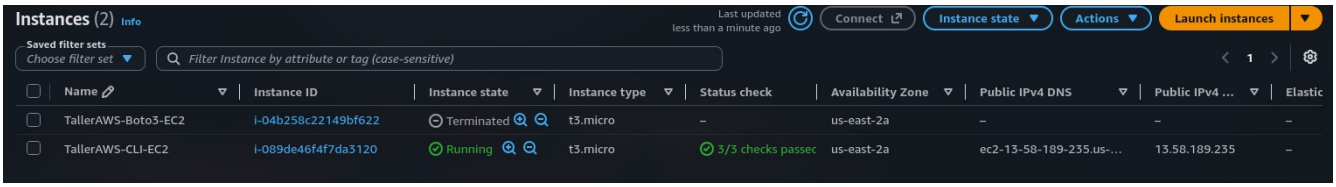
Todos los recursos están listos.

◄ 5m18s ◎                                   (aws) □ Punto2/aws_cli|●◦◌◦| conda ○ aws 00:06
```

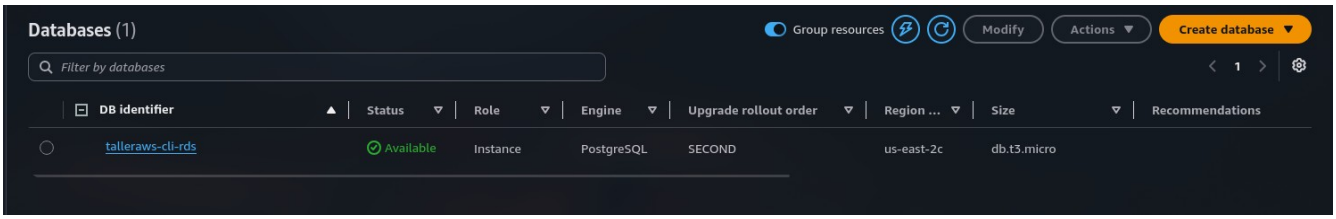
S3



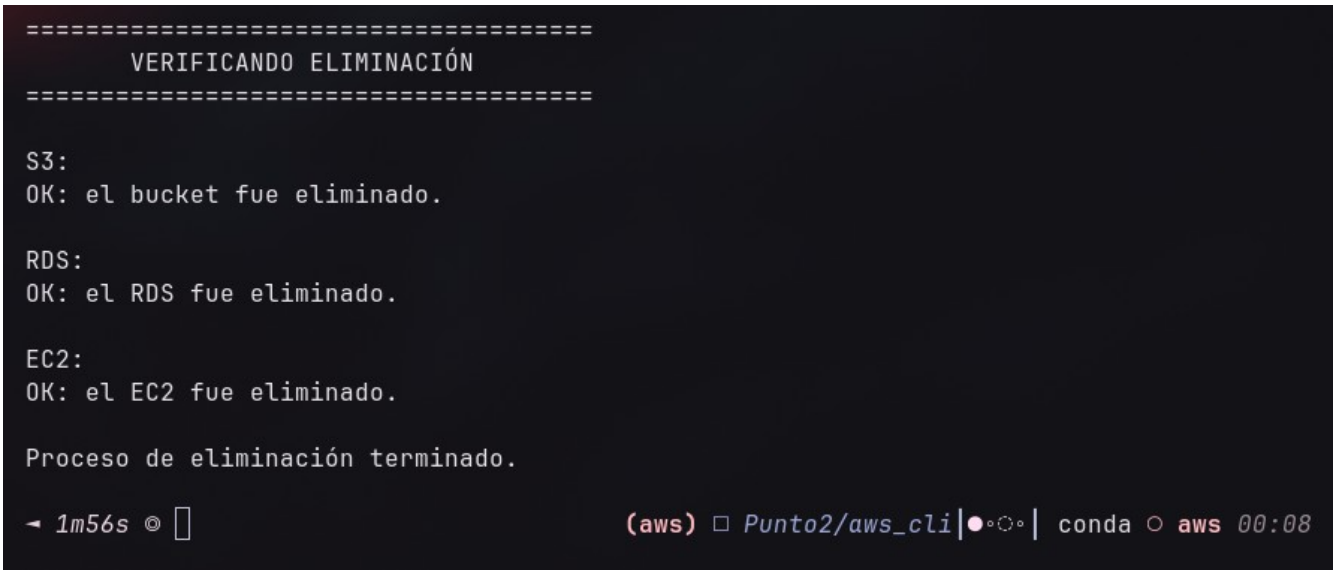
EC2



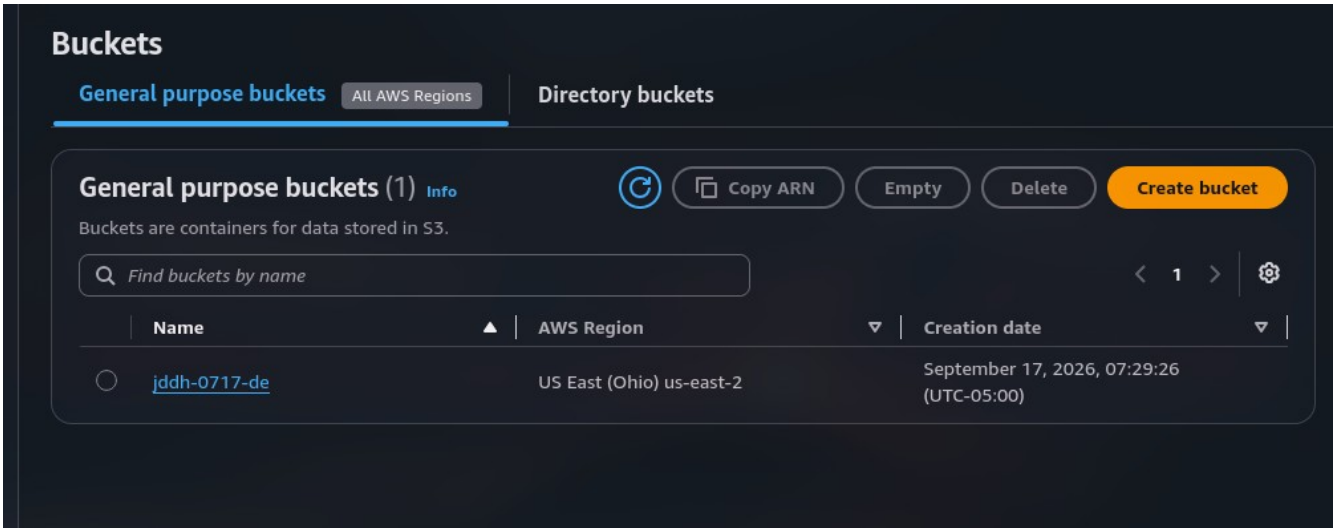
RDS



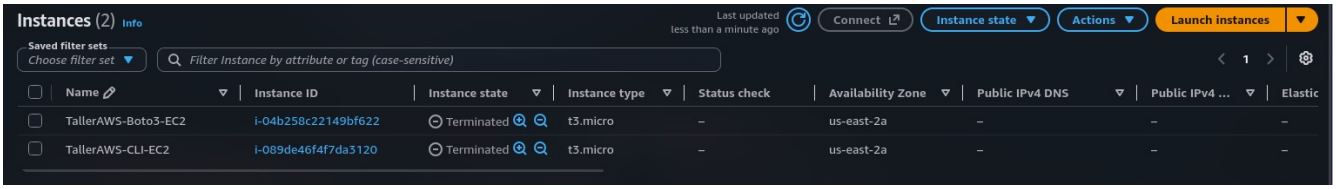
Eliminación



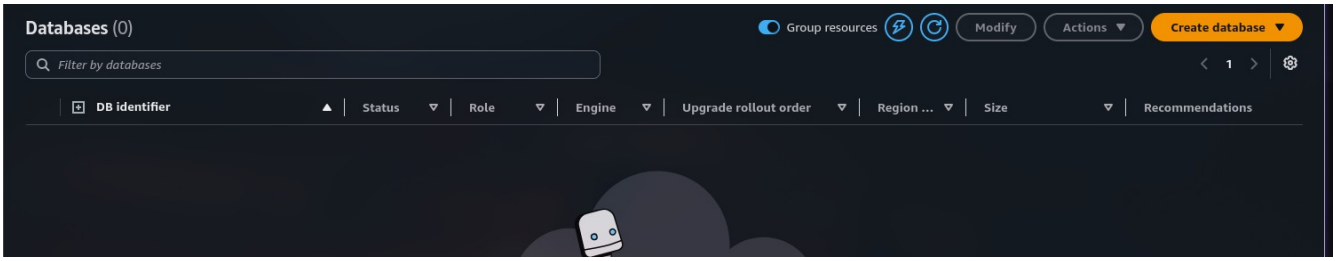
S3


Buckets
General purpose buckets
All AWS Regions
Directory buckets
General purpose buckets (1) Info
Copy ARN
Empty
Delete
Create bucket
Buckets are containers for data stored in S3.
Find buckets by name
1
Name
AWS Region
Creation date
jddh-0717-de
US East (Ohio) us-east-2
September 17, 2026, 07:29:26 (UTC-05:00)

EC2


Instances (2) Info
Last updated less than a minute ago
Connect
Instance state
Actions
Launch instances
Saved filter sets
Choose filter set
Filter Instance by attribute or tag (case-sensitive)
1
Name
Instance ID
Instance state
Instance type
Status check
Availability Zone
Public IPv4 DNS
Public IPv4 ...
Elastic
TallerAWS-Boto3-EC2
i-04b258c22149bf622
Terminated
t3.micro
–
us-east-2a
–
–
–
TallerAWS-CLI-EC2
i-089de46f4f7da3120
Terminated
t3.micro
–
us-east-2a
–
–
–

RDS


Databases (0)
Group resources
Modify
Actions
Create database
Filter by databases
1
DB identifier
Status
Role
Engine
Upgrade rollout order
Region ...
Size
Recommendations

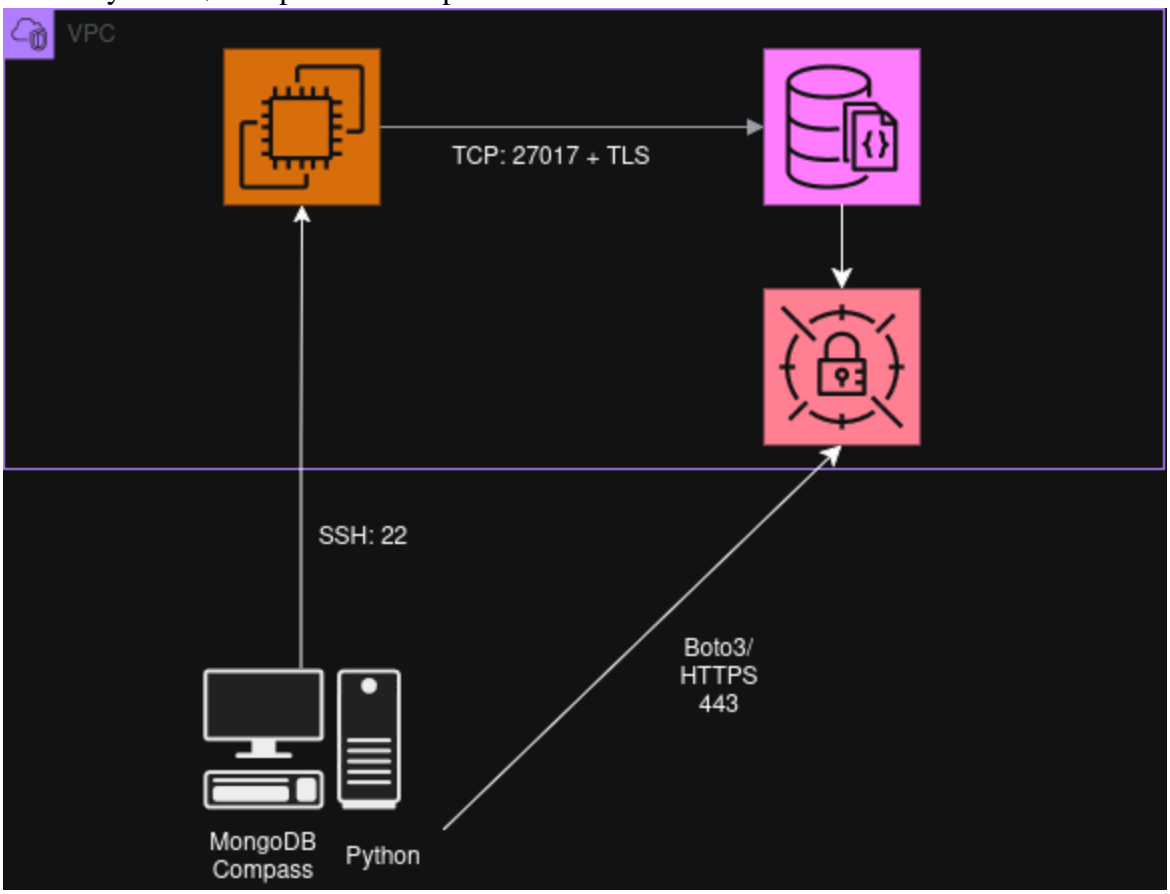
3. Amazon DocumentDB

Tanto MongoDB como DocumentDB utilizan el mismo modelo de datos basado en JSON. DocumentDB no usa el código de MongoDB por debajo, pero el servicio emula la API de MongoDB y soporta protocolos de MongoDB 3.6, 4.0, 5.0 y 8.0.

En DocumentDB los datos se almacenan en una capa de almacenamiento distribuida propia de AWS, esto desacopla el cómputo del almacenamiento, mientras que MongoDB usa nodos de cómputo y almacenamiento en las mismas instancias.

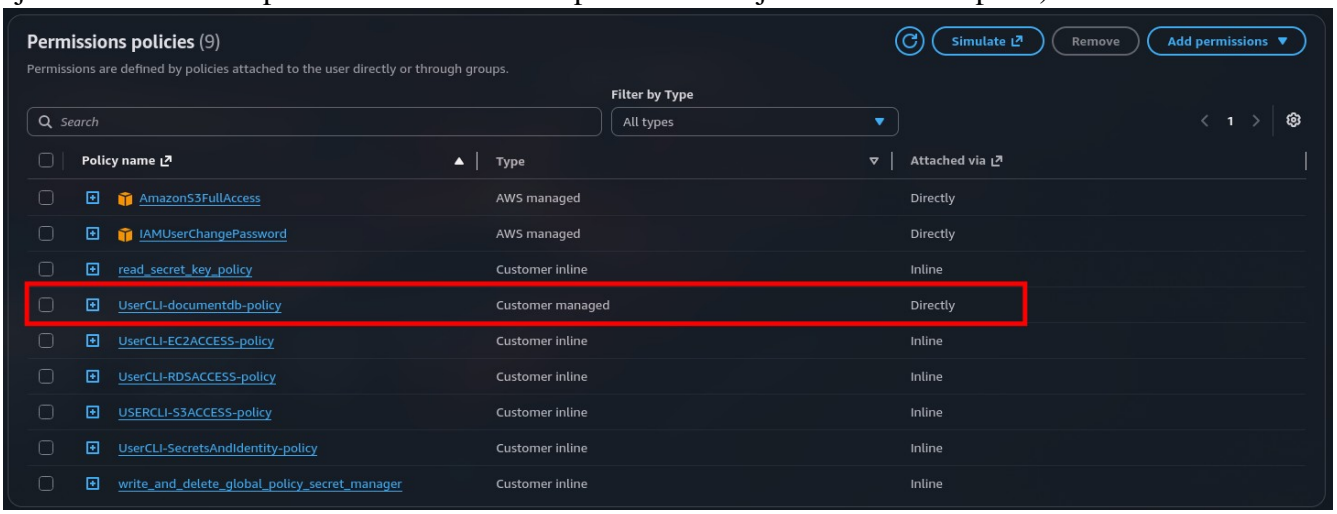
Amazon DocumentDB emula la API de MongoDB sobre una arquitectura propia desacoplada, lo que genera tres incompatibilidades críticas frente a MongoDB nativo: cobertura incompleta de la API (fallos al ejecutar ciertas etapas de agregación complejas como `$lookup` correlacionados o `$facet`), ausencia de motores nativos de búsqueda (carece de *Atlas Search* para texto completo avanzado o *Vector Search* para IA) y restricciones en transacciones ACID (límites de tiempo de ejecución más estrictos y un comportamiento distinto en la concurrencia de bloqueos por no utilizar el motor *WiredTiger*).

Para la práctica, DocumentDB Standard ($0.0822 por DCU/hora) cuesta menos que DocumentDB I/O-Optimized ($0.0905 por DCU/hora). Esto dado que el volumen de operaciones de I/O es extremadamente bajo. Usando una t3.micro como instancia de EC2 se agregaría un costo de $0.0104 USD por hora y unos $0.08 por GB/mes por almacenamiento.



Despliegue

Se crea la politica para trabajar con DocumentDB y EC2 (aunque se tiene permiso de EC2 por el ejercicio anterior se plantea acá nuevamente para hacer el ejercicio más completo)



Creación del grupo de seguridad para acceder unicamente desde la IP de mi computador para el EC2

```
◄ 1s ○ aws ec2 create-security-group \                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 20:53
            --group-name docdb-ec2-bastion-sg \
            --description "SSH desde la IP del administrador para el bastion de DocumentDB" \
            --vpc-id vpc-0f97d7e96864377f2 \
            --region us-east-2
{
    "GroupId": "sg-0d2cd2df16b28021f",
    "SecurityGroupArn": "arn:aws:ec2:us-east-2:573992724610:security-group/sg-0d2cd2df16b28021f"
}
◄ 1s ◎                                                   (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 20:53
```

```
◄ 4s ◎ aws ec2 authorize-security-group-ingress \        (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 20:54
            --group-id sg-0d2cd2df16b28021f \
            --protocol tcp \
            --port 22 \
            --cidr "$MI_IP/32" \
            --region us-east-2
{
    "Return": true,
    "SecurityGroupRules": [
        {
            "SecurityGroupRuleId": "sgr-044235d152562e2ef",
            "GroupId": "sg-0d2cd2df16b28021f",
            "GroupOwnerId": "573992724610",
            "IsEgress": false,
            "IpProtocol": "tcp",
            "FromPort": 22,
            "ToPort": 22,
            "CidrIpv4": "181.58.39.23/32",
            "SecurityGroupRuleArn": "arn:aws:ec2:us-east-2:573992724610:security-group-rule/sgr-044235d152562e2ef"
        }
    ]
}
```

Crear el grupo de seguridad para DocumentDB

```
◄ 1s ○ aws ec2 create-security-group \                    (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 20:56
            --group-name docdb-database-sg \
            --description "Acceso privado a DocumentDB desde el bastion EC2" \
            --vpc-id vpc-0f97d7e96864377f2 \
            --region us-east-2
{
    "GroupId": "sg-092450742548e6149",
    "SecurityGroupArn": "arn:aws:ec2:us-east-2:573992724610:security-group/sg-092450742548e6149"
}
```

Permitir el puerto 27017 para que el EC2 se pueda conectar a Document DB

```
◄ 1s ◎ set SG_EC2 sg-0d2cd2df16b28021f                   (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 20:57
      set SG_DOCDB sg-092450742548e6149

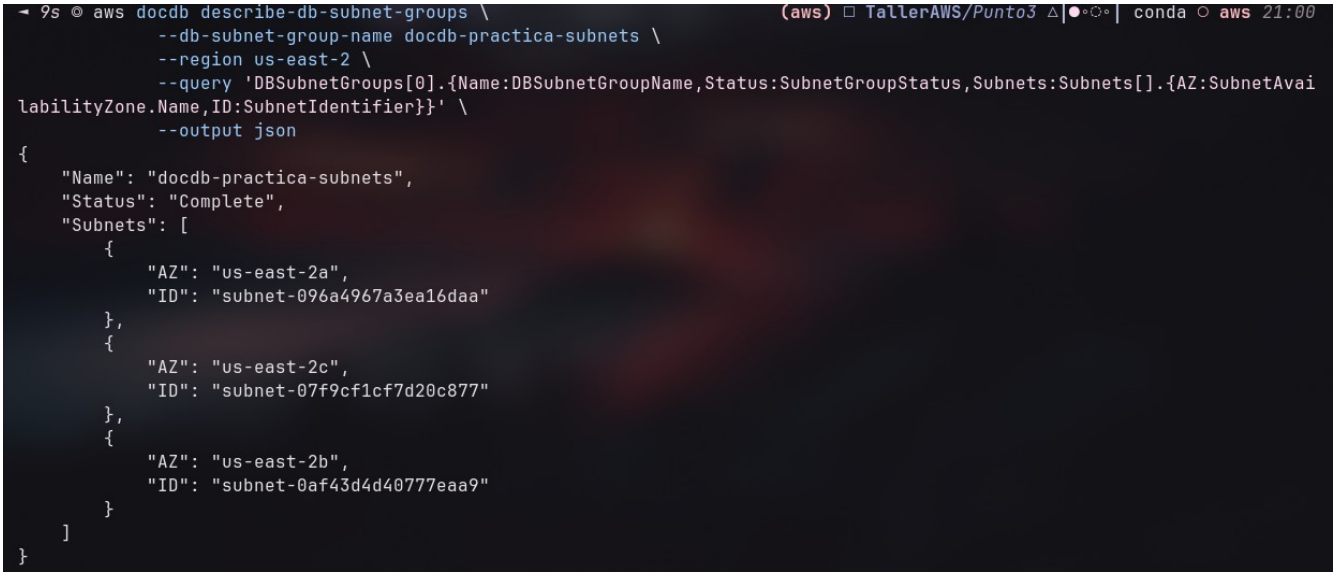
      aws ec2 authorize-security-group-ingress \
            --group-id $SG_DOCDB \
            --protocol tcp \
            --port 27017 \
            --source-group $SG_EC2 \
            --region us-east-2
{
    "Return": true,
    "SecurityGroupRules": [
        {
            "SecurityGroupRuleId": "sgr-0300455b9b803747b",
            "GroupId": "sg-092450742548e6149",
            "GroupOwnerId": "573992724610",
            "IsEgress": false,
            "IpProtocol": "tcp",
            "FromPort": 27017,
            "ToPort": 27017,
            "ReferencedGroupInfo": {
                "GroupId": "sg-0d2cd2df16b28021f",
                "UserId": "573992724610"
            },
            "SecurityGroupRuleArn": "arn:aws:ec2:us-east-2:573992724610:security-group-rule/sgr-0300455b9b803747b"
        }
    ]
}
```

Creación del cluster de DocumentDB

```
◄ 1s ◎ aws docdb create-db-subnet-group \                (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:00
            --db-subnet-group-name docdb-practica-subnets \
            --db-subnet-group-description "Subredes para la practica de Amazon DocumentDB" \
            --subnet-ids \
              subnet-0af43d4d40777eaa9 \
              subnet-096a4967a3ea16daa \
              subnet-07f9cf1cf7d20c877 \
            --region us-east-2
{
    "DBSubnetGroup": {
        "DBSubnetGroupName": "docdb-practica-subnets",
        "DBSubnetGroupDescription": "Subredes para la practica de Amazon DocumentDB",
        "VpcId": "vpc-0f97d7e96864377f2",
        "SubnetGroupStatus": "Complete",
        "Subnets": [
            {
                "SubnetIdentifier": "subnet-096a4967a3ea16daa",
                "SubnetAvailabilityZone": {
                    "Name": "us-east-2a"
                },
                "SubnetStatus": "Active"
            },
            {
                "SubnetIdentifier": "subnet-07f9cf1cf7d20c877",
                "SubnetAvailabilityZone": {
                    "Name": "us-east-2c"
                },
                "SubnetStatus": "Active"
```

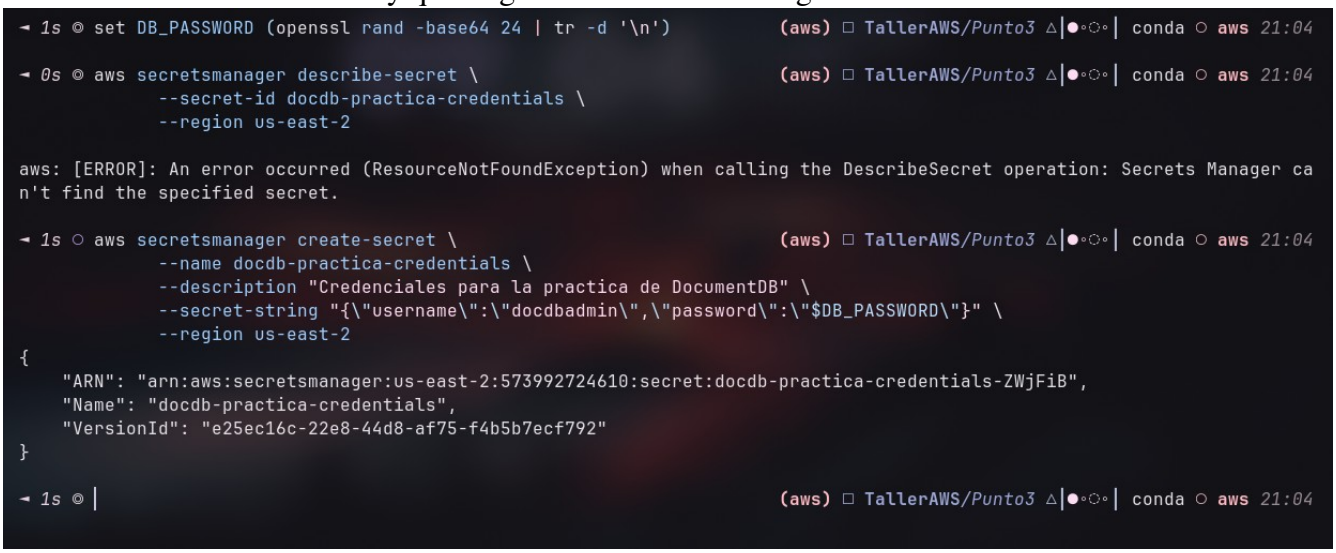


```
            {
                "SubnetIdentifier": "subnet-07f9cf1cf7d20c877",
                "SubnetAvailabilityZone": {
                    "Name": "us-east-2c"
                },
                "SubnetStatus": "Active"
            },
            {
                "SubnetIdentifier": "subnet-0af43d4d40777eaa9",
                "SubnetAvailabilityZone": {
                    "Name": "us-east-2b"
                },
                "SubnetStatus": "Active"
            }
        ],
        "DBSubnetGroupArn": "arn:aws:rds:us-east-2:573992724610:subgrp:docdb-practica-subnets",
        "SupportedNetworkTypes": [
            "IPV4"
        ]
    }
}
```



```
◂ 9s ◎ aws docdb describe-db-subnet-groups \                    (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:00
             --db-subnet-group-name docdb-practica-subnets \
             --region us-east-2 \
             --query 'DBSubnetGroups[0].{Name:DBSubnetGroupName,Status:SubnetGroupStatus,Subnets:Subnets[].{AZ:SubnetAvai
labilityZone.Name,ID:SubnetIdentifier}}' \
             --output json
{
    "Name": "docdb-practica-subnets",
    "Status": "Complete",
    "Subnets": [
        {
            "AZ": "us-east-2a",
            "ID": "subnet-096a4967a3ea16daa"
        },
        {
            "AZ": "us-east-2c",
            "ID": "subnet-07f9cf1cf7d20c877"
        },
        {
            "AZ": "us-east-2b",
            "ID": "subnet-0af43d4d40777eaa9"
        }
    ]
}
```

Generación de clave aleatoria y que se guarde en secrets manager.



```
◂ 1s ◎ set DB_PASSWORD (openssl rand -base64 24 | tr -d '\n')   (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:04

◂ 0s ◎ aws secretsmanager describe-secret \                     (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:04
             --secret-id docdb-practica-credentials \
             --region us-east-2

aws: [ERROR]: An error occurred (ResourceNotFoundException) when calling the DescribeSecret operation: Secrets Manager ca
n't find the specified secret.

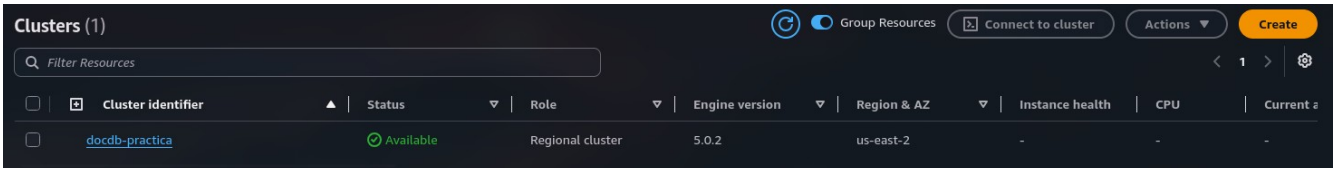
◂ 1s ○ aws secretsmanager create-secret \                       (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:04
             --name docdb-practica-credentials \
             --description "Credenciales para la practica de DocumentDB" \
             --secret-string "{\"username\":\"docdbadmin\",\"password\":\"$DB_PASSWORD\"}" \
             --region us-east-2
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:docdb-practica-credentials-ZWjFiB",
    "Name": "docdb-practica-credentials",
    "VersionId": "e25ec16c-22e8-44d8-af75-f4b5b7ecf792"
}

◂ 1s ◎ |                                                        (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:04
```

Creación del cluster serverless entre 0.5 y 1 DCU. Almacenamiento estándar

```
◄ 1s ◎ aws docdb create-db-cluster \                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:06
            --db-cluster-identifier docdb-practica \
            --engine docdb \
            --engine-version 5.0.2 \
            --master-username docdbadmin \
            --master-user-password "$DB_PASSWORD" \
            --serverless-v2-scaling-configuration MinCapacity=0.5,MaxCapacity=1 \
            --db-subnet-group-name docdb-practica-subnets \
            --vpc-security-group-ids sg-092450742548e6149 \
            --port 27017 \
            --backup-retention-period 1 \
            --storage-encrypted \
            --no-deletion-protection \
            --region us-east-2
{
    "DBCluster": {
        "AvailabilityZones": [
            "us-east-2b",
            "us-east-2c",
            "us-east-2a"
        ],
        "BackupRetentionPeriod": 1,
        "DBClusterIdentifier": "docdb-practica",
        "DBClusterParameterGroup": "default.docdb5.0",
        "DBSubnetGroup": "docdb-practica-subnets",
        "Status": "creating",
        "Endpoint": "docdb-practica.cluster-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "ReaderEndpoint": "docdb-practica.cluster-ro-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "MultiAZ": false,
```

```
    "DBCluster": {
        "AvailabilityZones": [
            "us-east-2b",
            "us-east-2c",
            "us-east-2a"
        ],
        "BackupRetentionPeriod": 1,
        "DBClusterIdentifier": "docdb-practica",
        "DBClusterParameterGroup": "default.docdb5.0",
        "DBSubnetGroup": "docdb-practica-subnets",
        "Status": "creating",
        "Endpoint": "docdb-practica.cluster-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "ReaderEndpoint": "docdb-practica.cluster-ro-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "MultiAZ": false,
        "Engine": "docdb",
        "EngineVersion": "5.0.2",
        "Port": 27017,
        "MasterUsername": "docdbadmin",
        "PreferredBackupWindow": "06:00-06:30",
        "PreferredMaintenanceWindow": "fri:10:12-fri:10:42",
        "ReadReplicaIdentifiers": [],
        "DBClusterMembers": [],
        "VpcSecurityGroups": [
            {
                "VpcSecurityGroupId": "sg-092450742548e6149",
                "Status": "active"
            }
        ],
◄ 11s ◎                                                 (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:07
```

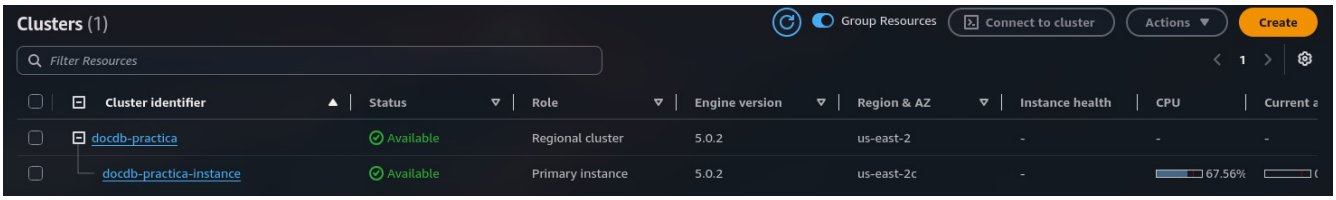


Instancia para poder conectarse a la base de datos

```
◄ 1s ⊙ aws docdb create-db-instance \                    (aws) □ TallerAWS/Punto3 △|●◌◦| conda ○ aws 21:10
            --db-instance-identifier docdb-practica-instance \
            --db-instance-class db.serverless \
            --engine docdb \
            --db-cluster-identifier docdb-practica \
            --region us-east-2
{
    "DBInstance": {
        "DBInstanceIdentifier": "docdb-practica-instance",
        "DBInstanceClass": "db.serverless",
        "Engine": "docdb",
        "DBInstanceStatus": "creating",
        "PreferredBackupWindow": "06:00-06:30",
        "BackupRetentionPeriod": 1,
        "VpcSecurityGroups": [
            {
                "VpcSecurityGroupId": "sg-092450742548e6149",
                "Status": "active"
            }
        ],
        "DBSubnetGroup": {
            "DBSubnetGroupName": "docdb-practica-subnets",
            "DBSubnetGroupDescription": "Subredes para la practica de Amazon DocumentDB",
            "VpcId": "vpc-0f97d7e96864377f2",
            "SubnetGroupStatus": "Complete",
            "Subnets": [
```

```
        "DBSubnetGroup": {
            "DBSubnetGroupName": "docdb-practica-subnets",
            "DBSubnetGroupDescription": "Subredes para la practica de Amazon DocumentDB",
            "VpcId": "vpc-0f97d7e96864377f2",
            "SubnetGroupStatus": "Complete",
            "Subnets": [
                {
                    "SubnetIdentifier": "subnet-096a4967a3ea16daa",
                    "SubnetAvailabilityZone": {
                        "Name": "us-east-2a"
                    },
                    "SubnetStatus": "Active"
                },
                {
                    "SubnetIdentifier": "subnet-07f9cf1cf7d20c877",

◄ 6s ⊙ |                                                 (aws) □ TallerAWS/Punto3 △|●◌◦| conda ○ aws 21:10
```



Creación de la clave SSH para conectarse a la instancia de EC2

```
◄ 1s ○ mkdir -p ~/.ssh                                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:22

      aws ec2 create-key-pair \
            --key-name docdb-practica-key \
            --key-type ed25519 \
            --key-format pem \
            --region us-east-2 \
            --query 'KeyMaterial' \
            --output text > ~/.ssh/docdb-practica-key.pem

      chmod 400 ~/.ssh/docdb-practica-key.pem

◄ 1s ◎ ls -l ~/.ssh/docdb-practica-key.pem                (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:22
.r-------- 388 dduquejh 14 Oct 21:22 /home/dduquejh/.ssh/docdb-practica-key.pem

◄ 0s ◎                                                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:22
```

Validación de la imagen de Amazon Linux

```
◄ 23s ◎ set AMI_ID (aws ssm get-parameter \               (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:25
                --name /aws/service/ami-amazon-linux-latest/al2023-ami-kernel-default-x86_64 \
                --region us-east-2 \
                --query 'Parameter.Value' \
                --output text)

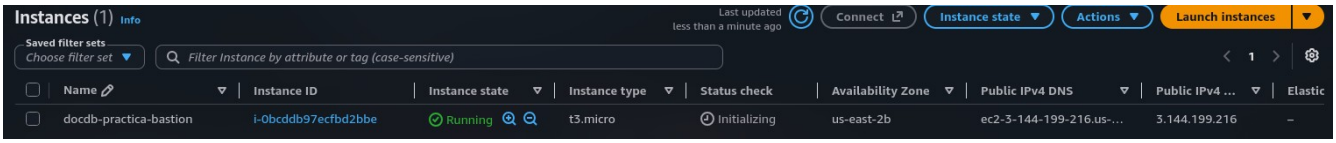
       echo $AMI_ID
ami-0e94515e56ea0c11b

◄ 1s ◎                                                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:25
```

Creación de la instancia

```
◄ 1s ◎ aws ec2 run-instances \                            (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:26
            --image-id $AMI_ID \
            --instance-type t3.micro \
            --key-name docdb-practica-key \
            --subnet-id subnet-0af43d4d40777eaa9 \
            --security-group-ids sg-0d2cd2df16b28021f \
            --associate-public-ip-address \
            --tag-specifications 'ResourceType=instance,Tags=[{Key=Name,Value=docdb-practica-bastion}]' \
            --region us-east-2 \
            --query 'Instances[0].{ID:InstanceId,State:State.Name,PublicIP:PublicIpAddress}' \
            --output table
-------------------------------------------------
|                RunInstances                   |
+----------------------+------------+----------+
|          ID          | PublicIP   |  State   |
+----------------------+------------+----------+
|  i-0bcddb97ecfbd2bbe |  None      |  pending |
+----------------------+------------+----------+

◄ 2s ◎                                                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| conda ○ aws 21:26
```



```
➜ 2s ⊙ aws ec2 describe-instances \                                    (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:27
            --instance-ids i-0bcddb97ecfbd2bbe \
            --region us-east-2 \
            --query 'Reservations[0].Instances[0].{Estado:State.Name,IP_Publica:PublicIpAddress,IP_Privada:PrivateIpAddr
ess,Subred:SubnetId,Clave:KeyName}' \
            --output table
-------------------------------------------------------------------------------------------
|                                   DescribeInstances                                     |
+-------------------+----------+---------------+---------------+---------------------------+
|       Clave       | Estado   |  IP_Privada   |  IP_Publica   |          Subred           |
+-------------------+----------+---------------+---------------+---------------------------+
|  docdb-practica-key|  running |  172.31.27.216 |  3.144.199.216 |  subnet-0af43d4d40777eaa9  |
+-------------------+----------+---------------+---------------+---------------------------+

➜ 1s ⊙                                                                 (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:27
```

Conexión por SSH al ec2

```
➜ 0s ⊙ ssh -i ~/.ssh/docdb-practica-key.pem ec2-user@3.144.199.216     (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:28
The authenticity of host '3.144.199.216 (3.144.199.216)' can't be established.
ED25519 key fingerprint is: SHA256:FuS97PvPc7K8flA2tYNmdLdPXVpDHsY3t6Ot9rifA2I
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
Warning: Permanently added '3.144.199.216' (ED25519) to the list of known hosts.
** WARNING: connection is not using a post-quantum key exchange algorithm.
** This session may be vulnerable to "store now, decrypt later" attacks.
** The server may need to be upgraded. See https://openssh.com/pq.html
   ,     #_
   ~\_  ####_        Amazon Linux 2023
  ~~  \_#####\
  ~~     \###|
  ~~       \#/ ___   https://aws.amazon.com/linux/amazon-linux-2023
   ~~       V~' '->
    ~~~         /
      ~~._.   _/
         _/ _/
       _/m/'
[ec2-user@ip-172-31-27-216 ~]$
```

Configuración certificado TLS y

```
➜ 1m47s ⊙ mkdir -p ~/.certs/docdb                                      (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:30

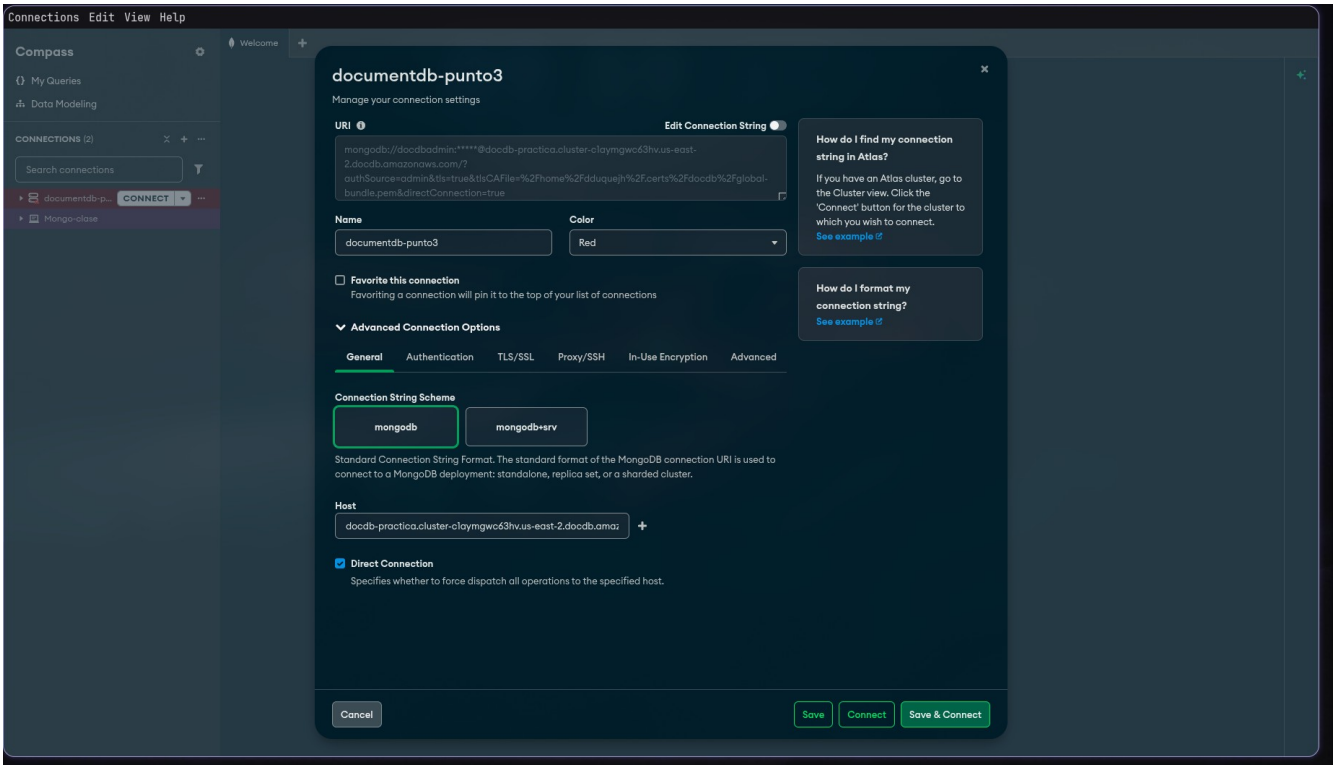
          curl -o ~/.certs/docdb/global-bundle.pem \
               https://truststore.pki.rds.amazonaws.com/global/global-bundle.pem
  % Total    % Received % Xferd  Average Speed   Time    Time     Time   Current
                                 Dload  Upload   Total   Spent    Left   Speed
100 170.4k 100 170.4k   0      0 296.4k      0                              0

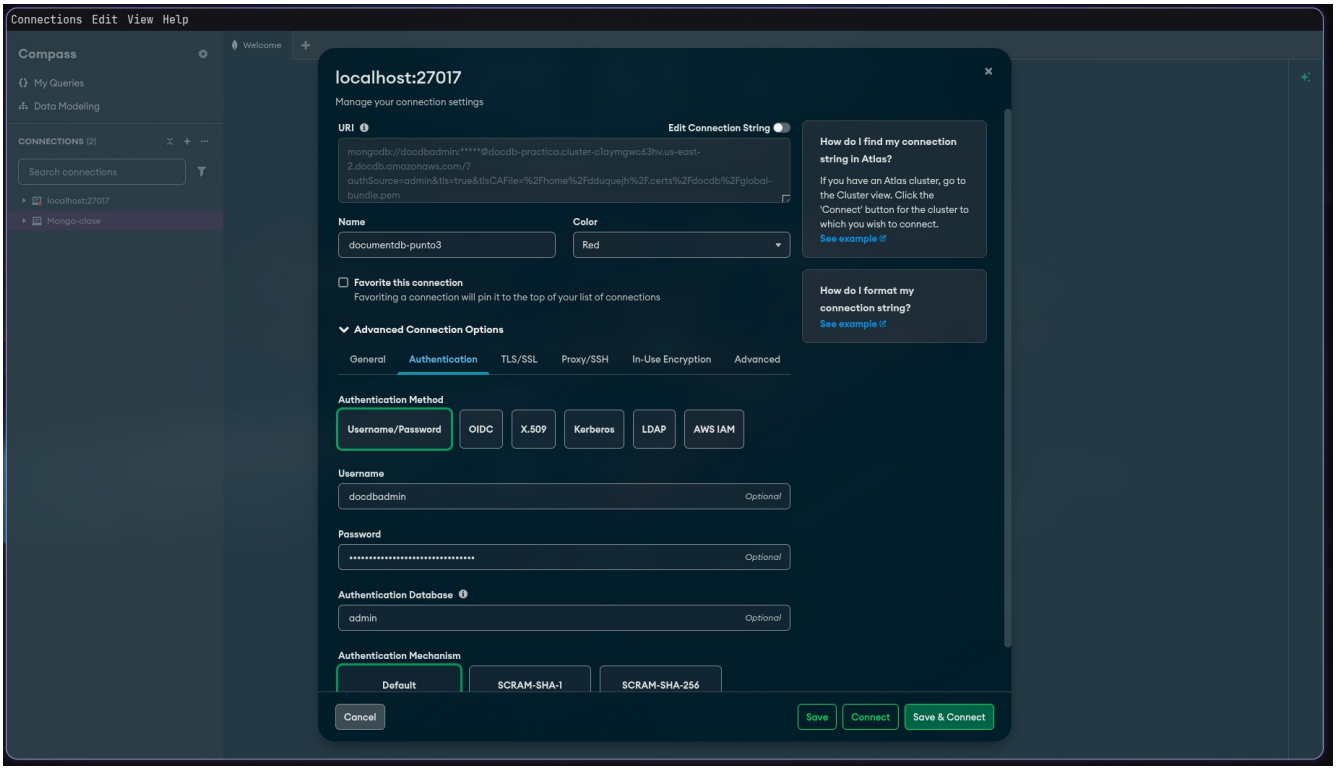
➜ 0s ⊙ ls -lh ~/.certs/docdb/global-bundle.pem                         (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:30
Permissions Size User     Date Modified Name
.rw-r--r--  175k dduquejh 14 Oct 21:30  🔑 /home/dduquejh/.certs/docdb/global-bundle.pem

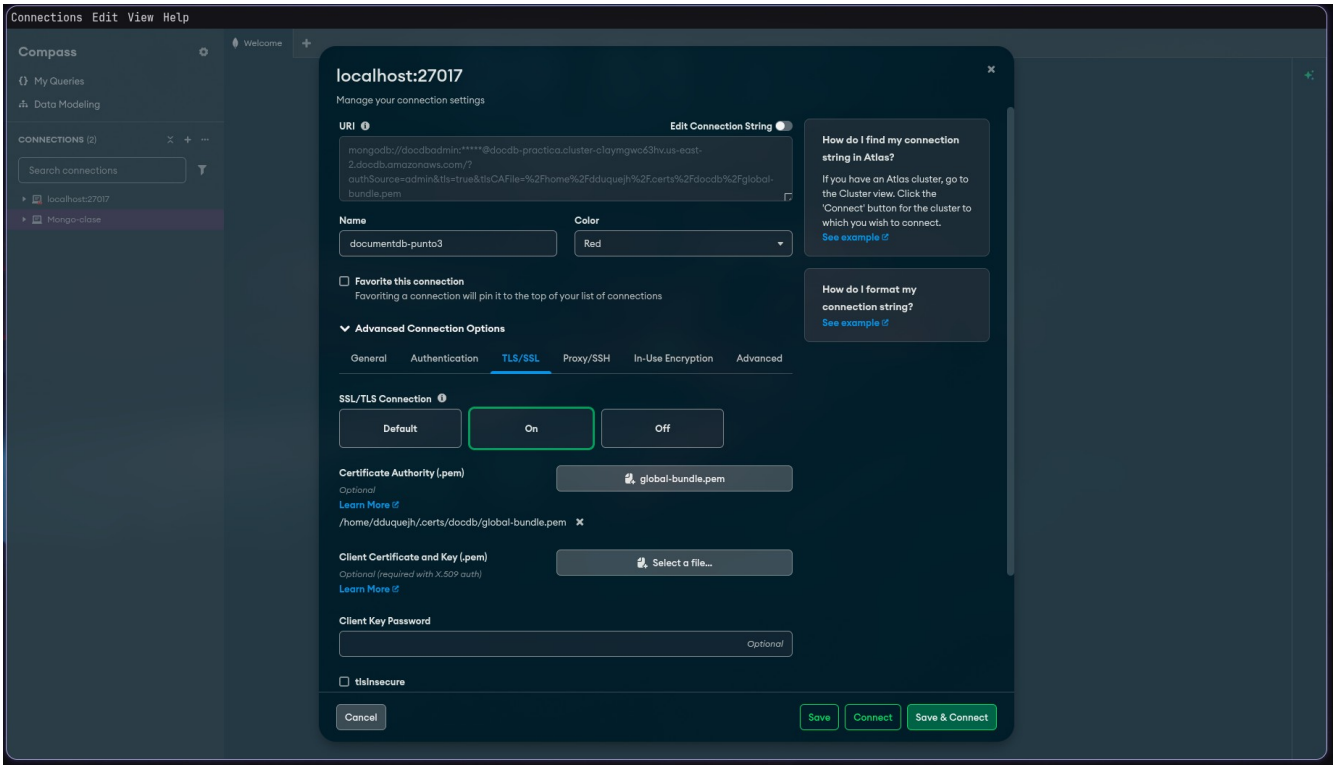
➜ 0s ⊙ ssh -i ~/.ssh/docdb-practica-key.pem \                          (aws) □ TallerAWS/Punto3 △|●◦○◦| conda ○ aws 21:30
            -N \
            -L 27017:docdb-practica.cluster-c1aymgwc63hv.us-east-2.docdb.amazonaws.com:27017 \
            ec2-user@3.144.199.216
** WARNING: connection is not using a post-quantum key exchange algorithm.
** This session may be vulnerable to "store now, decrypt later" attacks.
** The server may need to be upgraded. See https://openssh.com/pq.html
```

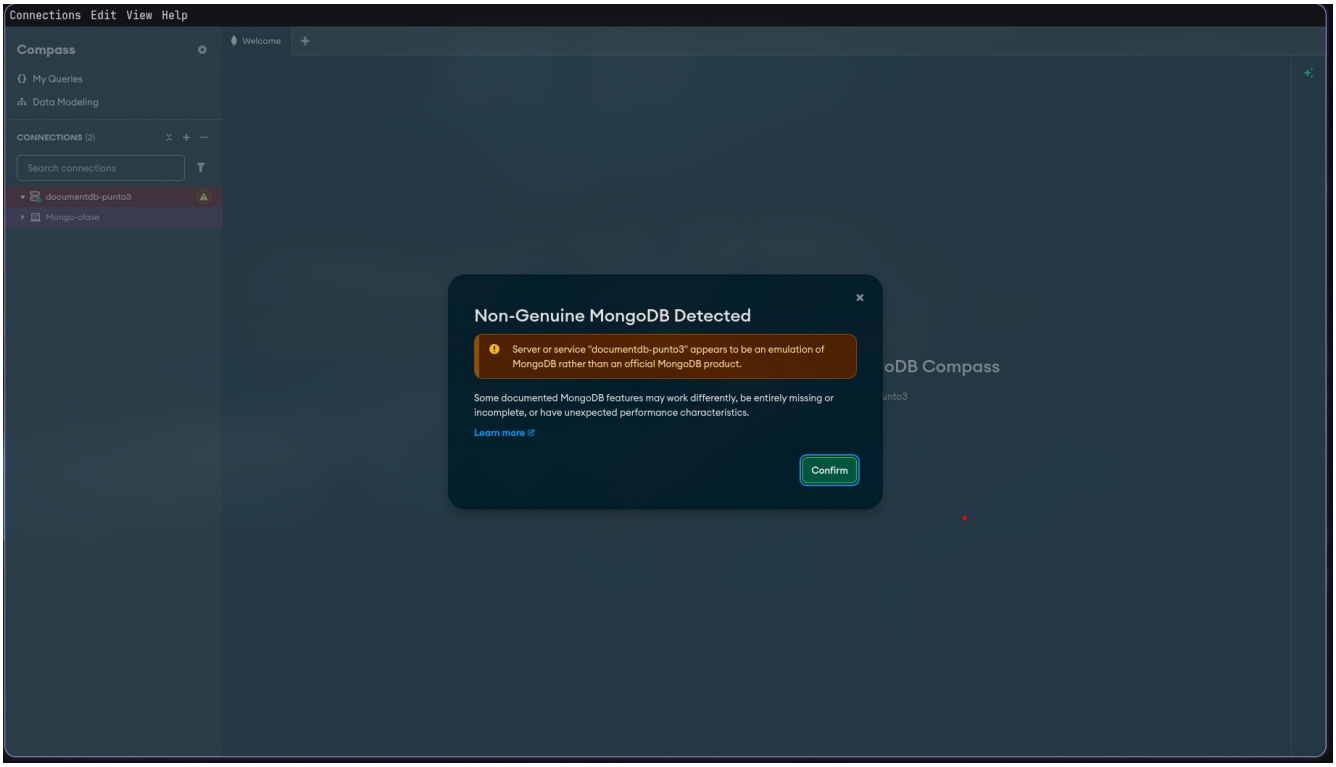
Conexión con MongoDB Compass

```
 GNU nano 9.1                                  /etc/hosts                                  Modified
# Static table lookup for hostnames.
# See hosts(5) for details.
127.0.0.1       localhost
::1             localhost
127.0.0.1       dduquejh.localdomain dduquejh
127.0.0.1 docdb-practica.cluster-c1aymgwc63hv.us-east-2.docdb.amazonaws.com
```




Connections Edit View Help
Compass
My Queries
Data Modeling
CONNECTIONS (2)
Search connections
localhost:27017
Mongo-clase
Welcome
localhost:27017
Manage your connection settings
URI
Edit Connection String
mongodb://docdbadmin:*****@docdb-practica.cluster-claymgwc63hv.us-east-2.docdb.amazonaws.com/?authSource=admin&tls=true&tlsCAFile=%2Fhome%2Fdduquejh%2F.certs%2Fdocdb%2Fglobal-bundle.pem
Name
documentdb-punto3
Color
Red
Favorite this connection
Favoriting a connection will pin it to the top of your list of connections
Advanced Connection Options
General
Authentication
TLS/SSL
Proxy/SSH
In-Use Encryption
Advanced
Authentication Method
Username/Password
OIDC
X.509
Kerberos
LDAP
AWS IAM
Username
docdbadmin
Optional
Password
Optional
Authentication Database
admin
Optional
Authentication Mechanism
Default
SCRAM-SHA-1
SCRAM-SHA-256
How do I find my connection string in Atlas?
If you have an Atlas cluster, go to the Cluster view. Click the 'Connect' button for the cluster to which you wish to connect.
See example
How do I format my connection string?
See example
Cancel
Save
Connect
Save & Connect


Connections Edit View Help
Compass
My Queries
Data Modeling
CONNECTIONS (2)
Search connections
localhost:27017
Mongo-clase
Welcome
localhost:27017
Manage your connection settings
URI
Edit Connection String
mongodb://docdbadmin:*****@docdb-practica.cluster-claymgwc63hv.us-east-2.docdb.amazonaws.com/?authSource=admin&tls=true&tlsCAFile=%2Fhome%2Fdduquejh%2F.certs%2Fdocdb%2Fglobal-bundle.pem
Name
documentdb-punto3
Color
Red
Favorite this connection
Favoriting a connection will pin it to the top of your list of connections
Advanced Connection Options
General
Authentication
TLS/SSL
Proxy/SSH
In-Use Encryption
Advanced
SSL/TLS Connection
Default
On
Off
Certificate Authority (.pem)
Optional
Learn More
global-bundle.pem
/home/dduquejh/.certs/docdb/global-bundle.pem
Client Certificate and Key (.pem)
Optional (required with X.509 auth)
Learn More
Select a file...
Client Key Password
Optional
tlsInsecure
How do I find my connection string in Atlas?
If you have an Atlas cluster, go to the Cluster view. Click the 'Connect' button for the cluster to which you wish to connect.
See example
How do I format my connection string?
See example
Cancel
Save
Connect
Save & Connect

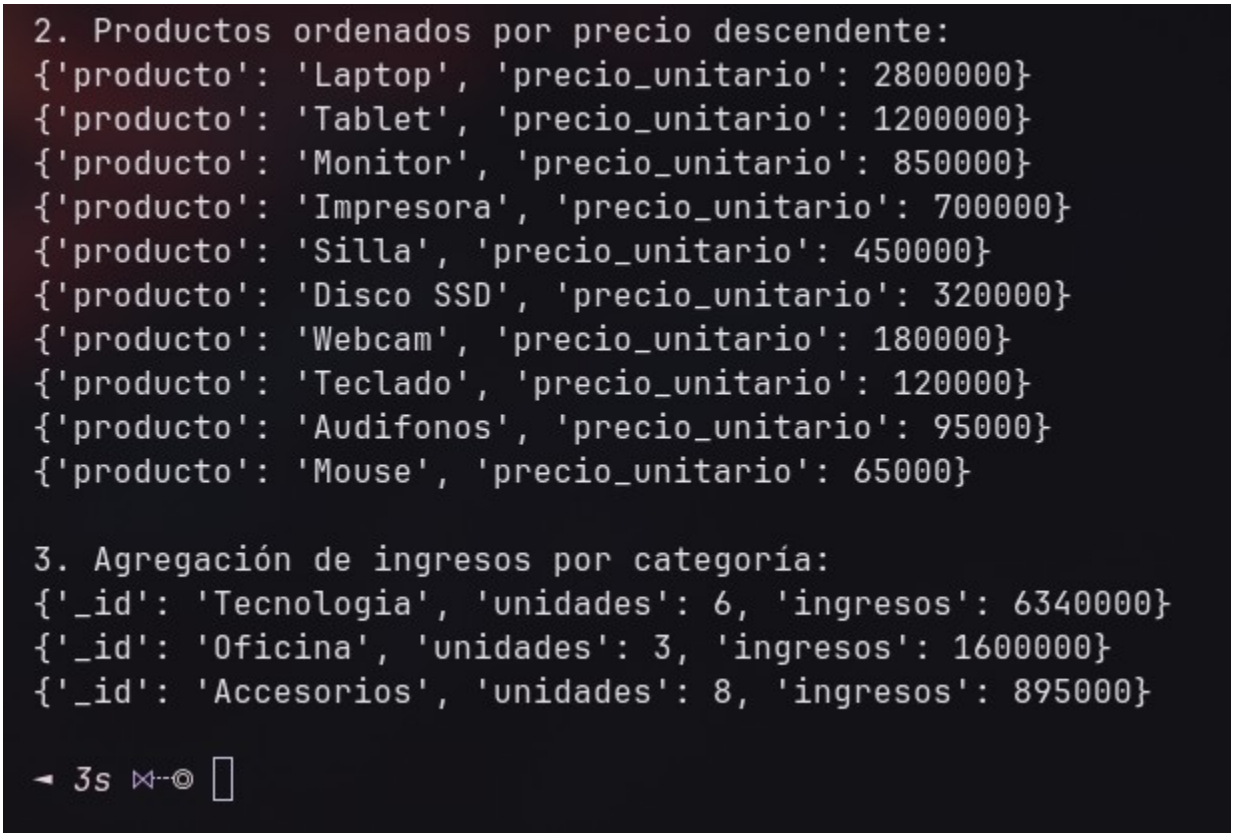


Conexción con Python y cargar documentos

```
◄ 1s ⋈┈◎ python documentdb_practica.py
/home/dduquejh/Documents/universidad/ingenieria-datos/TallerAWS/Punto3/documentdb_practica.py:47: UserWarning: You appear to be connected to a DocumentDB cluster. For more information regarding feature compatibility and support please visit https://www.mongodb.com/supportability/documentdb
  client = MongoClient(
Conexión a DocumentDB: OK
Documentos insertados: 10

1. Ventas de la categoria Tecnologia:
{'lote': 'taller-2026', 'id_venta': 1, 'producto': 'Laptop', 'categoria': 'Tecnologia', 'ciudad': 'Medellin', 'cantidad': 1, 'precio_unitario': 2800000}
{'lote': 'taller-2026', 'id_venta': 6, 'producto': 'Tablet', 'categoria': 'Tecnologia', 'ciudad': 'Envigado', 'cantidad': 1, 'precio_unitario': 1200000}
{'lote': 'taller-2026', 'id_venta': 4, 'producto': 'Monitor', 'categoria': 'Tecnologia', 'ciudad': 'Bogota', 'cantidad': 2, 'precio_unitario': 850000}
{'lote': 'taller-2026', 'id_venta': 10, 'producto': 'Disco SSD', 'categoria': 'Tecnologia', 'ciudad': 'Bogota', 'cantidad': 2, 'precio_unitario': 320000}

2. Productos ordenados por precio descendente:
{'producto': 'Laptop', 'precio_unitario': 2800000}
{'producto': 'Tablet', 'precio_unitario': 1200000}
{'producto': 'Monitor', 'precio_unitario': 850000}
{'producto': 'Impresora', 'precio_unitario': 700000}
{'producto': 'Silla', 'precio_unitario': 450000}
{'producto': 'Disco SSD', 'precio_unitario': 320000}
```

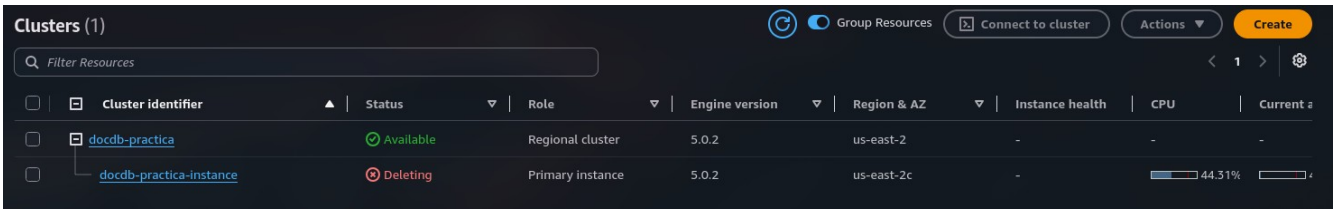


La captura de los datos en Mongo Compass tuve un error y solo puse una ‘v’. Me dí cuenta cuando había eliminado todos los recursos del ejercicio.

Eliminación

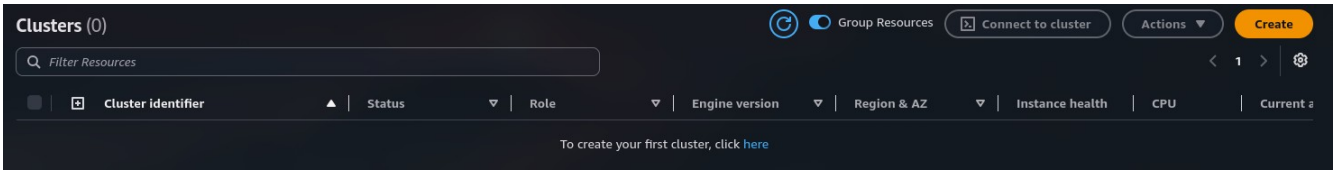
Eliminación de la instancia

```
~ 1s ⋈┈◎ aws docdb delete-db-instance \                (aws) □ TallerAWS/Punto3 △|●◦◌◦| py 🐍 3.12.13 conda ○ aws 22:11
             --db-instance-identifier docdb-practica-instance \
             --region us-east-2
{
    "DBInstance": {
        "DBInstanceIdentifier": "docdb-practica-instance",
        "DBInstanceClass": "db.serverless",
        "Engine": "docdb",
        "DBInstanceStatus": "deleting",
        "Endpoint": {
            "Address": "docdb-practica-instance.c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
            "Port": 27017,
            "HostedZoneId": "Z7L8695A82IZ6"
        },
        "InstanceCreateTime": "2026-10-15T02:15:02.150000+00:00",
        "PreferredBackupWindow": "06:00-06:30",
        "BackupRetentionPeriod": 1,
        "VpcSecurityGroups": [
            {
                "VpcSecurityGroupId": "sg-092450742548e6149",
                "Status": "active"
            }
        ],
        "AvailabilityZone": "us-east-2c",
        "DBSubnetGroup": {
            "DBSubnetGroupName": "docdb-practica-subnets",
            "DBSubnetGroupDescription": "Subredes para la practica de Amazon DocumentDB",
            "VpcId": "vpc-0f97d7e96864377f2",
            "SubnetGroupStatus": "Complete",
```



Eliminación del cluster

```
~ 1s ○ aws docdb delete-db-cluster \                   (aws) □ TallerAWS/Punto3 △|●◦◌◦| py 🐍 3.12.13 conda ○ aws 22:24
             --db-cluster-identifier docdb-practica \
             --skip-final-snapshot \
             --region us-east-2
{
    "DBCluster": {
        "AvailabilityZones": [
            "us-east-2b",
            "us-east-2c",
            "us-east-2a"
        ],
        "BackupRetentionPeriod": 1,
        "DBClusterIdentifier": "docdb-practica",
        "DBClusterParameterGroup": "default.docdb5.0",
        "DBSubnetGroup": "docdb-practica-subnets",
        "Status": "available",
        "EarliestRestorableTime": "2026-10-15T02:07:37.492000+00:00",
        "Endpoint": "docdb-practica.cluster-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "ReaderEndpoint": "docdb-practica.cluster-ro-c1aymgwc63hv.us-east-2.docdb.amazonaws.com",
        "MultiAZ": false,
        "Engine": "docdb",
        "EngineVersion": "5.0.2",
        "LatestRestorableTime": "2026-10-15T03:15:40.782000+00:00",
        "Port": 27017,
        "MasterUsername": "docdbadmin",
        "PreferredBackupWindow": "06:00-06:30",
        "PreferredMaintenanceWindow": "fri:10:12-fri:10:42",
        "ReadReplicaIdentifiers": [],
        "DBClusterMembers": [],
```



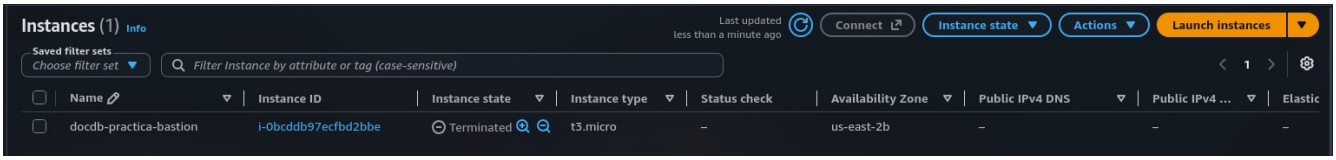
Eliminación del EC2

```
➜ 1s ⎈ aws ec2 terminate-instances \                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:20
            --instance-ids i-0bcddb97ecfbd2bbe \
            --region us-east-2
{
    "TerminatingInstances": [
        {
            "InstanceId": "i-0bcddb97ecfbd2bbe",
            "CurrentState": {
                "Code": 32,
                "Name": "shutting-down"
            },
            "PreviousState": {
                "Code": 16,
                "Name": "running"
            }
        }
    ]
}

➜ 1s ⎈                                                  (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:20
```

```
➜ 16s ⎈ aws ec2 describe-instances \                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:20
            --instance-ids i-0bcddb97ecfbd2bbe \
            --region us-east-2 \
            --query 'Reservations[].Instances[].[InstanceId,State.Name]' \
            --output table
-------------------------------------
|          DescribeInstances          |
+---------------------+--------------+
|  i-0bcddb97ecfbd2bbe |  terminated  |
+---------------------+--------------+

➜ 1s ⎈                                                  (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:21
```



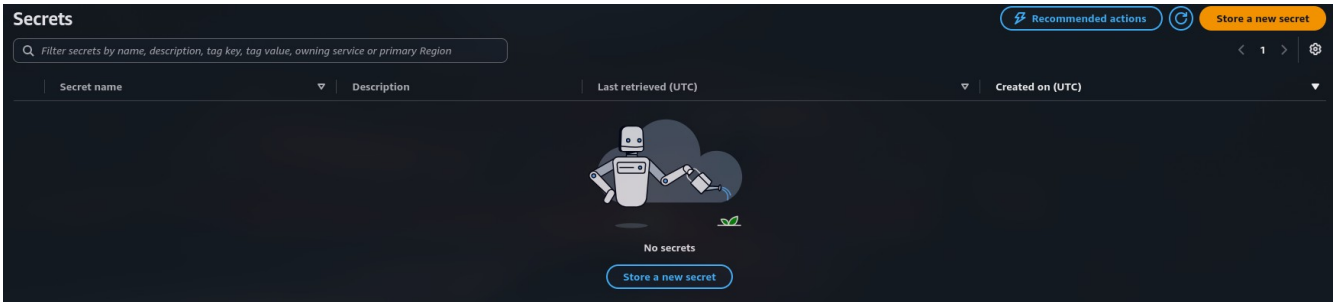
Secreto

```
~ 1s ◎ aws secretsmanager delete-secret \                    (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:22
            --secret-id docdb-practica-credentials \
            --force-delete-without-recovery \
            --region us-east-2
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:docdb-practica-credentials-ZWjFiB",
    "Name": "docdb-practica-credentials",
    "DeletionDate": "2026-10-14T22:22:06.680000-05:00"
}

~ 1s ◎ aws secretsmanager describe-secret \                  (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:22
            --secret-id docdb-practica-credentials \
            --region us-east-2

aws: [ERROR]: An error occurred (ResourceNotFoundException) when calling the DescribeSecret operation: Secrets Manager ca
n't find the specified secret.

~ 1s ○                                                       (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:22
```

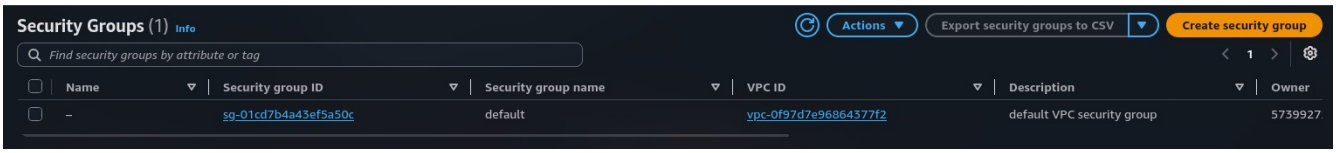


Grupos de seguridad

```
~ 1s ○ aws ec2 delete-security-group \                        (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:28
            --group-id sg-092450742548e6149 \
            --region us-east-2
{
    "Return": true,
    "GroupId": "sg-092450742548e6149"
}

~ 1s ◎ aws ec2 delete-security-group \                        (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:28
            --group-id sg-0d2cd2df16b28021f \
            --region us-east-2
{
    "Return": true,
    "GroupId": "sg-0d2cd2df16b28021f"
}

~ 1s ◎                                                       (aws) □ TallerAWS/Punto3 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:28
```



Punto 4: Amazon Neptune

Característica	Amazon Neptune	Neo4j
Modelos de datos	Soporta grafo de propiedades y modelo semántico RDF	Especializado exclusivamente en grafo de propiedades etiquetadas. Optimizado para relaciones complejas
Lenguajes de consulta	Gremlin (Apache TinkerPop), openCypher y SPARQL	Cypher
Herramientas de consulta/IDE	Neptune Notebooks basados en Jupyter para desarrollo y visualización de consultas paso a paso	Neo4j y Neo4j Bloom, entornos virtuales nativos muy potentes para escribir código y explorar datos
Visualización e Integración	Depende de soluciones de terceros o integraciones como librerías open-source en Python	Incluye herramientas visuales nativas como Bloom. Diseñada para analistas de negocio sin conocimientos de código
Analítica avanzada y ML	Neptune Analytics (motor en memoria para consultas rápidas) Neptune ML (integración directa con AWS SageMaker-ML)	Graph Data Science (GDS) suite integrada con algoritmos preinstalados para analítica profunda y ML

Para una configuración de bajo costo es necesario evaluar el tráfico que se va a tener y en base a eso hacer la elección de si es más conveniente economicamente la opción serverless o provisionada.

- **Serverless:** Cobra por NCU-hora con un costo de **$0.1608 USD/hora.** Si se tiene poco flujo con picos de tráfico esporádicos serverless puede ser más económico. Al configurar el mínimo en 1.0 NCU, durante las horas muertas se consumirá el mínimo de dinero posible. Cuándo se tiene mucho flujo puede subir la cantidad de NCU lo que aumenta el costo.
- **Provisionada:** Si se tiene flujo continuo durante el día aunque sea bajo es más económico tener una instancia. Por ejemplo, una instancia db.t3.medium cuesta **$0.098 USD/hora** p db.t4g.medium **$0.093 USD/hora,** que es considerablemente más económico que la opción serverless para muchos datos o para consultas continuas.

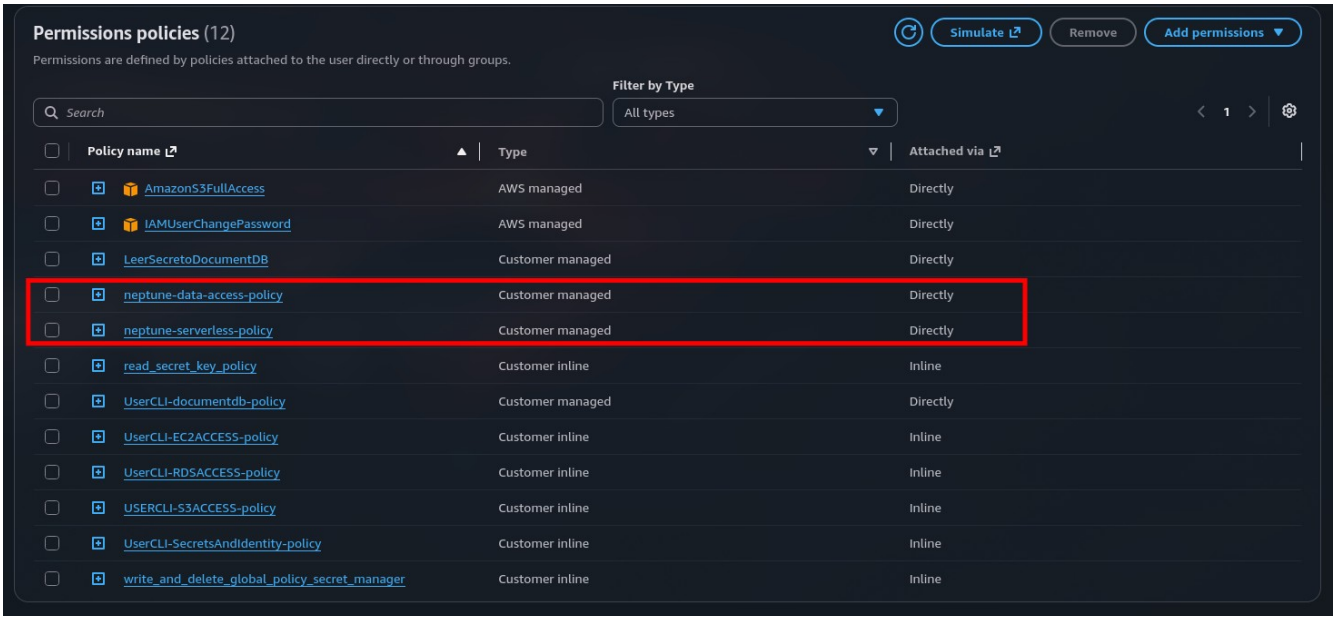
Una opción para consultar de forma local es por medio de un punto de acceso público de Neptune, donde el clúster expone una URL DNS directa a internet. Es protegida mediante firewalls y políticas IAM. Muy usado para desarrollo rápido, pruebas, automatizaciones locales y entornos ágiles. Además, no añade costos fijos extras.

La otra opción es usar un túnel SSH mediante EC2 (Bastion Host). Para esto es necesario aprovisionar y gestionar una instancia EC2 intermedia en la VPC. Cuenta con mayor seguridad que la opción de punto

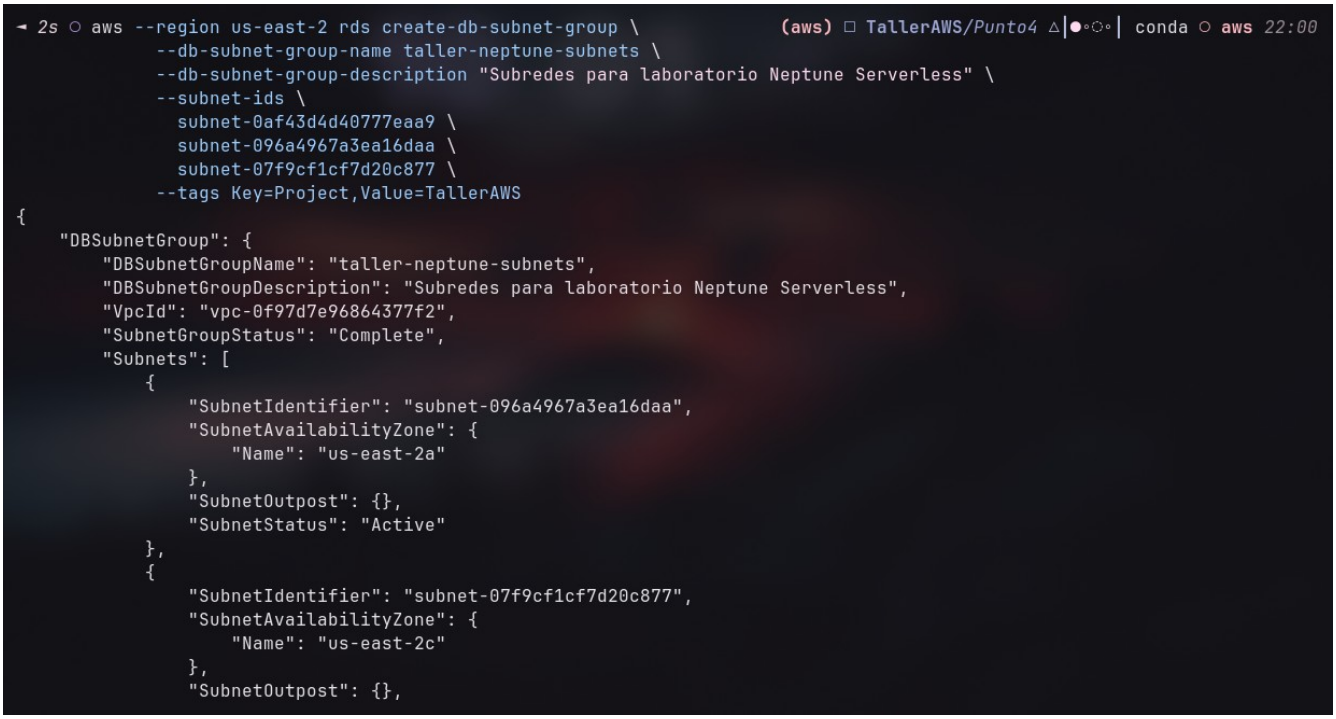
de acceso ya que la base de datos permanece en subnets privadas y ocultas. Opción usada en producción estricta, entornos empresariales corporativos o versiones antiguas de Neptune. Se agrega un costo adicional de las horas de cómputo de la instancia EC2 y su almacenamiento.

Despliegue

Se agregan los permisos al usuario de consola



Crear grupo de subredes de Neptune



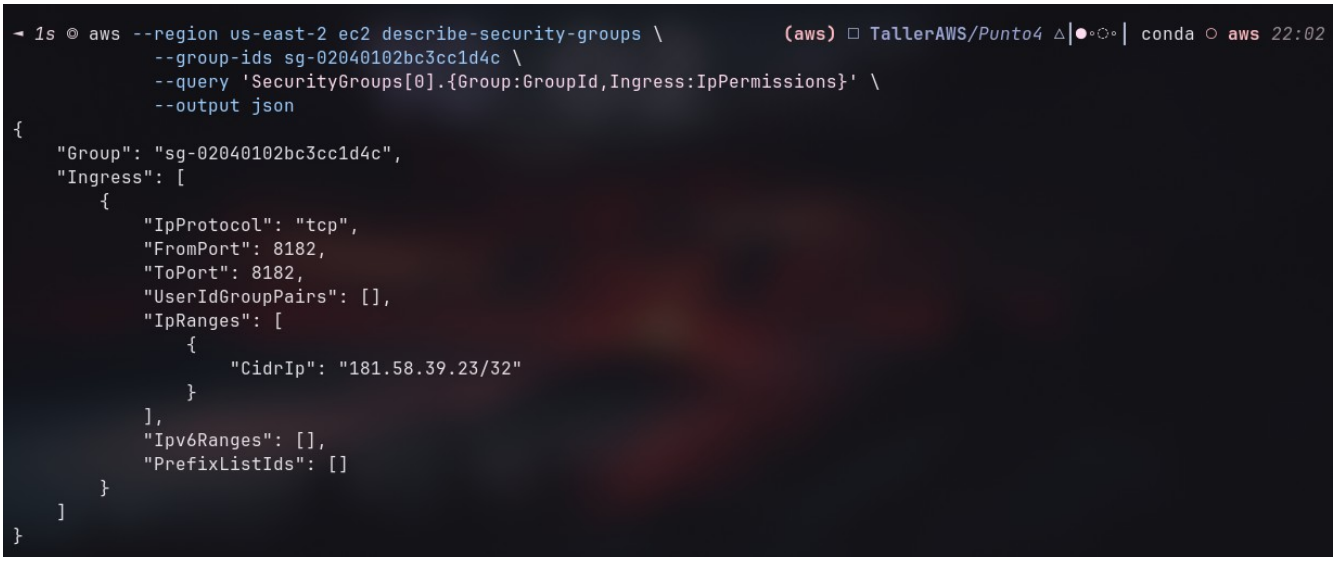
```
➜ 31s ◎ aws --region us-east-2 rds describe-db-subnet-groups \        (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:01
    --db-subnet-group-name taller-neptune-subnets \
    --query 'DBSubnetGroups[0].{Name:DBSubnetGroupName,Status:SubnetGroupStatus,Subnets:Subnets[].{Subnet:Subne
tIdentifier,AZ:SubnetAvailabilityZone.Name}}' \
    --output table
-----------------------------------------------
|           DescribeDBSubnetGroups            |
+----------------------------+----------------+
|            Name            |    Status      |
+----------------------------+----------------+
|  taller-neptune-subnets    |  Complete      |
+----------------------------+----------------+
||                 Subnets                   ||
|+-------------+---------------------------+|
||     AZ      |          Subnet           ||
|+-------------+---------------------------+|
||  us-east-2a |  subnet-096a4967a3ea16daa  ||
||  us-east-2c |  subnet-07f9cf1cf7d20c877  ||
||  us-east-2b |  subnet-0af43d4d40777eaa9  ||
|+-------------+---------------------------+|
```

Creación del grupo de seguridad

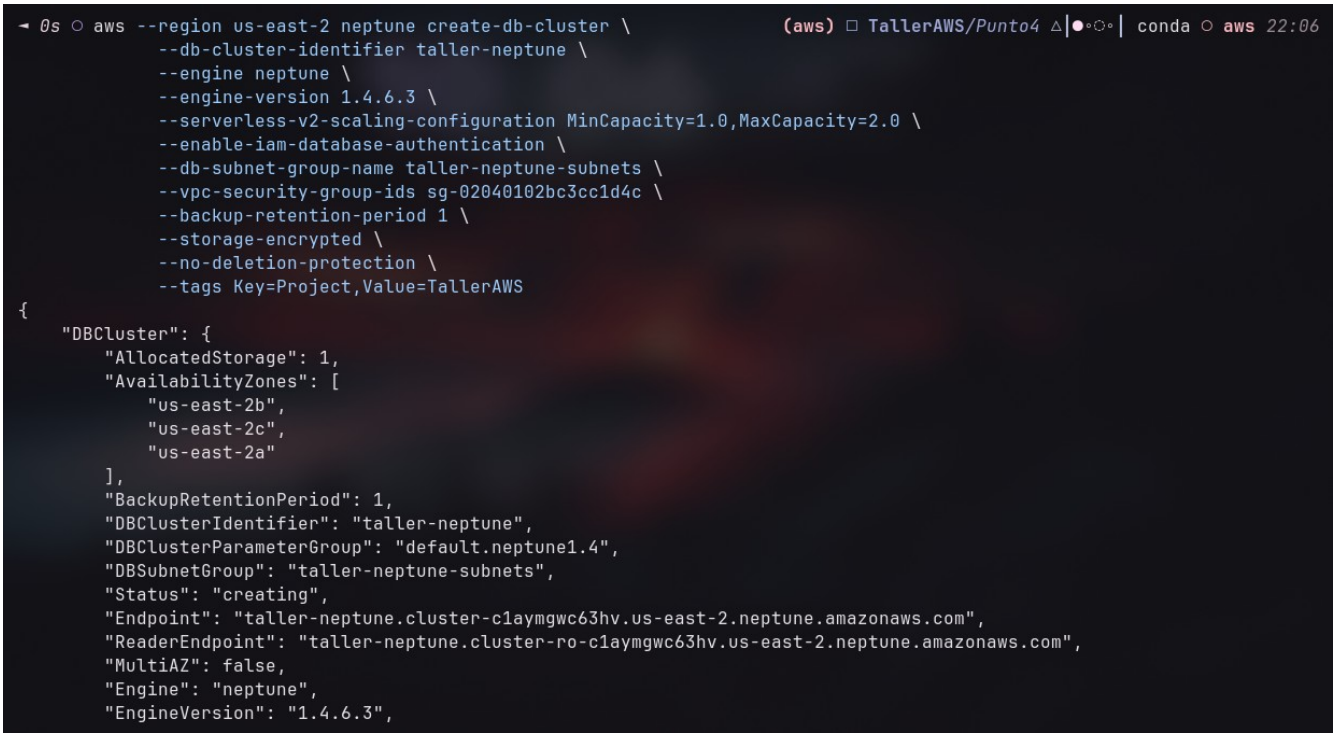
```
➜ 1s ◎ aws --region us-east-2 ec2 create-security-group \            (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:01
    --group-name taller-neptune-sg \
    --description "Acceso restringido a Neptune para el laboratorio" \
    --vpc-id vpc-0f97d7e96864377f2 \
    --tag-specifications 'ResourceType=security-group,Tags=[{Key=Project,Value=TallerAWS}]'
{
    "GroupId": "sg-02040102bc3cc1d4c",
    "Tags": [
        {
            "Key": "Project",
            "Value": "TallerAWS"
        }
    ],
    "SecurityGroupArn": "arn:aws:ec2:us-east-2:573992724610:security-group/sg-02040102bc3cc1d4c"
}
```

Autorización del puerto 8182

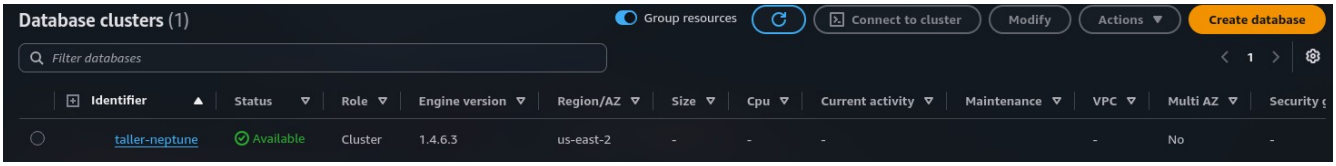
```
➜ 1s ◎ aws --region us-east-2 ec2 authorize-security-group-ingress \   (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:02
    --group-id sg-02040102bc3cc1d4c \
    --protocol tcp \
    --port 8182 \
    --cidr 181.58.39.23/32
{
    "Return": true,
    "SecurityGroupRules": [
        {
            "SecurityGroupRuleId": "sgr-0b213b2a4f002d21a",
            "GroupId": "sg-02040102bc3cc1d4c",
            "GroupOwnerId": "573992724610",
            "IsEgress": false,
            "IpProtocol": "tcp",
            "FromPort": 8182,
            "ToPort": 8182,
            "CidrIpv4": "181.58.39.23/32",
            "SecurityGroupRuleArn": "arn:aws:ec2:us-east-2:573992724610:security-group-rule/sgr-0b213b2a4f002d21a"
        }
    ]
}
```



Creación del clúster limitado a la IP del pc personal y tráfico TCP por el puerto 8182. Capacidad mínima de 1NCU y máxima de 2 NCU



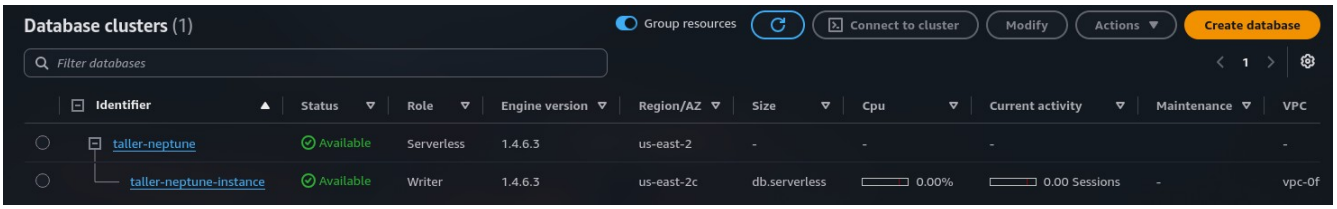
```
◄ 4s ◎ aws --region us-east-2 neptune describe-db-clusters \          (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:07
            --db-cluster-identifier taller-neptune \
            --query 'DBClusters[0].{Cluster:DBClusterIdentifier,Status:Status,Version:EngineVersion,IAM:IAMDatabaseAuthe
nticationEnabled,Serverless:ServerlessV2ScalingConfiguration}' \
            --output json
{
    "Cluster": "taller-neptune",
    "Status": "available",
    "Version": "1.4.6.3",
    "IAM": true,
    "Serverless": {
        "MinCapacity": 1.0,
        "MaxCapacity": 2.0
    }
}
```



Crear la instancia serverless

```
◄ 0s ○ aws --region us-east-2 neptune create-db-instance \          (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:09
            --db-instance-identifier taller-neptune-instance \
            --db-instance-class db.serverless \
            --engine neptune \
            --db-cluster-identifier taller-neptune \
            --publicly-accessible \
            --tags Key=Project,Value=TallerAWS
{
    "DBInstance": {
        "DBInstanceIdentifier": "taller-neptune-instance",
        "DBInstanceClass": "db.serverless",
        "Engine": "neptune",
        "DBInstanceStatus": "creating",
        "MasterUsername": "admin",
        "AllocatedStorage": 1,
        "PreferredBackupWindow": "09:21-09:51",
        "BackupRetentionPeriod": 1,
        "DBSecurityGroups": [],
        "VpcSecurityGroups": [
            {
                "VpcSecurityGroupId": "sg-02040102bc3cc1d4c",
                "Status": "active"
            }
        ],
        "DBParameterGroups": [
            {
                "DBParameterGroupName": "default.neptune1.4",
                "ParameterApplyStatus": "in-sync"
            }
        ],
```

```
◄ 14m38s ◎ aws --region us-east-2 neptune describe-db-instances \      (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:25
                --db-instance-identifier taller-neptune-instance \
                --query 'DBInstances[0].{Instance:DBInstanceIdentifier,Status:DBInstanceStatus,Public:PubliclyAccessible
,Endpoint:Endpoint.Address,Port:Endpoint.Port,Class:DBInstanceClass,Cluster:DBClusterIdentifier}' \
                --output json
{
    "Instance": "taller-neptune-instance",
    "Status": "available",
    "Public": true,
    "Endpoint": "taller-neptune-instance.c1aymgwc63hv.us-east-2.neptune.amazonaws.com",
    "Port": 8182,
    "Class": "db.serverless",
    "Cluster": "taller-neptune"
}
```



Probar la conexión a la instancia

```
◄ 1s ◎ aws --region us-east-2 neptunedata get-engine-status \      (aws) □ TallerAWS/Punto4 △|●◦◌◦| conda ○ aws 22:26
          --endpoint-url https://taller-neptune-instance.c1aymgwc63hv.us-east-2.neptune.amazonaws.com:8182
{
    "status": "healthy",
    "startTime": "Fri Oct 16 03:23:07 UTC 2026",
    "dbEngineVersion": "1.4.6.3.R1",
    "role": "writer",
    "dfeQueryEngine": "viaQueryHint",
    "gremlin": {
        "version": "tinkerpop-3.7.1"
    },
    "sparql": {
        "version": "sparql-1.1"
    },
    "opencypher": {
        "version": "Neptune-9.0.20190305-1.0"
    },
    "labMode": {
        "ObjectIndex": "disabled",
        "TableSpaceAutoExtendSizeInMB": "",
        "ReadWriteConflictDetection": "enabled"
    },
    "features": {
        "SlowQueryLogs": "disabled",
        "InlineServerGeneratedEdgeId": "disabled",
        "ResultCache": {
            "status": "disabled"
        },
        "IAMAuthentication": "enabled",
```

Probar la conexión desde python con test_connection.py

```
◄ 17s ◎ python test_connection.py                    (aws) □ TallerAWS/Punto4 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:30
HTTP: 200
{"requestId":"7d53318c-db92-4ac3-b3de-5b5ddeb3c69c","status":{"message":"","code":200,"attributes":{"@type":"g:Map","@val
ue":[]}},"result":{"data":{"@type":"g:List","@value":[{"@type":"g:Int64","@value":0}]},"meta":{"@type":"g:Map","@value":[
]}}}

◄ 3s ◎                                               (aws) □ TallerAWS/Punto4 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:30
```

Crear el grafo usando python (ejecutando grafo_neptune.py

```
◄ 13s ○ python grafo_neptune.py                      (aws) □ TallerAWS/Punto4 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:41
Conectando con Amazon Neptune...
Endpoint: https://taller-neptune-instance.c1aymgwc63hv.us-east-2.neptune.amazonaws.com:8182

Limpiando el grafo anterior...

Creando vertices...
  Vertice creado: Ana (persona)
  Vertice creado: Luis (persona)
  Vertice creado: Marta (persona)
  Vertice creado: Juan (persona)
  Vertice creado: Bus1 (vehiculo)
  Vertice creado: Bus2 (vehiculo)
  Vertice creado: Van1 (vehiculo)
  Vertice creado: Universidad (lugar)
  Vertice creado: Estacion (lugar)
  Vertice creado: Centro (lugar)

Creando aristas...
  ana -[VIAJA_EN]-> bus1
  luis -[VIAJA_EN]-> bus1
  marta -[VIAJA_EN]-> bus2
  juan -[VIAJA_EN]-> van1
  ana -[DESTINO]-> universidad
  luis -[DESTINO]-> centro
  marta -[DESTINO]-> estacion
  juan -[DESTINO]-> universidad
  bus1 -[CONECTA]-> universidad
  bus1 -[CONECTA]-> estacion
```

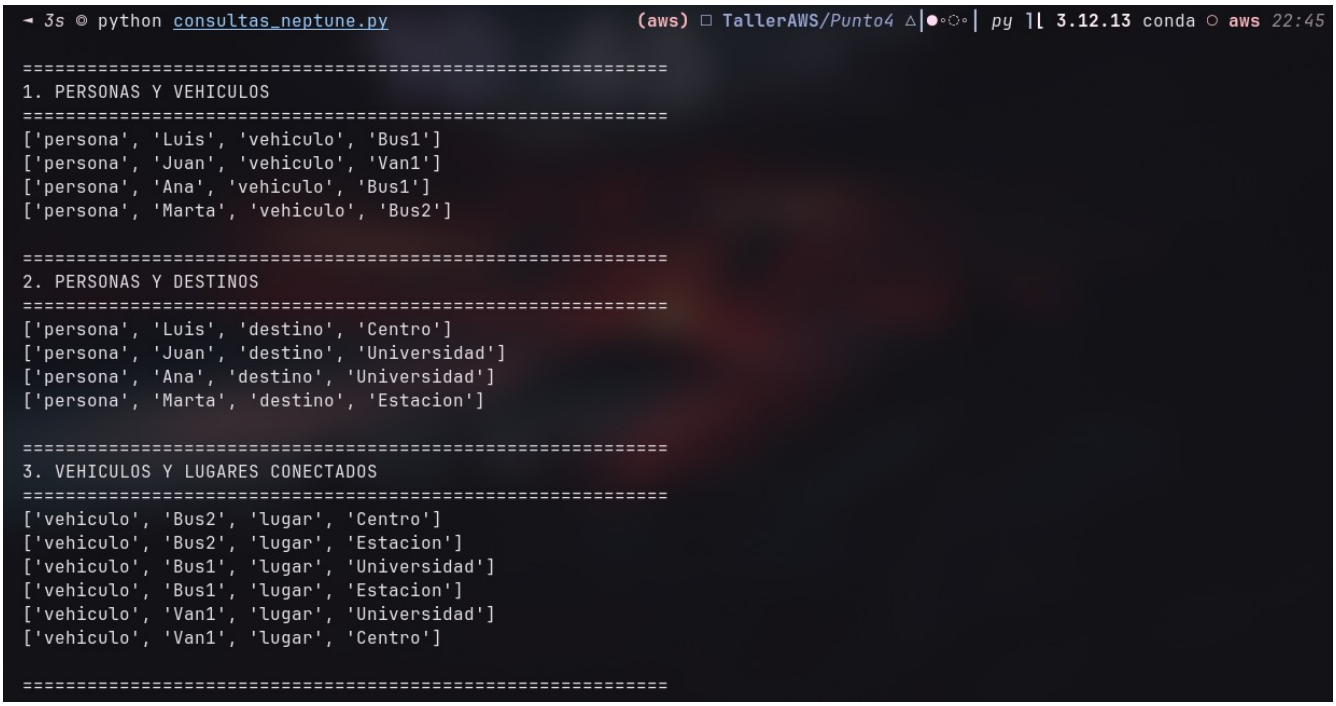
```
Creando aristas...
  ana -[VIAJA_EN]-> bus1
  luis -[VIAJA_EN]-> bus1
  marta -[VIAJA_EN]-> bus2
  juan -[VIAJA_EN]-> van1
  ana -[DESTINO]-> universidad
  luis -[DESTINO]-> centro
  marta -[DESTINO]-> estacion
  juan -[DESTINO]-> universidad
  bus1 -[CONECTA]-> universidad
  bus1 -[CONECTA]-> estacion
  bus2 -[CONECTA]-> estacion
  bus2 -[CONECTA]-> centro
  van1 -[CONECTA]-> universidad
  van1 -[CONECTA]-> centro
  juan -[CONDUCE]-> bus1

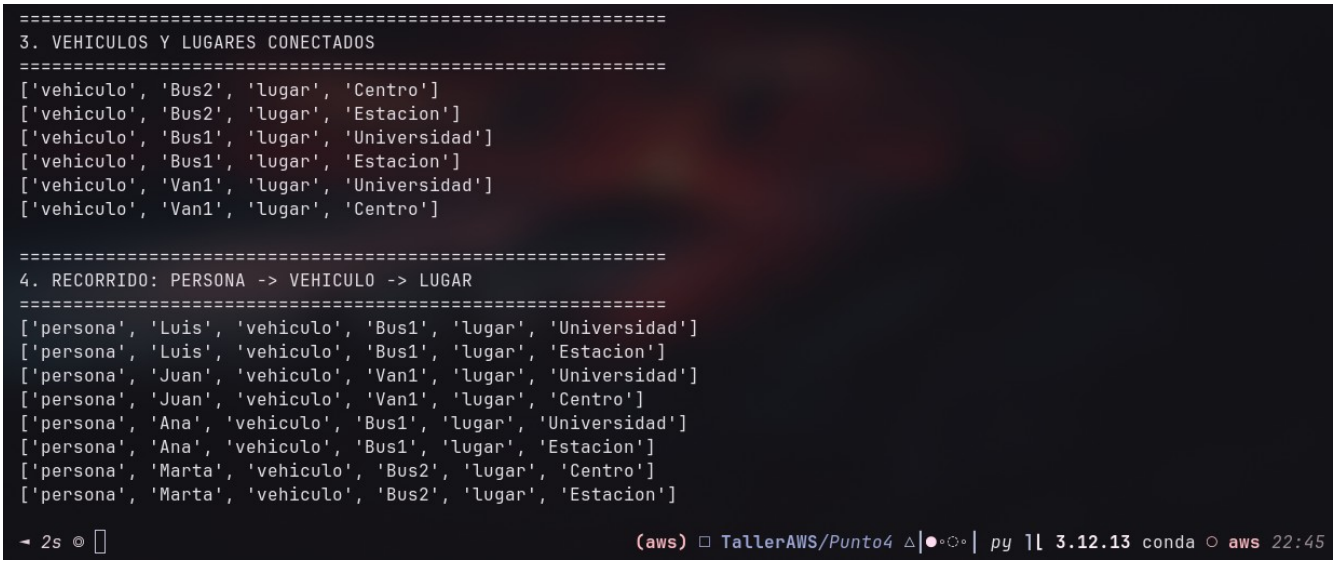
Verificando el grafo...

==============================
RESULTADO DE LA CARGA
==============================
Vertices: 10
Aristas:  15
Grafo creado correctamente.

◄ 12s ◎                                              (aws) □ TallerAWS/Punto4 △|●◦◌◦| py ]l 3.12.13 conda ○ aws 22:41
```

Consultas de recorrido (consultas_neptune.py)

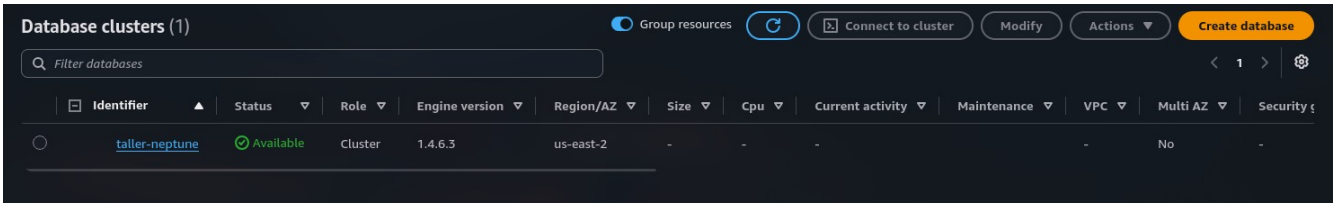




Eliminación

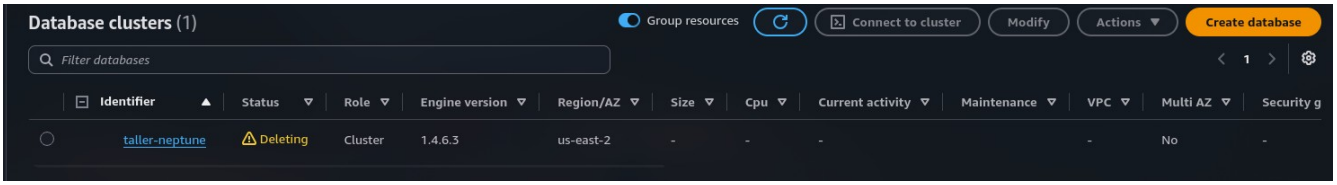
Eliminación de la instancia

```
◄ 1s © aws neptune delete-db-instance \                (aws) □ TallerAWS/Punto4 △|●◦◌◦| py ][ 3.12.13 conda ○ aws 23:04
            --region us-east-2 \
            --db-instance-identifier taller-neptune-instance \
            --no-skip-final-snapshot
{
    "DBInstance": {
        "DBInstanceIdentifier": "taller-neptune-instance",
        "DBInstanceClass": "db.serverless",
        "Engine": "neptune",
        "DBInstanceStatus": "deleting",
        "MasterUsername": "admin",
        "Endpoint": {
            "Address": "taller-neptune-instance.c1aymgwc63hv.us-east-2.neptune.amazonaws.com",
            "Port": 8182,
            "HostedZoneId": "Z18MU2VX5LLW0S"
        },
        "AllocatedStorage": 1,
        "InstanceCreateTime": "2026-10-16T03:24:19.186000+00:00",
        "PreferredBackupWindow": "09:21-09:51",
        "BackupRetentionPeriod": 1,
        "DBSecurityGroups": [],
        "VpcSecurityGroups": [
            {
                "VpcSecurityGroupId": "sg-02040102bc3cc1d4c",
                "Status": "active"
            }
        ],
        "DBParameterGroups": [
            {
```



Eliminar el clúster

```
➜ 1s ⊙ aws neptune delete-db-cluster \                    (aws) □ TallerAWS/Punto4 △|●◦○◦| py 🐍 3.12.13 conda ○ aws 23:18
            --region us-east-2 \
            --db-cluster-identifier taller-neptune \
            --skip-final-snapshot
{
    "DBCluster": {
        "AllocatedStorage": 1,
        "AvailabilityZones": [
            "us-east-2b",
            "us-east-2c",
            "us-east-2a"
        ],
        "BackupRetentionPeriod": 1,
        "DBClusterIdentifier": "taller-neptune",
        "DBClusterParameterGroup": "default.neptune1.4",
        "DBSubnetGroup": "taller-neptune-subnets",
        "Status": "available",
        "EarliestRestorableTime": "2026-10-16T03:07:03.681000+00:00",
        "Endpoint": "taller-neptune.cluster-c1aymgwc63hv.us-east-2.neptune.amazonaws.com",
        "ReaderEndpoint": "taller-neptune.cluster-ro-c1aymgwc63hv.us-east-2.neptune.amazonaws.com",
        "MultiAZ": false,
        "Engine": "neptune",
        "EngineVersion": "1.4.6.3",
        "LatestRestorableTime": "2026-10-16T04:09:40.580000+00:00",
        "Port": 8182,
        "MasterUsername": "admin",
        "PreferredBackupWindow": "09:21-09:51",
        "PreferredMaintenanceWindow": "wed:06:11-wed:06:41",
        "ReadReplicaIdentifiers": [],
```

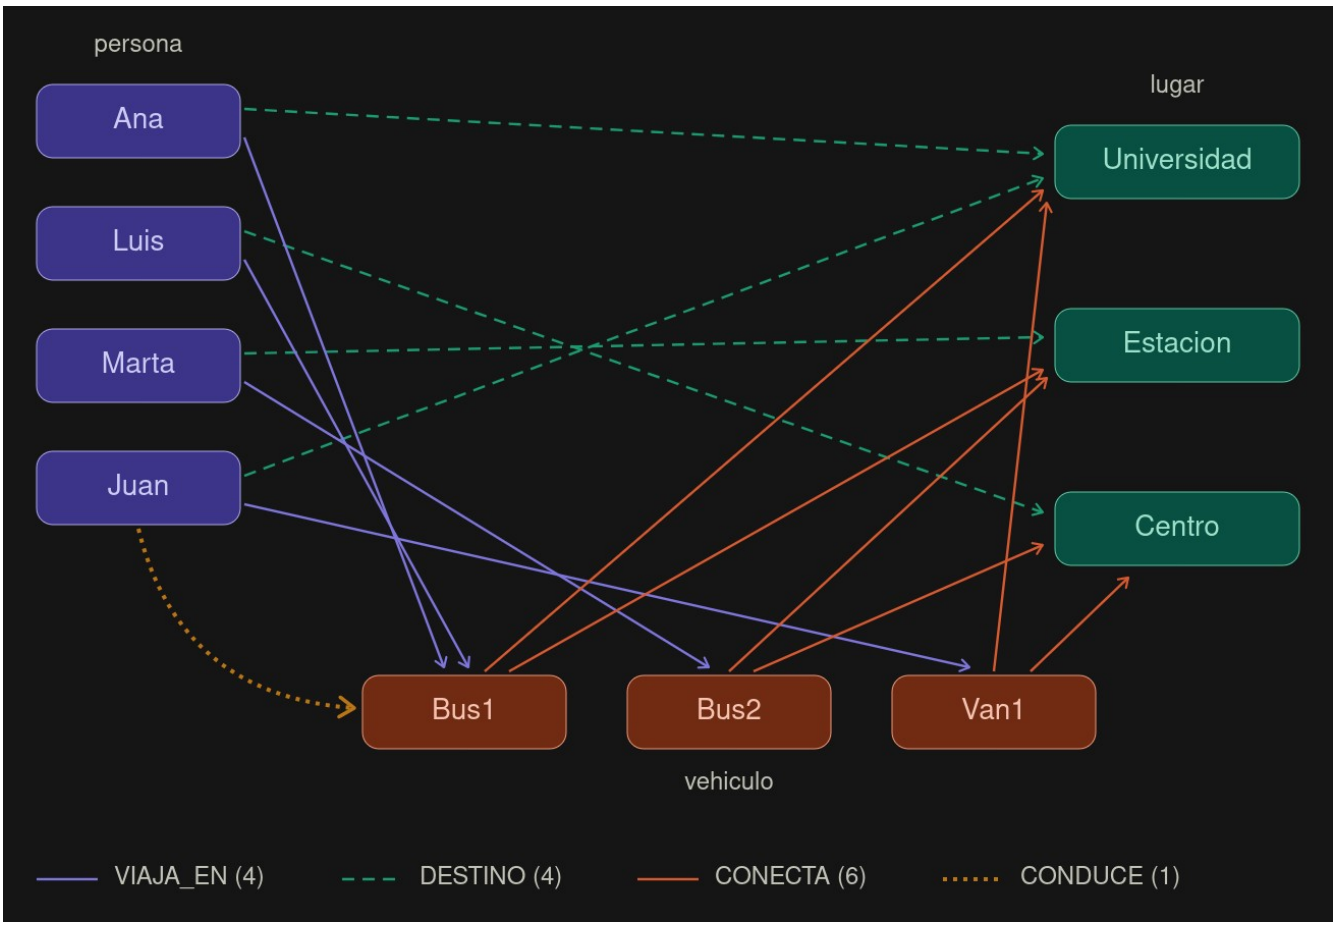


Quitar grupos de seguridad creados y subredes

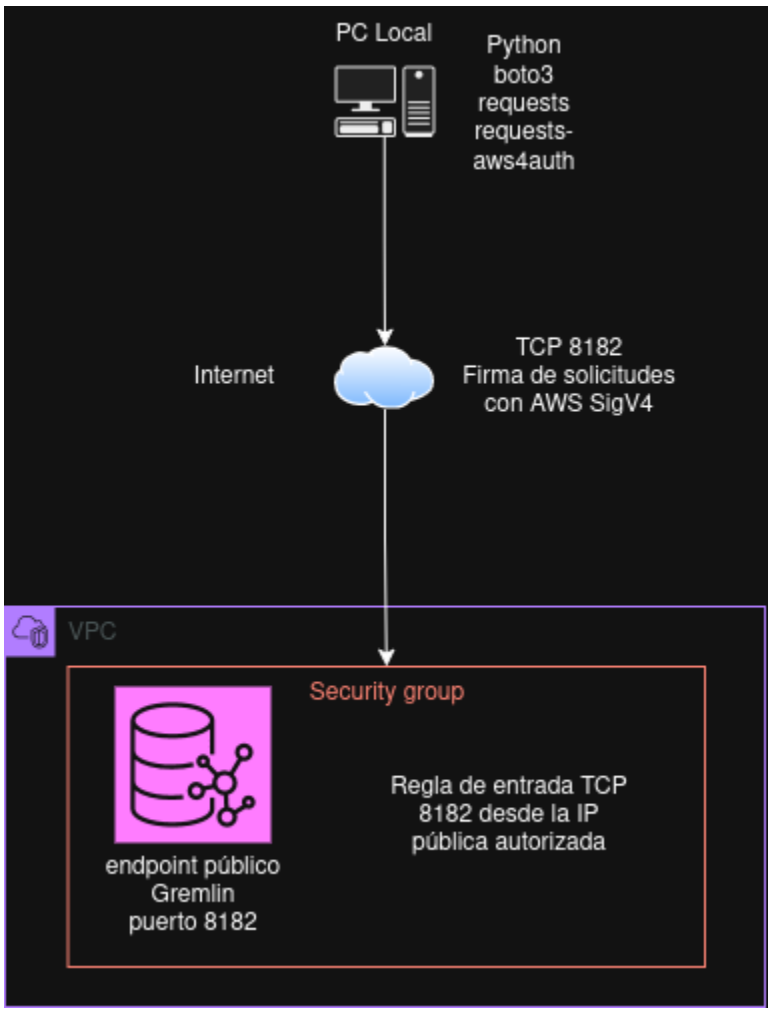
```
➜ 1s ○ aws ec2 delete-security-group \                    (aws) □ TallerAWS/Punto4 △|●◦○◦| py 🐍 3.12.13 conda ○ aws 23:21
            --region us-east-2 \
            --group-id sg-02040102bc3cc1d4c
{
    "Return": true,
    "GroupId": "sg-02040102bc3cc1d4c"
}
                                                                                                    ▲304▼15
➜ 1s ⊙                                                    (aws) □ TallerAWS/Punto4 △|●◦○◦| py 🐍 3.12.13 conda ○ aws 23:21
```

```
➜ 8s ⊙ aws neptune delete-db-subnet-group \               (aws) □ TallerAWS/Punto4 △|●◦○◦| py 🐍 3.12.13 conda ○ aws 23:21
            --region us-east-2 \
            --db-subnet-group-name taller-neptune-subnets
                                                                                                    ▲304▼15
➜ 1s ⊙                                                    (aws) □ TallerAWS/Punto4 △|●◦○◦| py 🐍 3.12.13 conda ○ aws 23:21
```

Modelo del grafo



Arquitectura de acceso neptune



Punto 5: Amazon Redshift

Servicio de data warehouse (almacenamiento de datos) para procesar y analizar vólumenes masivos de datos (a escala de petabytes) utilizando consultas SQL estándar. Muy utilizada para el análisis de inteligencia de negocio, análitica predictiva, análisis de clics en la web, agregación de datos históricos y consolidación de información proveniente de múltiples fuentes.

- **Clúster:** Elemento central de la infraestructura. Un conjuntoi de nodos que ejecutanm el motor de Redshift
- **Nodo lider:** Recibe las consultas del cliente, optimiza el plan de ejecución y compila el código para distribuirlo a los nodos de cómputo. No almacena datos del usuario.
- **Nodos de cómputo:** Ejecutan los fragmentos de código compilados por el nodo lider y almacenan los datos. Envían los resultados intermedios de vuelta al nodo líder
- **Almacenamiento administrativo:** Capa de almacenamiento basada en SSD de alto rendimiento respaldada por Amazon S3, que escala la capacidad de almacenamiento de forma automática e independiente del cómputo.
- **Arquitectura de almacenamiento columnar:** Organiza los datos por columnas en lugar de filas, reduciendo drásticamente los requerimientos de E/S de disco y acelerando las consultas analíticas.
- **Procesamiento masivamente paralelo:** Distribuye los datos y los fragmentos de consulta entre todos los nodos de cómputo para procesar la información de forma simultánea.

Característica	Amazon Redshift	Amazon RDS
Próposito principal	Procesamiento Analítico En Línea (OLAP)	Procesamiento de Transacciones En Línea (OLTP)
Tipo de carga de trabajo	Consultas complejas que leen millones de filas para agregar, promediar o buscar tendencias.	Operaciones frecuentes e inmediatas de lectura y escritura de registros individuales.
Estructura de datos	Datos optimizados por columnas para escaneos masivos eficientes.	Datos organizados por filas para inserciones, actualizaciones y eliminaciones rápidas.
Volumen de datos	Diseñado para Terabytes a Petabytes	Diseñado para Gigabytes a Gigabytes avanzados (pocos Terabytes).
Cuándo elegir	Objetivo de construir un tablero de controlo en herramientas de BI (QuickSight) para analizar un historial de ventas de los últimos 5 años, descubrir patrones de llos	Desarollo de una tienda de comercio electrónico que requiere registrar compras en tiempo real, actualizar el saldo del carrito de un cliente de forma

	usuarios o consolidar eventos que ocurren en un día	inmediata y gestionar inicios de sesión de manera transaccional y segura.

Para la configuración de menor costo es necesario analizar el costo por hora, duración de las consultas.

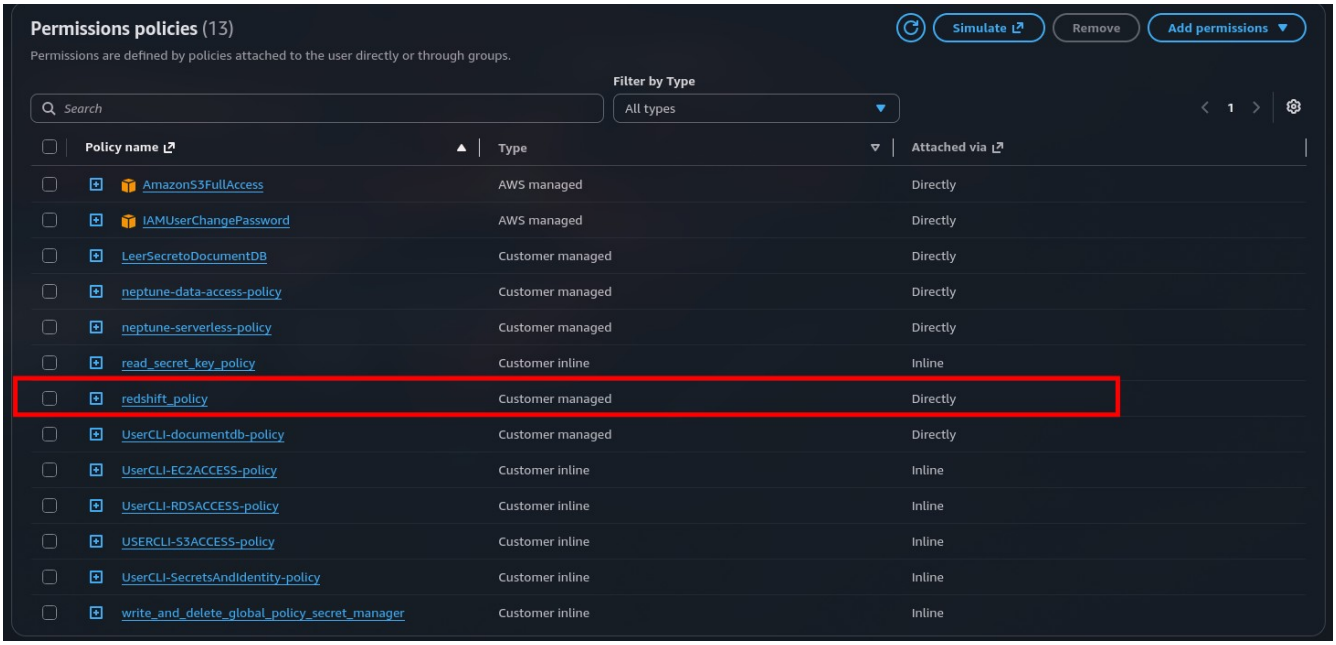
- La opción serverless tiene un costo de $0.36 USD por RPU/hora. Además, se tiene que usar mínimo 8 RPUs base por hora de uso activo. Lo que hace que con el mínimo de 8 RPUs el costo sea de unos $2.88 USD por hora activa. Se debe de resaltar que cuando no se tiene consultas se escala a 0 RPUs lo que detiene el cobro de cómputo. Es importante tener en cuenta que el almacenamiento de las tablas base (RMS) y los *snapshots* automáticos acumulados siguen cobrando centavos de dólar aunque no uses el cómputo.
- La opción aprovisionada cobra por hora del nodo encendido sin importar si procesa consultas o está inactivo. Una instancia básica dc2.large cuesta aproximadamente $0.25 USD/hora. Si el clúster no se pausa o elimina, los nodos de cómputo seguirán facturando hora tras hora al 100%.

Con esta información si se va a usar el clúster continuamente por más de 12 horas es más económico el clúster aprovisionado. Si es algo más corto de unas 2-3 horas de ejecución real puede salir más económico la opción serverless al pausarse el cobro cuando está inactivo o no recibe consultas.

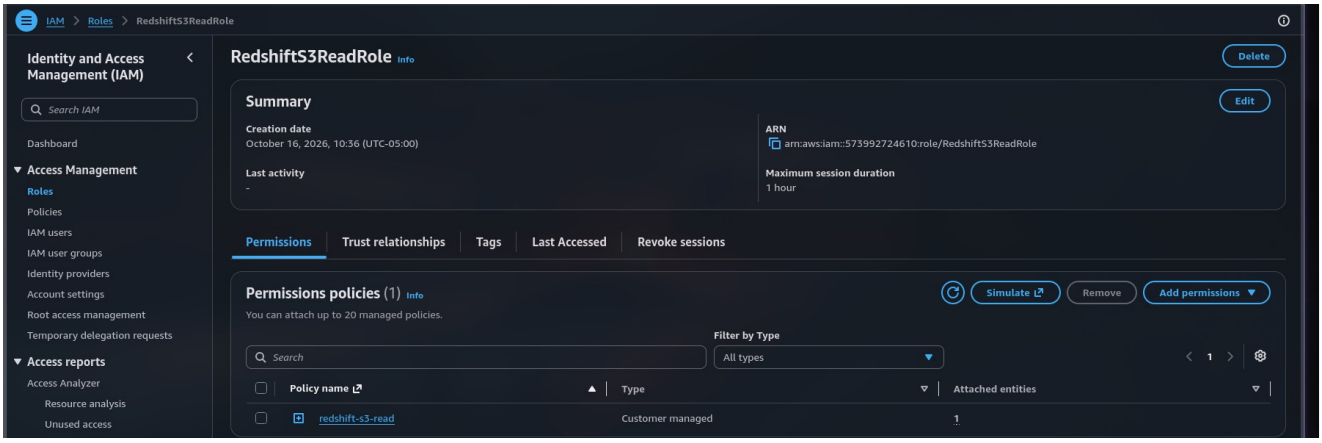
Con esto presente se va a desplegar la opción serverless.

Despliegue

Creación de la política IAM



Creación del rol y política para que Redshift tome los datos del s3



Creación del secreto

```
◄ 0s ◎ aws secretsmanager create-secret \                    (aws) □ TallerAWS/Punto5 △|◌◦| conda ○ aws 47% ↑ 10:38
            --name taller/redshift/admin \
            --description "Credenciales administrativas de Redshift Serverless" \
            --secret-string '{"username":"awsuser","password":"Hola1234*"}' \
            --region us-east-2
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:taller/redshift/admin-42BNSK",
    "Name": "taller/redshift/admin",
    "VersionId": "18209c8f-6668-4a6e-953f-cc1b055410d9"
}
```

Crear el namespace y workgroup de Amazon Redshift Serverless

```
◄ 0s ◎ set SECRET_JSON (aws secretsmanager get-secret-value \      (aws) □ TallerAWS/Punto5 △|◌◦| conda ○ aws 50% ↑ 10:41
                --secret-id taller/redshift/admin \
                --region us-east-2 \
                --query SecretString \
                --output text)

      set ADMIN_PASSWORD (printf '%s' "$SECRET_JSON" | jq -r '.password')
      set ADMIN_USERNAME (printf '%s' "$SECRET_JSON" | jq -r '.username')

      aws redshift-serverless create-namespace \
            --namespace-name taller-redshift-ns \
            --db-name taller_dw \
            --admin-username "$ADMIN_USERNAME" \
            --admin-user-password "$ADMIN_PASSWORD" \
            --iam-roles arn:aws:iam::573992724610:role/RedshiftS3ReadRole \
            --region us-east-2

      set -e SECRET_JSON ADMIN_PASSWORD ADMIN_USERNAME
{
    "namespace": {
        "adminUsername": "awsuser",
        "creationDate": "2026-10-16T15:42:27.287000+00:00",
        "dbName": "taller_dw",
        "iamRoles": [
            "IamRole(applyStatus=null, iamRoleArn=arn:aws:iam::573992724610:role/RedshiftS3ReadRole)"
        ],
        "kmsKeyId": "AWS_OWNED_KMS_KEY",
        "lakehouseRegistrationStatus": "NOT_REGISTERED",
        "logExports": [],
        "namespaceArn": "arn:aws:redshift-serverless:us-east-2:573992724610:namespace/c1b91a98-5ae0-40b0-9231-33340fbe2cf
```

```
{
    "namespace": {
        "adminUsername": "awsuser",
        "creationDate": "2026-10-16T15:42:27.287000+00:00",
        "dbName": "taller_dw",
        "iamRoles": [
            "IamRole(applyStatus=null, iamRoleArn=arn:aws:iam::573992724610:role/RedshiftS3ReadRole)"
        ],
        "kmsKeyId": "AWS_OWNED_KMS_KEY",
        "lakehouseRegistrationStatus": "NOT_REGISTERED",
        "logExports": [],
        "namespaceArn": "arn:aws:redshift-serverless:us-east-2:573992724610:namespace/c1b91a98-5ae0-40b0-9231-33340fbe2cf
4",
        "namespaceId": "c1b91a98-5ae0-40b0-9231-33340fbe2cf4",
        "namespaceName": "taller-redshift-ns",
        "status": "AVAILABLE"
    }
}
```

◄ 3s ◎ | (aws) □ TallerAWS/Punto5 △|◌◦| conda ○ aws 52% ↑ 10:42

◄ 25s ◎ aws redshift-serverless create-workgroup \ (aws) □ TallerAWS/Punto5 △|◌◦| conda ○ aws 55% ↑ 10:45

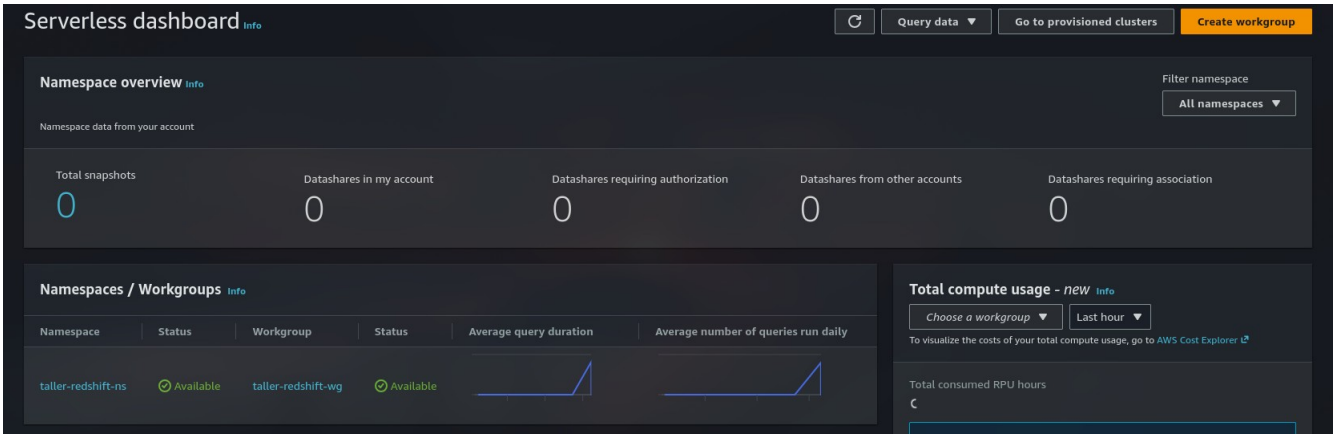
```
              --workgroup-name taller-redshift-wg \
              --namespace-name taller-redshift-ns \
              --base-capacity 4 \
              --no-publicly-accessible \
              --region us-east-2
{
    "workgroup": {
        "baseCapacity": 4,
        "configParameters": [
            {
                "parameterKey": "auto_mv",
                "parameterValue": "true"
            },
            {
                "parameterKey": "datestyle",
                "parameterValue": "ISO, MDY"
            },
            {
                "parameterKey": "enable_case_sensitive_identifier",
                "parameterValue": "false"
            },
            {
                "parameterKey": "enable_large_strings_opt_in",
                "parameterValue": ""
            },
            {
                "parameterKey": "enable_user_activity_logging",
                "parameterValue": "true"
            },
```

◄ 1s ◎ aws redshift-serverless get-workgroup \ (aws) □ TallerAWS/Punto5 △|◌◦| conda ○ aws 55% ↑ 10:46

```
              --workgroup-name taller-redshift-wg \
              --region us-east-2 \
              --query 'workgroup.{Estado:status,Endpoint:endpoint.address,Puerto:endpoint.port,Capacidad:baseCapacity}'
\
              --output table
-------------------------------------------------------------------------------------------------------------
|                                                GetWorkgroup                                               |
+-----------+-------------------------------------------------------------------------+------------+----------+
| Capacidad |                                 Endpoint                                |  Estado    | Puerto   |
+-----------+-------------------------------------------------------------------------+------------+----------+
|  4        |  taller-redshift-wg.573992724610.us-east-2.redshift-serverless.amazonaws.com  |  AVAILABLE |  5439    |
+-----------+-------------------------------------------------------------------------+------------+----------+
```

◄ 1s ◎ (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 55% ↑ 10:47

```
◄ 1s ◎ aws redshift-serverless get-namespace \                    (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 57% ↑ 10:47
              --namespace-name taller-redshift-ns \
              --region us-east-2 \
              --query 'namespace.{Estado:status,BaseDatos:dbName,RolIAM:iamRoles}' \
              --output json
{
    "Estado": "AVAILABLE",
    "BaseDatos": "taller_dw",
    "RolIAM": [
        "IamRole(applyStatus=in-sync, iamRoleArn=arn:aws:iam::573992724610:role/RedshiftS3ReadRole)"
    ]
}
```



Ejecución del script de python (ejecutar_redshift.py)

```
◄ 4s ○ python python/ejecutar_redshift.py                         (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:06
=== 1. Preparar archivos en S3 ===
Bucket existente: talleraws-redshift-573992724610
Subido y verificado: s3://talleraws-redshift-573992724610/datos/clientes.csv
Subido y verificado: s3://talleraws-redshift-573992724610/datos/ventas.csv

=== 2. Verificar recursos y secreto ===

=== 3. Crear tablas ===
SQL enviado. ID: 4ecb78fe-6248-451f-bef0-6cf2de9a54c6
Sentencia terminada: 4ecb78fe-6248-451f-bef0-6cf2de9a54c6
SQL enviado. ID: de05455a-847a-41c6-abf1-804717d2d150
Sentencia terminada: de05455a-847a-41c6-abf1-804717d2d150

=== 4. Cargar archivos CSV ===
SQL enviado. ID: 1a88ff6b-4d6e-4669-8965-005ae22d1471
Sentencia terminada: 1a88ff6b-4d6e-4669-8965-005ae22d1471
SQL enviado. ID: 5e41fda4-f780-4cf5-8068-d4cd17e0db8e
Sentencia terminada: 5e41fda4-f780-4cf5-8068-d4cd17e0db8e
SQL enviado. ID: a77214ad-5128-473f-830e-5f0c962413c3
Sentencia terminada: a77214ad-5128-473f-830e-5f0c962413c3
Datos cargados en clientes
SQL enviado. ID: acd237e7-3f34-4269-b894-6dc7bedbca79
Sentencia terminada: acd237e7-3f34-4269-b894-6dc7bedbca79
Datos cargados en ventas

=== 5. Ejecutar consultas y recuperar resultados ===
```

```
=== 5. Ejecutar consultas y recuperar resultados ===

======================================================================
Ventas superiores a 900000
======================================================================
SQL enviado. ID: dcc0f66c-ee67-4112-8881-d308ffd6cbd1
Sentencia terminada: dcc0f66c-ee67-4112-8881-d308ffd6cbd1

venta_id | producto | importe | fecha
----------------------------------------------------------------------
112 | Laptop | 3600000.00 | 2026-09-12
101 | Laptop | 3500000.00 | 2026-09-01
107 | Laptop | 3400000.00 | 2026-09-07
104 | Laptop | 3200000.00 | 2026-09-04
103 | Monitor | 950000.00 | 2026-09-03

======================================================================
Ventas relacionadas con clientes
======================================================================
SQL enviado. ID: 1880b184-b037-4b78-9adf-c00b030960f9
Sentencia terminada: 1880b184-b037-4b78-9adf-c00b030960f9

venta_id | nombre | ciudad | producto | importe | fecha
----------------------------------------------------------------------
101 | Ana | Medellin | Laptop | 3500000.00 | 2026-09-01
102 | Carlos | Bogota | Mouse | 80000.00 | 2026-09-02
103 | Ana | Medellin | Monitor | 950000.00 | 2026-09-03
104 | Laura | Cali | Laptop | 3200000.00 | 2026-09-04
105 | Andres | Medellin | Teclado | 150000.00 | 2026-09-05
106 | Sofia | Bogota | Monitor | 900000.00 | 2026-09-06
```

```
Sentencia terminada: 1880b184-b037-4b78-9adf-c00b030960f9

venta_id | nombre | ciudad | producto | importe | fecha
----------------------------------------------------------------------
101 | Ana | Medellin | Laptop | 3500000.00 | 2026-09-01
102 | Carlos | Bogota | Mouse | 80000.00 | 2026-09-02
103 | Ana | Medellin | Monitor | 950000.00 | 2026-09-03
104 | Laura | Cali | Laptop | 3200000.00 | 2026-09-04
105 | Andres | Medellin | Teclado | 150000.00 | 2026-09-05
106 | Sofia | Bogota | Monitor | 900000.00 | 2026-09-06
107 | Mateo | Envigado | Laptop | 3400000.00 | 2026-09-07
108 | Carlos | Bogota | Teclado | 140000.00 | 2026-09-08
109 | Andres | Medellin | Mouse | 75000.00 | 2026-09-09
110 | Laura | Cali | Monitor | 875000.00 | 2026-09-10
111 | Mateo | Envigado | Mouse | 85000.00 | 2026-09-11
112 | Sofia | Bogota | Laptop | 3600000.00 | 2026-09-12

======================================================================
Resumen por cliente
======================================================================
SQL enviado. ID: eb96edbc-450c-4c17-a4f7-05ccea1858e5
Sentencia terminada: eb96edbc-450c-4c17-a4f7-05ccea1858e5

cliente_id | nombre | ciudad | total_vendido | cantidad_compras
----------------------------------------------------------------------
5 | Sofia | Bogota | 4500000.00 | 2
1 | Ana | Medellin | 4450000.00 | 2
3 | Laura | Cali | 4075000.00 | 2
6 | Mateo | Envigado | 3485000.00 | 2
4 | Andres | Medellin | 225000.00 | 2
```

```
SQL enviado. ID: eb96edbc-450c-4c17-a4f7-05ccea1858e5
Sentencia terminada: eb96edbc-450c-4c17-a4f7-05ccea1858e5

cliente_id | nombre | ciudad | total_vendido | cantidad_compras
-----------------------------------------------------------------------
5 | Sofia | Bogota | 4500000.00 | 2
1 | Ana | Medellin | 4450000.00 | 2
3 | Laura | Cali | 4075000.00 | 2
6 | Mateo | Envigado | 3485000.00 | 2
4 | Andres | Medellin | 225000.00 | 2
2 | Carlos | Bogota | 220000.00 | 2

=======================================================================
Resumen por ciudad
=======================================================================
SQL enviado. ID: 9b3eb991-57a9-45b2-8aaf-edd2d701a91b
Sentencia terminada: 9b3eb991-57a9-45b2-8aaf-edd2d701a91b

ciudad | total_vendido | cantidad_ventas
-----------------------------------------------------------------------
Bogota | 4720000.00 | 4
Medellin | 4675000.00 | 4
Cali | 4075000.00 | 2
Envigado | 3485000.00 | 2

=======================================================================
Verificacion de registros
```

```
=======================================================================
Verificacion de registros
=======================================================================
SQL enviado. ID: 51690d66-aee0-47b1-9f4c-842b5815e5cd
Sentencia terminada: 51690d66-aee0-47b1-9f4c-842b5815e5cd

tabla | registros
-----------------------------------------------------------------------
ventas | 12
clientes | 6

Proceso finalizado correctamente.

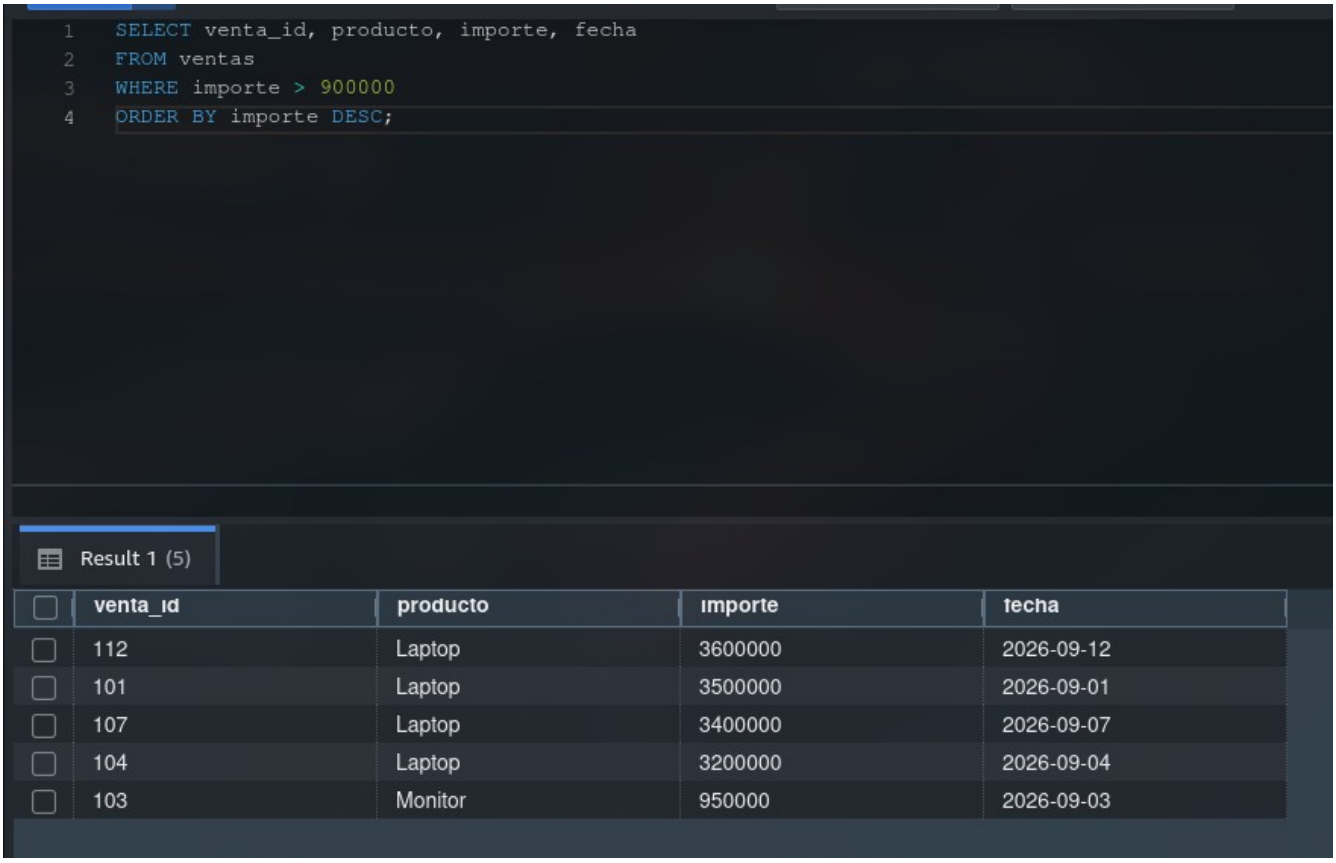
◄ 1m20s ◎ |                                    (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:08
```

Consuiltas y explicación

¿Qué ventas superaron los $900.000 COP?

La consulta filtra las ventas cuyo importe es estrictamente mayor a $900.000 COP y las organiza de mayor a menor valor. Permite identificar las transacciones de mayor importe, por ejemplo, las ventas de portátiles y monitores que superan ese umbral.

Esta información es útil para identificar operaciones de alto valor y analizar cuáles productos generan ventas individuales más elevadas.



```sql
SELECT venta_id, producto, importe, fecha
FROM ventas
WHERE importe > 900000
ORDER BY importe DESC;
```

Result 1 (5)

venta_id	producto	importe	fecha
112	Laptop	3600000	2026-09-12
101	Laptop	3500000	2026-09-01
107	Laptop	3400000	2026-09-07
104	Laptop	3200000	2026-09-04
103	Monitor	950000	2026-09-03

¿Quién realizó cada compra, en qué ciudad vive y qué producto compró?

La consulta relaciona las tablas `ventas` y `clientes` mediante el campo `cliente_id`. De esta manera, cada venta se presenta con información adicional del cliente, como su nombre y ciudad.

Como existen 12 ventas y 6 clientes en el conjunto de datos, se esperan 12 registros en el resultado, siempre que todas las ventas tengan un cliente asociado. Un mismo cliente puede aparecer varias veces porque puede realizar múltiples compras.

Esta consulta demuestra cómo integrar información de diferentes tablas para obtener una visión más completa de las transacciones.

```sql
SELECT
    v.venta_id,
    c.nombre,
    c.ciudad,
    v.producto,
    v.importe,
    v.fecha
FROM ventas v
JOIN clientes c
    ON v.cliente_id = c.cliente_id
ORDER BY v.venta_id;
```

Result 1 (12) Export

venta_id	nombre	ciudad	producto	importe	fecha
101	Ana	Medellin	Laptop	3500000	2026-09-01
102	Carlos	Bogota	Mouse	80000	2026-09-02
103	Ana	Medellin	Monitor	950000	2026-09-03
104	Laura	Cali	Laptop	3200000	2026-09-04
105	Andres	Medellin	Teclado	150000	2026-09-05
106	Sofia	Bogota	Monitor	900000	2026-09-06
107	Mateo	Envigado	Laptop	3400000	2026-09-07
108	Carlos	Bogota	Teclado	140000	2026-09-08
109	Andres	Medellin	Mouse	75000	2026-09-09
110	Laura	Cali	Monitor	875000	2026-09-10
111	Mateo	Envigado	Mouse	85000	2026-09-11

Query ID: 203208 Elapsed time: 36

¿Cuánto dinero ha gastado cada cliente y cuántas compras ha realizado?

La función `SUM()` calcula el importe acumulado de las compras de cada cliente, mientras que `COUNT()` cuenta el número de ventas asociadas a cada uno. `GROUP BY` agrupa las transacciones por cliente.

Los resultados permiten identificar:

- Los clientes que generan mayores ingresos.
- Los clientes que realizan más compras.
- Las diferencias entre el número de compras y el dinero gastado.

Por ejemplo, un cliente puede tener pocas compras, pero un importe total elevado si adquirió productos costosos. Otro puede realizar más compras de menor valor. Esto permite distinguir entre frecuencia de compra y valor económico aportado.

```sql
SELECT
    c.cliente_id,
    c.nombre,
    SUM(v.importe) AS total_compras,
    COUNT(v.venta_id) AS cantidad_ventas
FROM clientes c
JOIN ventas v
    ON c.cliente_id = v.cliente_id
GROUP BY c.cliente_id, c.nombre
ORDER BY total_compras DESC;
```

Result 1 (6)

cliente_id	nombre	total_compras	cantidad_ventas
5	Sofia	4500000	2
1	Ana	4450000	2
3	Laura	4075000	2
6	Mateo	3485000	2
4	Andres	225000	2
2	Carlos	220000	2

¿Qué ciudades generan mayores ingresos y cuántas ventas se registran en cada una?

La consulta agrupa las ventas según la ciudad del cliente. Para cada ciudad calcula el importe total vendido y la cantidad de transacciones.

Esto permite comparar la actividad comercial entre Medellín, Bogotá, Cali y Envigado, e identificar dónde se concentra el mayor volumen de ventas.

Los resultados pueden utilizarse para orientar campañas comerciales, promociones o estrategias de fidelización por zona geográfica. Sin embargo, como el conjunto de datos es pequeño y contiene solo seis clientes, las conclusiones deben entenderse como un ejercicio académico, no como una representación del mercado real.

```sql
SELECT
    c.ciudad,
    SUM(v.importe) AS total_ventas,
    COUNT(v.venta_id) AS cantidad_ventas
FROM clientes c
JOIN ventas v
    ON c.cliente_id = v.cliente_id
GROUP BY c.ciudad
ORDER BY total_ventas DESC;
```

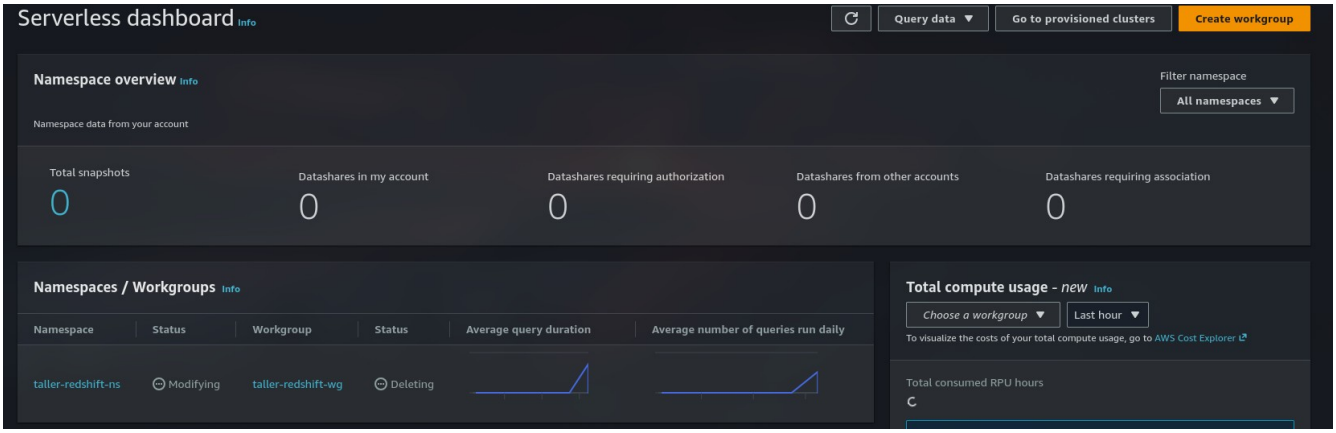
Result 1 (4)

ciudad	total_ventas	cantidad_ventas
Bogota	4720000	4
Medellin	4675000	4
Cali	4075000	2
Envigado	3485000	2

Eliminación

Eliminación del workgroup y namespace

```
◄ 22s ◎ aws redshift-serverless delete-workgroup \                    (aws) □ TallerAWS/Punto5 △|●◌◦| conda ○ aws 11:15
            --workgroup-name taller-redshift-wg \
            --region us-east-2
{
    "workgroup": {
        "baseCapacity": 4,
        "configParameters": [
            {
                "parameterKey": "auto_mv",
                "parameterValue": "true"
            },
            {
                "parameterKey": "datestyle",
                "parameterValue": "ISO, MDY"
            },
            {
                "parameterKey": "enable_case_sensitive_identifier",
                "parameterValue": "false"
            },
            {
                "parameterKey": "enable_large_strings_opt_in",
                "parameterValue": ""
            },
            {
                "parameterKey": "enable_user_activity_logging",
                "parameterValue": "true"
            },
            {
                "parameterKey": "query_group",
```



```
➜ 1s ◎ aws redshift-serverless delete-namespace \                    (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:19
            --namespace-name taller-redshift-ns \
            --region us-east-2
{
    "namespace": {
        "adminUsername": "awsuser",
        "creationDate": "2026-10-16T15:42:27.287000+00:00",
        "dbName": "taller_dw",
        "iamRoles": [
            "IamRole(applyStatus=in-sync, iamRoleArn=arn:aws:iam::573992724610:role/RedshiftS3ReadRole)"
        ],
        "kmsKeyId": "AWS_OWNED_KMS_KEY",
        "lakehouseRegistrationStatus": "NOT_REGISTERED",
        "logExports": [],
        "namespaceArn": "arn:aws:redshift-serverless:us-east-2:573992724610:namespace/c1b91a98-5ae0-40b0-9231-33340fbe2cf
4",
        "namespaceId": "c1b91a98-5ae0-40b0-9231-33340fbe2cf4",
        "namespaceName": "taller-redshift-ns",
        "status": "DELETING"
    }
}

➜ 1s ◎ [ ]                                                           (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:19
```

```
➜ 1s ○ aws redshift-serverless get-namespace \                       (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:21
            --namespace-name taller-redshift-ns \
            --region us-east-2

aws: [ERROR]: An error occurred (ResourceNotFoundException) when calling the GetNamespace operation: Serverless namespace
 taller-redshift-ns not found.

➜ 1s ○ [ ]                                                           (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:21
```

Eliminar el S3

```
➜ 1s ◎ aws s3 rm s3://talleraws-redshift-573992724610 \              (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:20
            --recursive \
            --region us-east-2
delete: s3://talleraws-redshift-573992724610/datos/ventas.csv
delete: s3://talleraws-redshift-573992724610/datos/clientes.csv

➜ 1s ◎ aws s3api delete-bucket \                                     (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:20
            --bucket talleraws-redshift-573992724610 \
            --region us-east-2

➜ 1s ◎ aws s3api head-bucket \                                       (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:21
            --bucket talleraws-redshift-573992724610

aws: [ERROR]: An error occurred (404) when calling the HeadBucket operation: Not Found

➜ 1s ○ [ ]                                                           (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:21
```

Eliminar el secreto

```
➜ 1s ◎ aws secretsmanager delete-secret \                            (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:22
            --secret-id taller/redshift/admin \
            --force-delete-without-recovery \
            --region us-east-2
{
    "ARN": "arn:aws:secretsmanager:us-east-2:573992724610:secret:taller/redshift/admin-42BNSK",
    "Name": "taller/redshift/admin",
    "DeletionDate": "2026-10-16T11:22:50.073000-05:00"
}

➜ 1s ◎ [ ]                                                           (aws) □ TallerAWS/Punto5 △|●◦◌◦| conda ○ aws 11:22
```

Punto 6: AWS Glue Data Catalog

AWS Glue Data Catalog almacena exclusivamente metadatos (descripción estructural de los datos). No almacena registros, ni filas, ni archivos. Funciona como un índice o un mapa de carreteras hacia donde realmente residen los datos.

Diferencia entre archivos en Amazon S3 vs Metadatos en el Catálogo

Característica	Archivos de datos en Amazon S3	Metadatos en AWS Glue Data Catalog
¿Qué es?	Almacenamiento físico y persistente de la información	El diccionario o índice centralizado de los datos.
¿Que contiene exactamente?	Archivos reales cargados con registros (formatos como CSV, JSON, Parquet o Avro).	Esquemas, nombres de columnas, tipos de datos (int, string), rutas S3 y formatos de compresión.
Volumen de almacenamiento	Gigabytes, Terabytes o Petabytes de datos operativos del negocio.	Unos pocos Kilobytes o Megabytes de texto descriptivo.
Ejemplo de contenido	Un archivo `ventas_2026.parquet` con 10 millones de filas de transacciones.	Una definición que dice: *"La tabla 'ventas' tiene las columnas 'id' (int) y 'monto' (double), y está guardada en `s3://mi-bucket/ventas/`"*.

Componentes clave de AWS GLUE

- **Base de datos:** Estructura lógica de agrupación. No es una base de datos relacional como MySQL, sino un contenedor o carpeta virtual dentro del catálogo para organizar las tablas por proyectos, departamentos o entornos.
- **Tablas:** Definición del esquema que representa los archivos de S3 como si fueran una tabla SQL tradicional. Define la estructura para que herramientas externas (como Amazon Athena) puedan realizar consultas. Una tabla de Glue le dice al motor de búsqueda cuántas columnas tienen los archivos, de qué tipo es cada columna, cuál es la delimitación del archivo (separado por comas o tabulares), si los datos están en particiones, etc.
- **Crawlers:** Es un programa automatizado que hace el trabajo pesado. En lugar de configurar manualmente el esquema y columnas de cada tabla, se configura un Crawler. La función es conectarse de forma segura a las carpetas de S3, leer una muestra de archivos reales para deducir automáticamente su formato y estrucutura, crear o actualizar automáticamente las tablas dentro de la base de datos de glue o detectar si han llegado nuevas columnas o si los datos se han estructurado en nuevas carpetas (particiones)

Costos

- AWS Glue Crawler $0.44 USD DPU-Hora (Data Processing Unit). Facturación por segundo con un mínimo de 10 minutos por ejecución.
- AWS Glue Catalog gratis el primer millón, $1.00 usd por cada 100k objetos al mes y $1.00 usd por cada millón de solicitudes.
- AWS S3 $0.023 usd por GB y $0.0004 usd por 1000 peticiones
- Amazon Athena $5.00 usd por TB escaneado

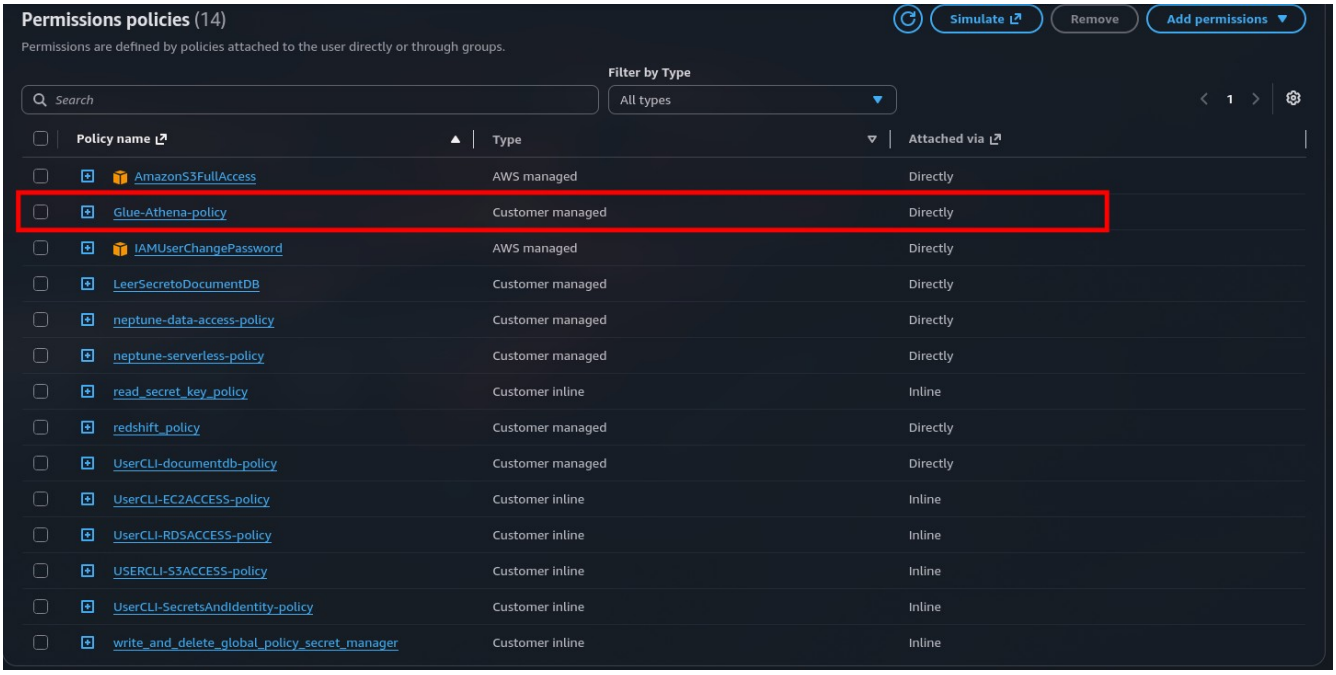
¿Por qué no se necesita un secreto en Secrets Manager?

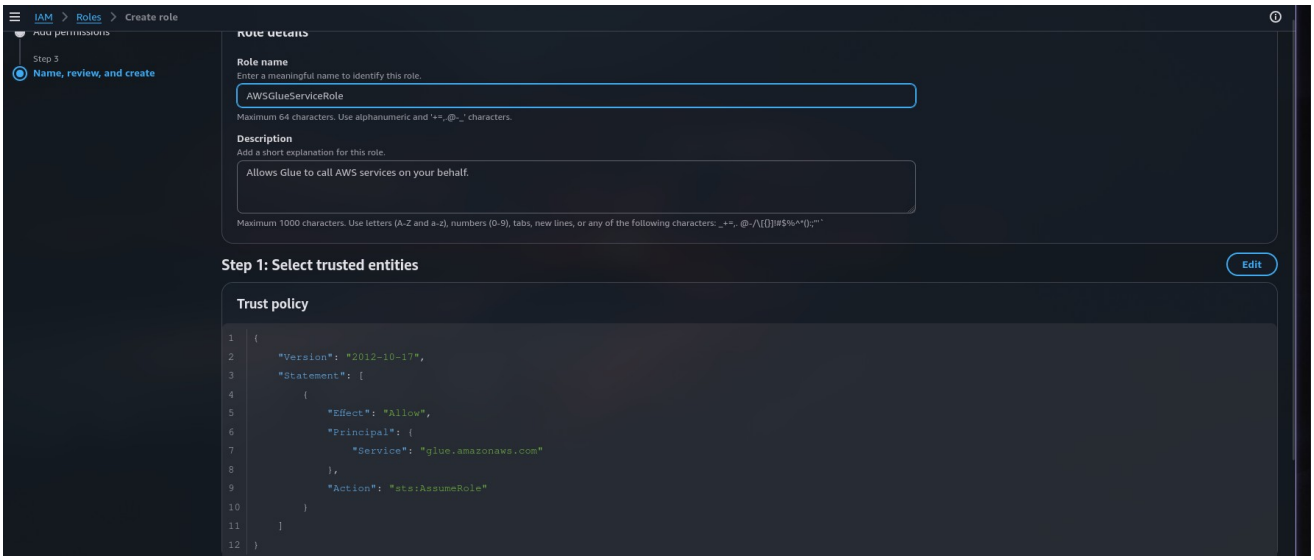
En el modelo de seguridad de AWS, el acceso entre servicios nativos se gestiona mediante el principio de identidades y roles, no mediante contraseñas, tokens o llaves de aplicación de larga duración.

- **Relación de confianza nativa:** S3, AWS Glue y Amazon Athena pertenecen al mismo ecosistema central de AWS. Están diseñados para comunicarse entre sí mediante el plano de control de AWS utilizando **Roles de IAM (Identity and Access Management)**.
- **Roles asumibles:** Cuando configuras un *Glue Crawler* o ejecutas una consulta en *Athena*, no les proporcionas un usuario y contraseña. En su lugar, les asignas un **Rol de IAM** (una identidad con permisos temporales). El servicio "asume" ese rol para realizar la tarea.
- **Credenciales temporales automáticas:** Tras bambalinas, AWS genera llaves de acceso que **caducan en pocas horas y se rotan automáticamente** cada vez que el componente se ejecuta. Al no existir una contraseña fija o estática, no hay nada que proteger dentro de Secrets Manager.

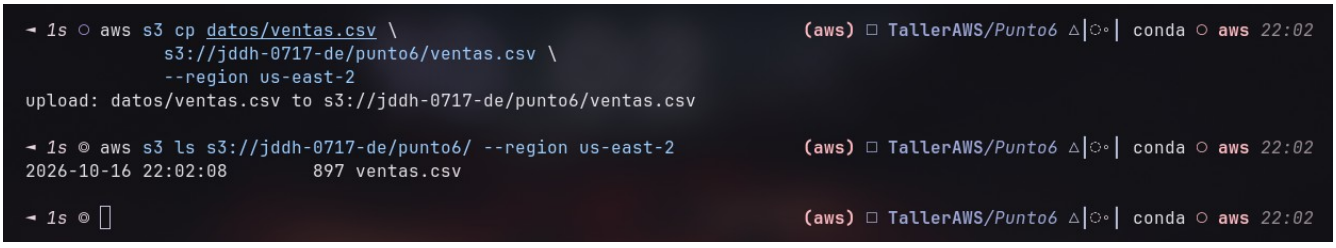
Despliegue

Crear la política de acceso para el usuario y rol para ejecutar el crawler





Subir los datos al s3 en la carpeta punto6



Crear base de datos y crawler

```
◄ 1s ◎ aws glue create-database \                                    (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:02
            --database-input '{"Name":"taller_aws_punto6","Description":"Catalogo para el punto 6 del Taller AWS"}' \
            --region us-east-2

◄ 1s ◎ aws glue get-databases \                                      (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:03
            --region us-east-2 \
            --query 'DatabaseList[?Name==`taller_aws_punto6`].Name'
[
    "taller_aws_punto6"
]

◄ 1s ◎                                                               (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:03
```

```
◄ 6s ◎ aws glue create-crawler \                                     (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:07
             --name crawler_ventas_punto6 \
             --role arn:aws:iam::573992724610:role/AWSGlueServiceRole \
             --database-name taller_aws_punto6 \
             --targets '{"S3Targets":[{"Path":"s3://jddh-0717-de/punto6/"}]}' \
             --schema-change-policy '{"UpdateBehavior":"UPDATE_IN_DATABASE","DeleteBehavior":"DEPRECATE_IN_DATABASE"}' \
             --region us-east-2

◄ 1s ◎ aws glue get-crawler \                                        (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:07
             --name crawler_ventas_punto6 \
             --region us-east-2 \
             --query 'Crawler.{Estado:State,UltimoAnalisis:LastCrawl.Status,Detalles:LastCrawl.ErrorMessage}' \
             --output table
-----------------------------------------
|              GetCrawler               |
+-----------+---------+-----------------+
| Detalles  | Estado  | UltimoAnalisis  |
+-----------+---------+-----------------+
|  None     |  READY  |  None           |
+-----------+---------+-----------------+

◄ 1s ◎                                                               (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:07
```

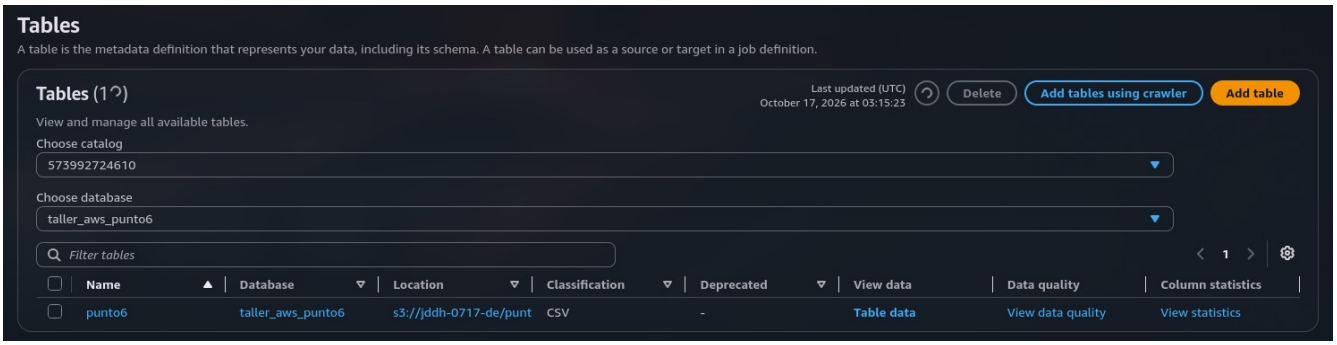
Iniciar el Crawler

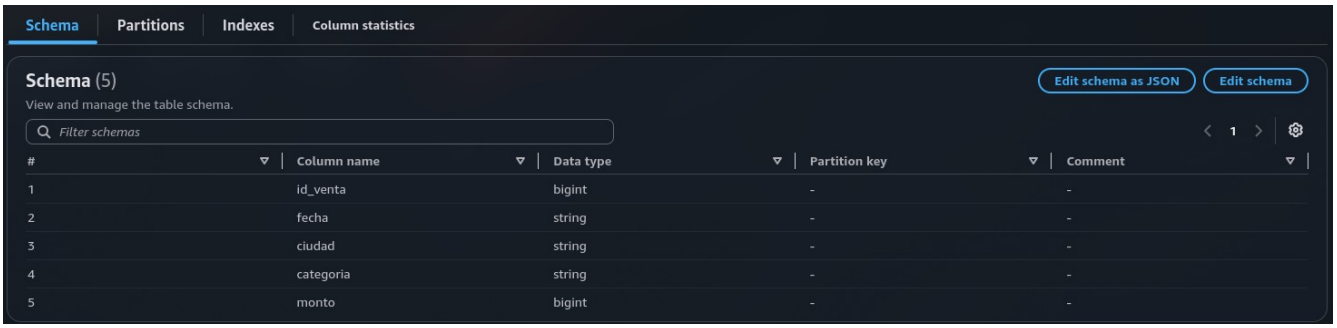
```
◄ 1s ◎ aws glue start-crawler \                                      (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:09
             --name crawler_ventas_punto6 \
             --region us-east-2

◄ 1s ◎ aws glue get-crawler \                                        (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:09
             --name crawler_ventas_punto6 \
             --region us-east-2 \
             --query 'Crawler.{Estado:State,UltimoAnalisis:LastCrawl.Status,Error:LastCrawl.ErrorMessage}' \
             --output json
{
    "Estado": "RUNNING",
    "UltimoAnalisis": null,
    "Error": null
}
```

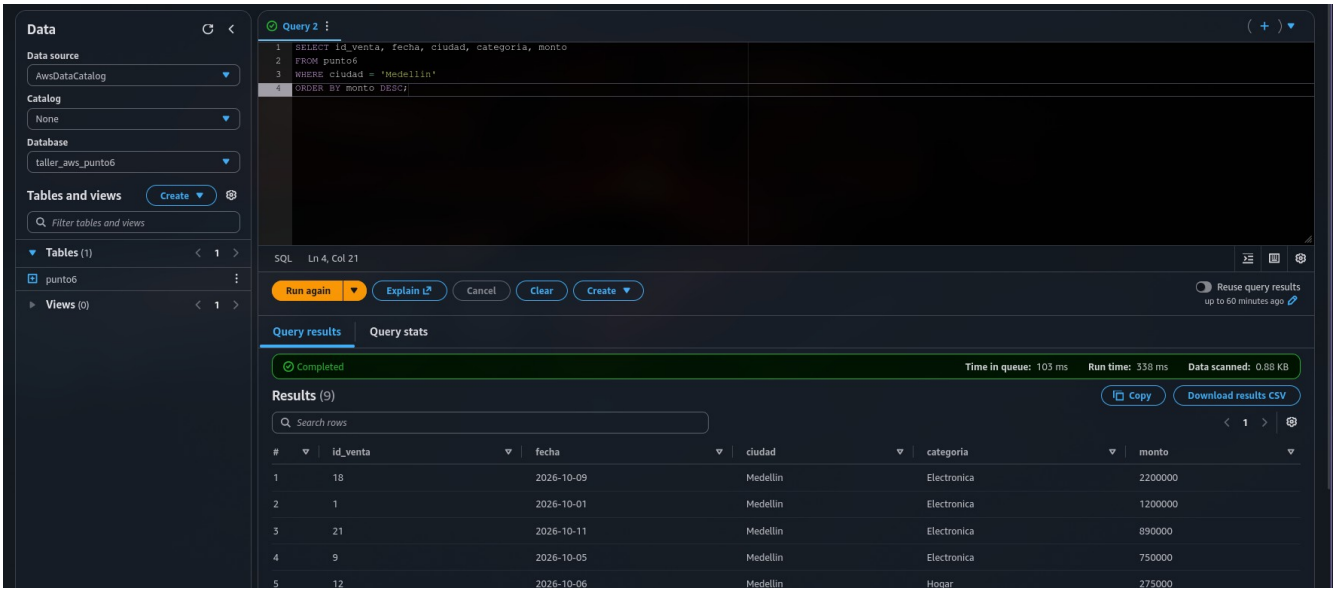
```
◄ 1s ◎ aws glue get-crawler \                                        (aws) □ TallerAWS/Punto6 △|○◦| conda ○ aws 22:09
            --name crawler_ventas_punto6 \
            --region us-east-2 \
            --query 'Crawler.{Estado:State,UltimoAnalisis:LastCrawl.Status,Error:LastCrawl.ErrorMessage}' \
            --output json
{
    "Estado": "READY",
    "UltimoAnalisis": "SUCCEEDED",
    "Error": null
}
```

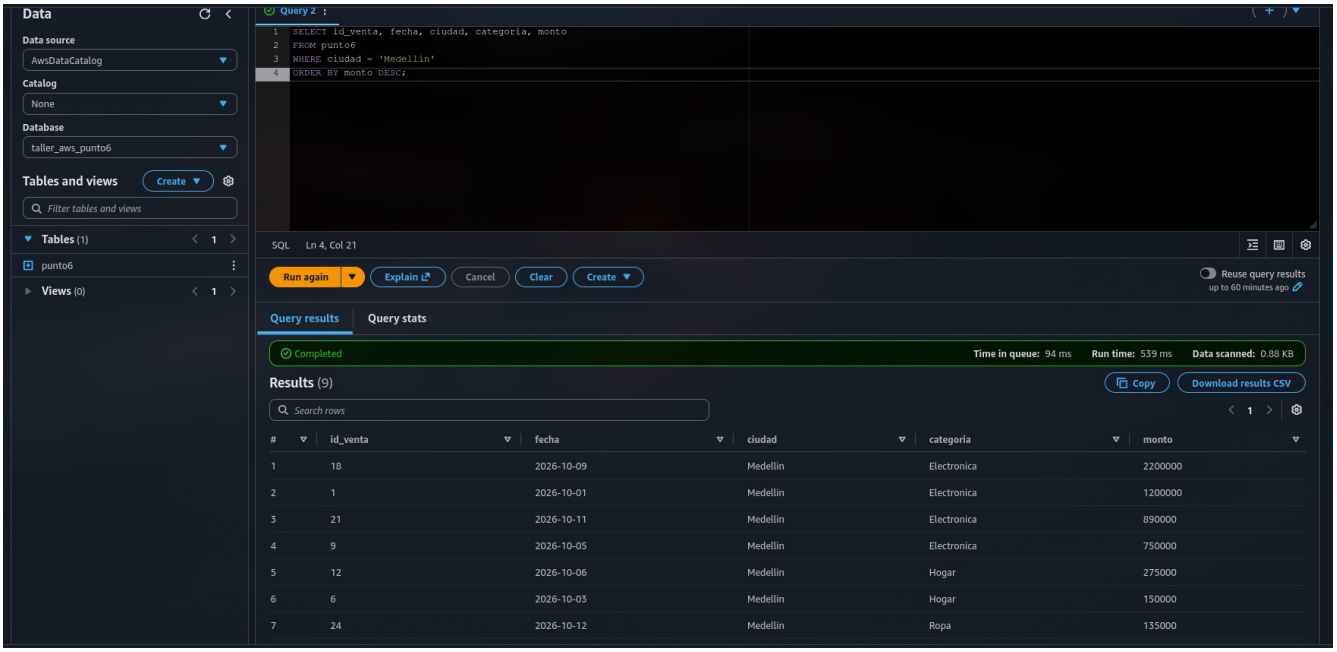
Tablas del catalogo



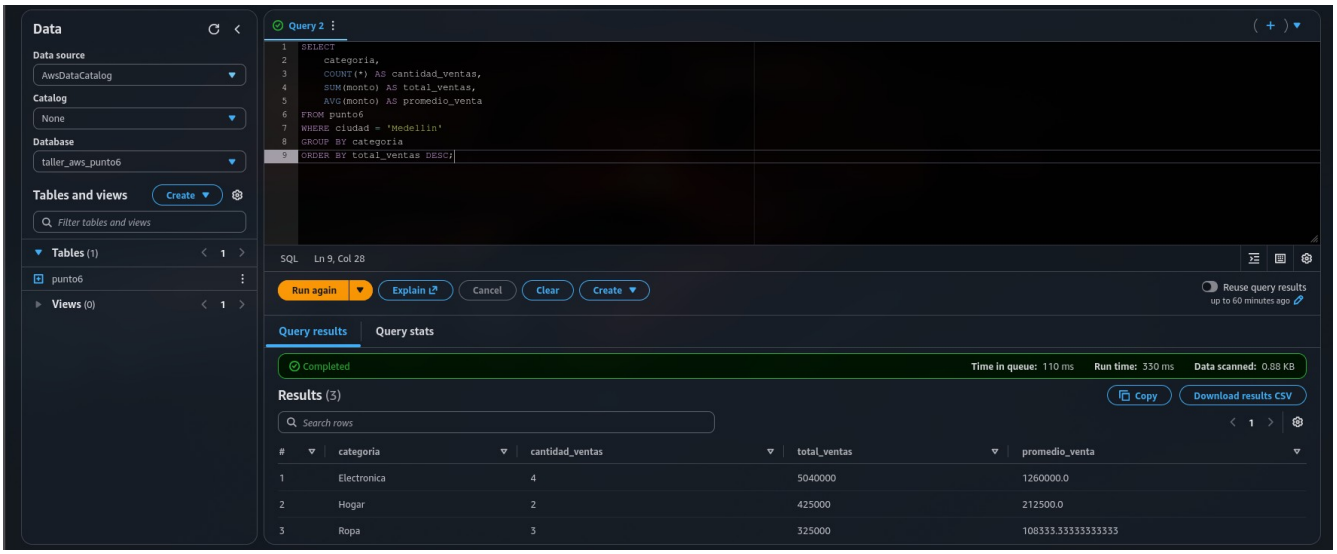


Consultas en Athena





Consulta de agregación



Agregar registros al dataset inicial

```
~ 1s ◎ cp datos/ventas.csv datos/ventas_inicial.csv                    (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:19

~ 0s ◎ ls -lh datos/                                                   (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:20
Permissions Size User     Date Modified Name
.rw-r--r--  897 dduquejh 16 Oct 22:01  ventas.csv
.rw-r--r--  897 dduquejh 16 Oct 22:20  ventas_inicial.csv

~ 0s ◎ echo '25,2026-10-13,Medellin,Electronica,500000                 (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:20
       26,2026-10-13,Bogota,Hogar,200000
       27,2026-10-14,Cali,Ropa,175000
       28,2026-10-14,Medellin,Hogar,300000' >> datos/ventas.csv

~ 0s ◎ wc -l datos/ventas.csv                                          (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:20
29 datos/ventas.csv
```

Cargar el nuevo dataset

```
~ 0s ◎ aws s3 cp datos/ventas.csv \                                    (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
            s3://jddh-0717-de/punto6/ventas.csv \
            --region us-east-2
upload: datos/ventas.csv to s3://jddh-0717-de/punto6/ventas.csv

~ 1s ◎ aws s3 ls s3://jddh-0717-de/punto6/ --region us-east-2          (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
2026-10-16 22:21:12       1040 ventas.csv

~ 1s ◎                                                                 (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
```

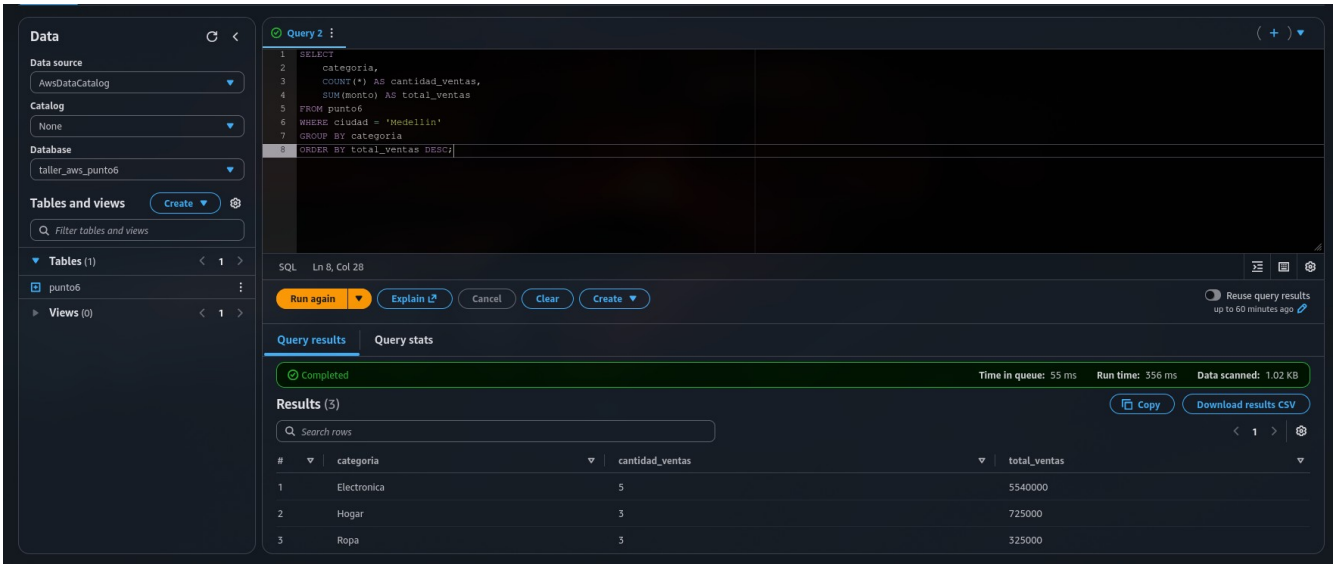
Actualizar el catalogo con Glue

```
~ 1s ◎ aws glue start-crawler \                                        (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
            --name crawler_ventas_punto6 \
            --region us-east-2

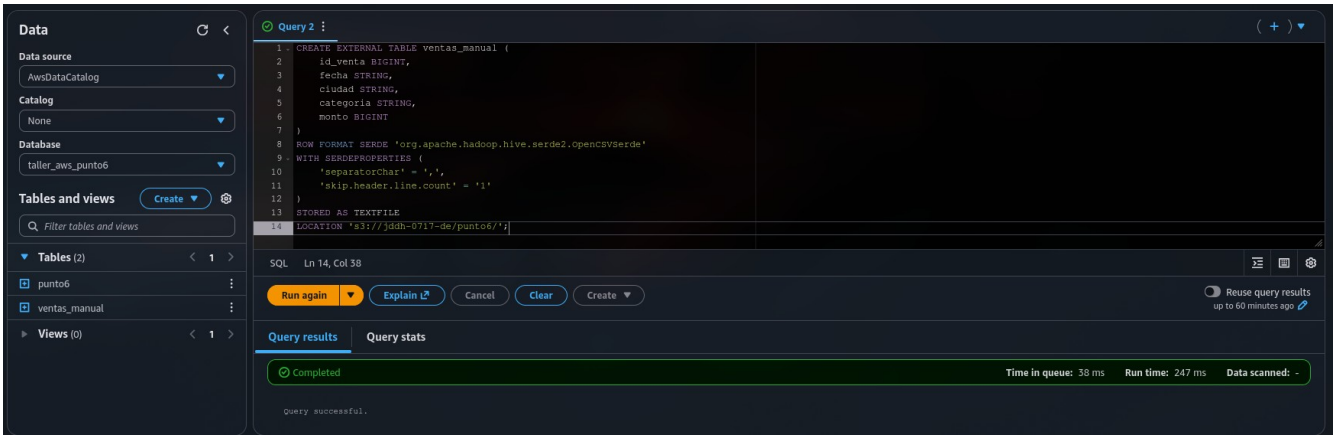
~ 1s ◎ aws glue get-crawler \                                          (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
            --name crawler_ventas_punto6 \
            --region us-east-2 \
            --query 'Crawler.{Estado:State,UltimoAnalisis:LastCrawl.Status}' \
            --output json
{
    "Estado": "RUNNING",
    "UltimoAnalisis": "SUCCEEDED"
}

~ 1s ◎                                                                 (aws) □ TallerAWS/Punto6 △|◌◦| conda ○ aws 22:21
```

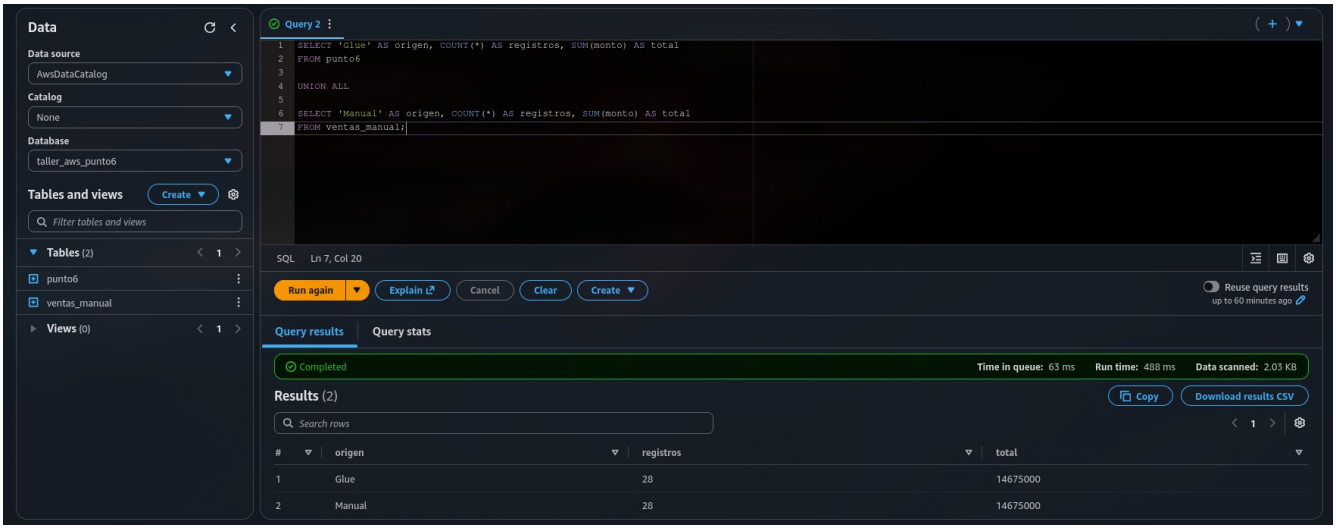
Consultas con los nuevos datos



Crear tabla manual en Athena



Comparacion tabla manual y catalogo



Eliminación

Eliminar el crawler

```
~ ls ◎ aws glue get-crawler \                                    (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:26
            --name crawler_ventas_punto6 \
            --region us-east-2 \
            --query 'Crawler.State' \
            --output text
READY

~ ls ◎ aws glue delete-crawler \                                 (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:26
            --name crawler_ventas_punto6 \
            --region us-east-2

~ ls ◎ aws glue get-crawlers \                                   (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:26
            --region us-east-2 \
            --query 'Crawlers[?Name==`crawler_ventas_punto6`].Name' \
            --output json
[]

~ ls ◎                                                           (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:26
```

Eliminación de las tablas

```
◄ 1s ◎ aws glue delete-table \                                    (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
            --database-name taller_aws_punto6 \
            --name punto6 \
            --region us-east-2

◄ 1s ◎ aws glue delete-table \                                    (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
            --database-name taller_aws_punto6 \
            --name ventas_manual \
            --region us-east-2

◄ 2s ◎ aws glue get-tables \                                      (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
            --database-name taller_aws_punto6 \
            --region us-east-2 \
            --query 'TableList[].Name' \
            --output json
[]

◄ 1s ◎                                                           (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
```

Eliminar la base de datos

```
◄ 1s ◎ aws glue delete-database \                                 (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
            --name taller_aws_punto6 \
            --region us-east-2

◄ 1s ◎ aws glue get-databases \                                   (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
            --region us-east-2 \
            --query 'DatabaseList[?Name==`taller_aws_punto6`].Name' \
            --output json
[]

◄ 1s ◎                                                           (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:27
```

Vaciar el bucket de S3

```
◄ 1s ◎ aws s3 rm s3://jddh-0717-de/ \                             (aws) □ TallerAWS/Punto6 △|●◦○◦| conda ○ aws 22:29
            --recursive \
            --region us-east-2
delete: s3://jddh-0717-de/Unsaved/2026/09/24/1adf48d3-67d1-4474-8156-3d82d4e5222b.txt
delete: s3://jddh-0717-de/Unsaved/2026/10/16/5c7711b1-78f1-4b07-b2bd-555d3b7116eb.csv.metadata
delete: s3://jddh-0717-de/Unsaved/2026/09/24/65738b5b-905a-4c41-8752-15d293f0391e.txt
delete: s3://jddh-0717-de/Unsaved/2026/10/16/72210f32-9145-4a78-b285-425fade64f93.csv.metadata
delete: s3://jddh-0717-de/Unsaved/2026/09/24/ae2ebe16-a1c6-49ac-b5cb-d94746f199cb.csv
delete: s3://jddh-0717-de/Unsaved/2026/10/16/72210f32-9145-4a78-b285-425fade64f93.csv
delete: s3://jddh-0717-de/Unsaved/2026/09/24/ae2ebe16-a1c6-49ac-b5cb-d94746f199cb.csv.metadata
delete: s3://jddh-0717-de/Unsaved/2026/10/16/b1af6035-caa3-400e-9ca2-1961406e1220.txt
delete: s3://jddh-0717-de/Unsaved/2026/10/16/5c7711b1-78f1-4b07-b2bd-555d3b7116eb.csv
delete: s3://jddh-0717-de/Unsaved/2026/10/16/bef5d660-8b3a-4a7f-bd1e-654dd8d26236.csv
delete: s3://jddh-0717-de/Unsaved/2026/10/16/bef5d660-8b3a-4a7f-bd1e-654dd8d26236.csv.metadata
delete: s3://jddh-0717-de/data/customers/city=Seville/data_0.parquet
delete: s3://jddh-0717-de/images/source_image.png
delete: s3://jddh-0717-de/data/customers/city=Barcelona/data_0.parquet
delete: s3://jddh-0717-de/Unsaved/2026/10/16/eb7da800-9459-4439-9c46-5fade2752be7.csv.metadata
delete: s3://jddh-0717-de/Unsaved/2026/10/16/f482b58b-f1d4-4bba-b87d-ae28cd72d764.csv.metadata
delete: s3://jddh-0717-de/Unsaved/2026/10/16/f482b58b-f1d4-4bba-b87d-ae28cd72d764.csv
delete: s3://jddh-0717-de/punto6/ventas.csv
delete: s3://jddh-0717-de/Unsaved/2026/10/16/eb7da800-9459-4439-9c46-5fade2752be7.csv
delete: s3://jddh-0717-de/data/customers/city=Valencia/data_0.parquet
delete: s3://jddh-0717-de/data/customers/city=Bilbao/data_0.parquet
delete: s3://jddh-0717-de/data/customers/city=Madrid/data_0.parquet
```

```
◄ 2s ◎ aws s3 ls s3://jddh-0717-de/ \                    (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:29
        --recursive \
        --region us-east-2

◄ 1s ◎                                                   (aws) □ TallerAWS/Punto6 △|●◦◌◦| conda ○ aws 22:29
```